



GÖTEBORGS UNIVERSITET

Institutionen för matematiska vetenskaper

Textklassificering på en liten datamängd

Sofia Fu
Malte Kjær Hemmingsen
Omar Alfarouk Malla
Alexander Gabriel Mitchell

Handledare: Maria Roginskaya

Bihandledare: Paula Femenias

VT 2026

Förord

Detta examensarbete har genomförts inom ramen för kandidatprojektet i samarbete med Byggnadsdesigngruppen vid Arkitekturinstitutionen. Projektet behandlar automatisk klassificering av intervjudata relaterad till människors skäl till att flytta, med hjälp av maskininlärningsmetoder inom textklassificering.

Vi vill rikta ett stort tack till vår handledare Maria för kontinuerlig vägledning, återkoppling och stöd under projektets gång. De regelbundna mötena har varit värdefulla för både projektets riktning och utveckling. Vi vill även tacka Paula och Byggnadsdesigngruppen för tillgång till datamaterialet samt för diskussioner kring resultaten och tolkningen av intervjuerna.

Bidragsrapport

Sofia Fu Har tillsammans med Omar Alfarouk Malla arbetat med datainläsning och förbehandling av textdata samt implementering av klassificeringsmodellerna Multinomial Naive Bayes och logistisk regression med L2-regularisering. Har även bidragit till implementation av meningsuppdelning och majoritetsröstning. I rapporten har Sofia skrivit inledning, abstract och resultatdelen (avsnitt 4), inklusive tolkning av tabeller och figurer med Omar Alfarouk Malla. Sofia har även skrivit metodavsnittet (avsnitt 3.1 och 3.5) samt varit delaktig i analys- och diskussionsdelen, inklusive avsnitt 5.1 och 5.2. Utöver detta har Sofia arbetat med språklig och innehållslig bearbetning av bakgrund och teori, vilket innefattar förbättring av struktur och flöde samt införande och numrering av ekvationer som använts i metod och diskussion.

Malte Kjær Hemmingsen Har bidragit till val och utveckling av metoder samt den teoretiska grunden bakom dessa. Han har tillsammans med Alexander Gabriel Mitchell arbetat med bakgrund och teori, där han bidragit till att forma problemformulering och teoretisk inramning av arbetet.

Under projektets gång har han varit aktiv i analys och diskussion av resultat, vilket har bidragit till tolkning av modellernas beteende och metodval. Han har skrivit delar av diskussionsavsnittet (avsnitt 5), särskilt kopplat till felklassificerade resultat samt jämförelser mellan modeller.

Malte har även varit ansvarig för den praktiska planeringen av projektet samt i kommunikationen med byggnadsdesigngruppen, vilket bidragit till förståelsen av datamaterialet och dess användning i projektet.

Omar Alfarouk Malla Har tillsammans med Sofia Fu haft huvudansvar för kodbasen, inklusive organisering, implementation av klassificeringsmodeller, utvärdering av modeller samt hantering av tränings och testdata. Han har även arbetat med vidareutveckling, felsökning och verifiering av kodens funktionalitet genom stegvis testning av olika delmoment. Omar har haft ansvar för sammanställning av resultat i tabeller (avsnitt 4) samt tillsammans med Sofia bidragit till tolkning av resultat utifrån tabeller och figurer. Han har även bidragit till analys, planering, slutsatser och förbättringsförslag i diskussionsdelen (avsnitt 5).

Alexander Gabriel Mitchell Har främst ansvarat för skrivandet av bakgrund och teori, inklusive litteratursökning, inläsning och sammanställning av relevant forskningslitteratur. Han

har även bidragit till strukturering och utveckling av metodavsnittet samt den övergripande uppbyggnaden av rapporten.

I diskussionsavsnittet (avsnitt 5) har han bidragit till tolkning av resultat och metodernas begränsningar, särskilt kopplat till teori och empiriska resultat. Arbetet har huvudsakligen fokuserat på textproduktion, teoretisk syntes och integration av forskningslitteratur i rapportens olika delar.

Sammandrag

Manuell klassificering av intervjudata är tidskrävande och subjektiv. Detta kandidatarbete utvärderar Multinomial Naive Bayes och L2-regulariserad logistisk regression på ett litet dataset bestående av 404 intervjuer om skäl till flytt, indelade i sex kategorier. Två textformat jämförs: fullständiga intervjuer kontra korta textbeskrivningar. Meningsnivåsegmentering med majoritetsröstning testas också som en potentiell förbättring.

Resultaten visar att logistisk regression konsekvent presterar bättre än Multinomial Naive Bayes, med ett viktat F1-värde på 71% jämfört med 61% för Multinomial Naive Bayes på korta textbeskrivningar. Korta, fokuserade texter ger bättre klassificering än fullständiga intervjuer, där irrelevant information försvårar mönsterigenkänning. Meningssegmentering förbättrar prestandan på korta texter men försämrar den på fullständiga intervjuer. Underrepresenterade kategorier felklassificeras konsekvent i alla experiment, huvudsakligen på grund av klassobalans.

Sammanfattningsvis kan automatiserad klassificering stödja manuell kategorisering, men är ännu inte tillförlitlig nog att ersätta den.

Abstract

Manual classification of interview data is time consuming and subjective. This thesis evaluates Multinomial Naive Bayes and L2-regularized logistic regression on a small dataset of 404 interviews about reasons for moving, divided into six categories. Two text formats are compared: full interviews versus short reason descriptions. Sentence-level segmentation with majority voting is also tested as a potential improvement.

Results show that logistic regression consistently outperforms Multinomial Naive Bayes, reaching a weighted F1 score of 71% compared to 61% for Multinomial Naive Bayes on short descriptions. Short, focused texts yield better classification than full interviews, where irrelevant information hinders pattern recognition. Sentence segmentation improves performance on short texts but harms it on full interviews. Underrepresented categories are consistently misclassified across all experiments, mainly due to class imbalance.

In conclusion, automated classification may support manual categorization but is not yet reliable enough to replace it.

Innehåll

1	Inledning	3
2	Bakgrund och teori	3
2.1	Statistiska utmaningar vid liten datamängd	3
2.1.1	Hög dimensionalitet och sparsitet	3
2.1.2	Överanpassning och generaliseringsförmåga	4
2.1.3	Klassobalans	4
2.1.4	Multilabel-klassificering	4
2.1.5	Bias–variance-avvägningen	4
2.2	Textrepresentation	5
2.3	Naive Bayes	5
2.4	Logistisk regression med regularisering	6
2.5	Utvärderingsmått	6
3	Metod	7
3.1	Datamaterial	7
3.2	Förbehandling av textdata	8
3.3	Datadelning och korsvalidering	8
3.4	Textrepresentation	9
3.5	Hantering av multilabel-klassificering	9
3.6	Modellimplementering	10
3.6.1	Klassificeringsmetoder	10
3.6.2	Meningsuppdelning som metodförbättring	11
4	Resultat	11
4.1	Klassificeringsresultat – hela intervjutext	11
4.2	Klassificeringsresultat – korta texter	14
5	Diskussion	19
5.1	Datakällans påverkan och modeljämförelse	19
5.1.1	Meningsuppdelningens effekt	20
5.2	Metodernas begränsningar	21
5.3	Förbättringsförslag	22

5.4	Slutsats	22
6	Källförteckning	22
7	AI-användande	23
A	Appendix	23

1 Inledning

Klassificering är ett viktigt sätt för människor att förstå och ordna världen. Vi delar in djur och växter i olika arter, människor efter politisk uppfattning eller religion, och i vardagen sorterar vi föremål efter likheter och skillnader för att förenkla hanteringen av dem. Även inom forskningen är klassificering central. När forskare genomför intervjustudier måste insamlad text ofta sorteras och kategoriseras manuellt, vilket är både tidskrävande och subjektivt. Automatisk textklassificering kan fungera som ett kompletterande verktyg, men många metoder kräver stora mängder träningsdata, vilket är något som saknas i detta projekt. Metoder som Multinomial Naive Bayes och logistisk regression med L2-regularisering har länge använts som robusta baslinjer inom textklassificering och har visat sig effektiva även vid begränsade datamängder (Jurafsky & Martin, 2009; Hastie et al., 2017).

Arbetet jämför dessa två klassificeringsmetoder på ett dataset bestående av 404 intervjuer om varför personer väljer att flytta, indelade i sex kategorier: renoveringen, området, familjeskäl, bostaden, andra bostadsrelaterade faktorer och vill bo på annat sätt. Två textformat utvärderas: fullständiga intervjutexter samt korta textbeskrivningar av flyttorsaken. Meningsnivåsegmentering med majoritetsröstning testas också som en potentiell förbättring. Vi undersöker hur väl maskinlärningsmodeller kan tränas för textklassificering på en liten datamängd. Fortsättningsvis undersöker vi hur modellernas prestanda påverkas av olika databehandlingsstrategier, i vilken utsträckning modellerna kan återskapa den manuella klassificeringen, samt hur den begränsade datamängden påverkar modellens stabilitet (det vill säga hur känsliga modellerna är för variationer i träningsdatan).

2 Bakgrund och teori

I detta avsnitt presenteras den teoretiska grund som projektet bygger på, från statistiska utmaningar vid liten datamängd till de klassificeringsmetoder och utvärderingsmått som används.

2.1 Statistiska utmaningar vid liten datamängd

2.1.1 Hög dimensionalitet och sparsitet

Hög dimensionalitet uppstår när antalet variabler överstiger antalet observationer och är en vanlig utmaning vid textklassificering, där varje unikt ord i datamängden utgör en separat variabel. Varje intervju utgör här ett dokument, det vill säga en observation, och de kategorier som intervjun tillhör utgör dess klass (James et al., 2013). Datamängden i detta projekt består av två texttyper: längre intervjutexter samt kortare, koncisa svar på orsak till flytt. Trots att datamängden är begränsad genererar den samlade vokabulären ett stort antal variabler i förhållande till antalet dokument, vilket resulterar i en högdimensionell och gles frekvensmatris. I frekvensmatrisen är raderna intervjuer, kolumnerna unika ord i hela datamängden och värdena i matrisen är hur många gånger ordet förekommer i en intervju.

2.1.2 Överanpassning och generaliseringsförmåga

Den höga dimensionaliteten ökar risken för överanpassning, det vill säga att modellen anpassas alltför starkt till träningsdatan och lär sig slumpmässiga variationer snarare än underliggande struktur (James et al., 2013). En överanpassad modell presterar väl på träningsmängden men har sämre generaliseringsförmåga, som är förmågan att prestera väl på nya, tidigare osedda observationer. För att motverka överanpassning delas data upp i tränings- och testmängd, och stratifierad korsvalidering används för att få en mer tillförlitlig uppskattning av modellens prestanda samt säkerställa att klassfördelningen bibehålls i varje fold.

2.1.3 Klassobalans

Klassobalans uppstår när vissa klasser innehåller betydligt fler dokument än andra, vilket kan göra det svårt för modellen att korrekt lära sig mönster i de underrepresenterade klasserna (He & Garcia, 2009). Detta riskerar att modellen favoriserar majoritetsklassen, vilket kan leda till att mindre förekommande klasser klassificeras fel oftare, trots att modellens övergripande noggrannhet är hög (Leevy, Khoshgoftaar, Bauder & Seliya, 2018). I detta projekt varierar antalet dokument per kategori avsevärt. För att minska effekten av klassobalans används F_1 som utvärderingsmått istället för enbart accuracy (se avsnitt 2.5), och korsvalidering säkerställer att även små klasser får möjlighet att påverka modellträningen.

2.1.4 Multilabel-klassificering

Vid multilabel-klassificering kan en observation tillhöra flera klasser samtidigt, till skillnad från flerklassificering där varje observation tilldelas exakt en klass (James et al., 2013). Detta ställer högre krav på både modellval och utvärdering. I detta projekt kan varje intervju tillhöra flera av de sex huvudkategorierna samtidigt, vilket innebär att standardmetoder som Multinomial Naive Bayes och logistisk regression med L2-regularisering inte direkt är tillämpbara i sin grundform. En vanlig ansats är att omvandla problemet till flera binära klassificeringsproblem, ett per klass, eller att duplicera träningsdata så att varje observation förekommer en gång per kategoritillhörighet (Zhang & Zhou, 2014).

2.1.5 Bias–variance-avvägningen

Vid modellval uppstår en avvägning mellan bias och varians. Bias mäter hur mycket modellens prediktioner i genomsnitt avviker från de sanna värdena, medan varians mäter hur känslig modellen är för variationer i träningsdatan (James et al., 2013). Det förväntade prediktionsfelet kan dekomponeras som

$$\mathbb{E}[(y - \hat{f}(x))^2] = \text{Bias}(\hat{f}(x))^2 + \text{Var}(\hat{f}(x)) + \sigma^2, \quad (1)$$

där σ^2 är det irreducibla bruset i datan. De två modeller som tillämpas i detta projekt befinner sig på olika positioner längs detta spektrum, där Multinomial Naive Bayes har hög bias till följd av oberoendeantagandet men låg varians, medan penaliserad regression minskar variansen via regularisering på bekostnad av ökad bias (James et al., 2013). Vid liten datamängd, där risken för överanpassning är märkbar, kan en högre bias vara ett acceptabelt pris för ökad stabilitet i modellens prediktioner.

2.2 Textrepresentation

Innan klassificeringsmodellerna kan tillämpas måste intervjutexterna omvandlas till numeriska representationer. I **bag-of-words**-modellen representeras ett dokument som en vektor av ordantal, där varje position i vektorn motsvarar hur många gånger ett specifikt ord förekommer i texten. Ordens ordning ignoreras, så dokumentet behandlas som en osorterad samling ord (Jurafsky & Martin, 2009). Modellen är enkel att implementera och fungerar ofta som utgångspunkt i textklassificering, men ignorerar semantiskt sammanhang och förstärker den dimensionalitetsproblematik som beskrivs ovan.

TF-IDF (Term Frequency–Inverse Document Frequency) är en viktningsmetod som bygger vidare på bag-of-words genom att tilldela varje ord ett värde baserat på hur ofta det förekommer i ett dokument relativt hur vanligt det är i hela korpusen (Jurafsky & Martin, 2009). Termfrekvensen för ord w i dokument d definieras som

$$\text{TF}(w, d) = \frac{f_{w,d}}{\sum_{w' \in d} f_{w',d}},$$

och invers dokumentfrekvens definieras som

$$\text{IDF}(w) = \log \frac{N}{1 + |\{d : w \in d\}|},$$

där $f_{w,d}$ är antalet gånger ordet w förekommer i dokument d , N är totalt antal dokument och $|\{d : w \in d\}|$ är antalet dokument som innehåller ordet w . Ettan i nämnaren förhindrar division med noll. Det kombinerade TF-IDF-värdet ges av

$$\text{TF-IDF}(w, d) = \text{TF}(w, d) \cdot \text{IDF}(w) \quad (2)$$

som innebär att ord som är specifika för ett dokument får höga vikter, medan ord som förekommer i nästan alla dokument nedvärderas automatiskt. I vårt projekt används TF-IDF med maximalt 2000 funktioner för att begränsa dimensionaliteten.

2.3 Naive Bayes

Naive Bayes är en probabilistisk klassificeringsmetod baserad på Bayes sats och antagandet om villkorligt oberoende mellan ord givet klassen (Jurafsky & Martin, 2009). Trots detta förenklade antagande har metoden visat sig vara effektiv inom textklassificering, särskilt vid små datamängder (Hastie, Tibshirani & Friedman, 2017).

Bayes sats beskriver hur sannolikheten för en händelse c sker givet ny information $\mathbf{d}$ (James et al., 2013),

$$P(c | \mathbf{d}) = \frac{P(\mathbf{d} | c) \cdot P(c)}{P(\mathbf{d})},$$

där $P(c)$ är priorsannolikheten för klass c , $P(\mathbf{d} | c)$ är sannolikheten att observera dokument $\mathbf{d}$ givet klassen, och $P(c | \mathbf{d})$ är den eftersökta posteriorsannolikheten.

Det centrala antagandet i Naive Bayes är att alla ord i ett dokument är villkorligt oberoende av varandra givet klassen (James et al., 2013). Vilket innebär att

$$P(\mathbf{d} | c) = \prod_{i=1}^n P(\omega_i | c), \quad (3)$$

där ω_i är det i :te ordet i dokumentet $\mathbf{d}$ givet klass c (Jurafsky & Martin, 2009).

I detta projekt används varianten **Multinomial Naive Bayes** (MNB), där sannolikheten $P(\mathbf{d} | c)$ modelleras genom en multinomial fördelning över ord. Detta innebär att dokumentet betraktas som en samling ord där varje ord förekommer ett visst antal gånger beroende på klassen (Jurafsky & Martin, 2009). Ett dokument representeras som en vektor av ordantal där varje ord har en viss sannolikhet att förekomma givet klassen. Den multinomiala sannolikhetsfunktionen ges av

$$P(X) = \frac{n!}{n_1! n_2! \dots n_m!} p_1^{n_1} p_2^{n_2} \dots p_m^{n_m}, \quad (4)$$

där n är det totala antalet ord, n_i är antalet förekomster av ord i och p_i är sannolikheten för ord i givet klassen.

2.4 Logistisk regression med regularisering

Logistisk regression är en klassificeringsmetod, som modellerar sannolikheten att en observation tillhör en viss klass. Vid fler än två klasser används multinomial logistisk regression, där ett linjärt värde först beräknas för varje klass,

$$z_c = \omega_c \cdot \mathbf{x} + b_c \quad (5)$$

där ω_c är viktvektorn, b_c är bias för klass c och $\mathbf{x}$ är dokumentets feature vektor, det vill säga dess numeriska representation efter TF-IDF omvandlingen. Sannolikhetsfördelningen över alla K klasser erhålls sedan via **softmax-funktionen**,

$$P(Y = c | \mathbf{x}) = \frac{e^{z_c}}{\sum_{k=1}^K e^{z_k}}, \quad (6)$$

vilket säkerställer att sannolikheterna summerar till ett och att modellen kan jämföra alla klasser direkt mot varandra (James et al., 2013).

För att begränsa modellens komplexitet och minska risken för överanpassning penaliseras koefficienterna via en regulariseringsterm som läggs till i kostnadsfunktionen (James et al., 2013). **L2-regularisering**, även kallad Ridge, lägger till summan av koefficienternas kvadrater,

$$\mathcal{L}_{\text{Ridge}} = \mathcal{L} + \lambda \sum_j \omega_{c,j}^2. \quad (7)$$

Parametern λ styr penaliseringens styrka. I praktiken parametreras detta ofta som $C = \frac{1}{\lambda}$, där ett litet C ger stark regularisering och ett stort C ger svag regularisering. L2 krymper alla koefficienter mot noll utan att eliminera dem, vilket är en egenskap som kan vara fördelaktig vid högdimensionella data (James et al., 2013).

2.5 Utvärderingsmått

Modellernas prestanda utvärderas med etablerade klassificeringsmått definierade utifrån antalet sanna positiva (TP), falska positiva (FP), falska negativa (FN) och sanna negativa (TN) (Hastie, Tibshirani & Friedman, 2017). Noggrannhet ger andelen korrekt klassificerade observationer,

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (8)$$

men är ett missvisande mått vid klassobalans. Precision och recall fångar komplementära aspekter av modellens förmåga

$$\text{Precision} = \frac{TP}{TP + FP},$$

$$\text{Recall} = \frac{TP}{TP + FN}$$

och F_1 -mättet kombinerar medelvärde av precision och recall

$$F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}. \quad (9)$$

För en fullständig bild av modellens prestanda används viktad F_1 där vanligare klasser får proportionerligt större inflytande på det slutliga värdet

$$\text{Viktad } F_1 = \sum_{c=1}^C \frac{n_c}{N} \cdot F_{1,c} \quad (10)$$

där n_c är antalet observationer i klass c , N är det totala antalet observationer och $F_{1,c}$ är F_1 -mättet för klass c definierad enligt ekvation (9).

3 Metod

I detta avsnitt beskrivs den metodologi som tillämpats i studien, från datainsamling och förbehandling till modellimplementering och utvärdering. Analysen genomförs i fyra experimentella konfigurationer enligt tabell 2, där datakälla och segmenteringsstrategi varierar systematiskt för att undersöka deras påverkan på klassificeringsprestanda.

3.1 Datamaterial

Datamaterialet kommer från Byggnadsdesigngruppen vid Arkitekturinstitutionen och består av anonymiserade intervjuer med personer som tillfrågats om skälen till sin flytt. Varje intervju hade tilldelats ett unikt kodnummer (Pxxx) utan koppling till namn eller andra identifierande uppgifter när vi fick tillgång till materialet. Materialet finns i två format som används parallellt i studien. Det första formatet består av 453 transkriberade intervjuer i .docx-format, där varje fil innehåller en fullständig intervju per person. Texterna är relativt långa och innehåller både intervjufrågor och svar, vilket innebär att inte all text är direkt relevant för flyttorsaken. Det andra formatet är en excel-fil med 450 kortare textbeskrivningar, en till två meningar per person, där enbart den faktiska orsaken till flytten är nedskriven. Denna data är mer koncis och fokuserad jämfört med de fullständiga intervjuerna. Eftersom en person kan ha angett flera skäl till sin flytt är klassificeringen av multilabel-karaktär, vilket hanteras genom den dupliceringsansats som beskrivs i avsnitt 3.5.

Av de 453 transkriberade intervjuer i .docx-format och 450 kortare textbeskrivningar, används endast 404 intervjuer eftersom det endast är dessa intervjuer som har tillhörande facit i form av klassificerade flyttorsaker. De resterande intervjuerna från det transkriberade intervjuer i .docx-format och kortare textbeskrivningar exkluderas därför från analysen. De exkluderade

intervjuerna har inte granskats närmare, och det kan inte uteslutas att de systematiskt skiljer sig från de inkluderade vad gäller exempelvis kategoritillhörighet eller textlängd, vilket skulle kunna påverka resultatens generaliserbarhet. Totalt finns facit för 404 unika intervjuer fördelade över sex huvudkategorier: *renoveringen*, *området*, *familjeskäl*, *bostaden*, *andra bostadsrelaterade faktorer*, *vill bo på annat sätt*. De ursprungliga 40 underkategorierna har grupperats till dessa 6 huvudkategorier för att ge modellen tillräckligt med data i varje klass.

För att förstå modellernas förutsättningar presenteras datamängdens fördelning i tabell 1.

Tabell 1: Antal intervjuer per kategori	
Kategori	Antal intervjuer
bostaden	218
familjeskäl	132
renoveringen	112
vill bo på annat sätt	98
området	67
andra bostadsrelaterade faktorer	41
Summa kategoritillhörigheter (multilabel)	668
Antal unika intervjuer	404

Tabell 1 visar en tydlig klassobalans, där kategorin *bostaden* är drygt fem gånger större än den minsta klassen. Denna ojämnheter försvårar modellernas identifiering av särdrag för mindre kategorier, då minoritetsklasserna riskerar att överskuggas av mer frekvent förekommande ord i de större klasserna. Skillnaden mellan unika intervjuer (404) och totala tillhörigheter (668) visar att en stor andel av informanterna har angett flera flyttorsaker (ett snitt på 1,65 kategorier per person). Detta motiverar den dupliceringsansatsen i avsnitt 3.5 för att maximera träningsdatan.

3.2 Förbehandling av textdata

För att förbättra modellens prestanda genomfördes textförbehandling i flera steg. Texterna konverterades först till små bokstäver, varefter specialtecken och siffror togs bort. Sedan exkluderades ord kortare än två tecken samt ord som saknade vokaler (exempelvis interjektioner som 'öhm'), i syfte att rensa bort icke-informativt brus från datamängden. Därefter tokeniserades texten, det vill säga delades upp i enskilda ord som sedan användes som modellens ingångsdata (Jurafsky & Martin, 2009). Förbehandlingen tillämpades på data som användes både för Multinomial Naive Bayes och logistisk regressionsmodellen, så att inputvektorerna för båda metoderna var jämförbara.

3.3 Datadelning och korsvalidering

För att träna och utvärdera modellerna delades intervjudata upp i 80% träningsdata och 20% testdata. Uppdelningen gjordes på unika intervju-ID för att säkerställa att samma intervju inte förekom i både träning och testmängden. Detta är särskilt viktigt vid duplicerad träningsdata där en intervju kan förekomma flera gånger under olika kategorier. Utan denna kontroll skulle identiska textrader kunna hamna i både träning och test, vilket skulle ge en missvisande

överskattning av modellens generaliseringsförmåga.

Under modellträning användes stratifierad korsvalidering med 5 folds, där varje fold bevarar klassfördelningen från hela datasetet. För varje iteration tränas modellen på fyra folds och testas på den återstående folden, där TF-IDF-vektoriseringen anpassas enbart till träningsdata för att förhindra informationsläckage. Detta ska säkerställa en mera robust utvärdering av modellen genom att varje intervju används som testdata exakt en gång, samtidigt som klassfördelningen bevaras i varje fold. På detta sätt blir varje fold representativ för hela datasetet, och maximerar utnyttjandet av den begränsade datamängden. Slutresultatet beräknas genom att samla samtliga förutsägelser från alla fem iterationer och utvärdera dem samlat.

3.4 Textrepresentation

Intervjutexterna representerades som TF-IDF-vektorer, i enighet med den metodik som beskrivs i avsnitt 2.2. På detta sätt fångas både förekomstmönster och informationsvärde hos orden, vilket förbättrar modellens möjlighet att skilja mellan olika kategorier. Vektorerna från TF-IDF användes sedan som input för både Multinomial Naive Bayes och logistisk regressionsmodell för att klassificera intervjuerna efter kategori.

3.5 Hantering av multilabel-klassificering

Eftersom varje intervju kan tillhöra flera kategorier samtidigt, kan modellerna i ekvation (4) och (6) inte tillämpas direkt i sin grundform, som förutsätter en klass per observation. För att hantera detta omvandlades problemet till ett flertal enkelklassificeringsfall genom att träningsdatan duplicerades, där varje intervju med flera kategorier i facit får en separat rad per kategori, så att modellen tränades på varje kategoritillhörighet individuellt. Exempelvis kan en intervju vara märkt med både *Renovering* och *Familjeskäl* om personen har uttalat båda dessa som skäl till att flytta. Intervjun förekommer då två gånger i träningsdatan, där samma text kopplas till en kategori i taget. Testdatan förblev oförändrad, och en prediktion räknades som korrekt om den predicerade kategorin återfanns bland en av intervjuens faktiska kategorier.

Fördelen med denna ansats är att implementationen är förhållandevis enkel och att träningsmängden ökar markant, vilket innebär att underrepresenterade kategorier exponeras oftare under träningen och modellen blir mer robust. Utan dupliceringen hade en dominerande kategori behövt väljas per intervju, vilket hade medfört informationsförlust och försämrat modellens förmåga att lära sig mönster för alla relevanta kategorier. Därmed blir sannolikheten att träffa rätt kategori betydligt bättre för multilabel intervjuer vilket är fördelaktigt då dessa intervjuer anses innehålla mer information och mer komplexa fall.

Det bör noteras att ansatsen medför statistiska begränsningar. Att samma intervjutext förekommer flera gånger i träningsdatan bryter mot antagandet om oberoende observationer som Multinomial Naive Bayes vilar på (James et al., 2013) i ekvation (3), vilket kan leda till vilseledande sannolikhetssuppskattningar och att frekventa klasser överrepresenteras. För logistisk regression med L2-regularisering innebär dupliceringen att intervjuer med flera kategorier får större inflytande på modellens koefficienter ω_c i ekvationerna (5) och (6), eftersom samma text förekommer flera gånger under träningen och därmed introducerar en implicit viktning som inte explicit modellerats, jämfört med intervjuer med en enda kategori. Dessa begränsningar bör beaktas vid tolkning av resultaten.

3.6 Modellimplementering

Samtliga modeller implementerades i Python med biblioteken scikit-learn (klassificering och korsvalidering), pandas (datahantering) och matplotlib samt seaborn (visualisering). Fyra experimentella konfigurationer testades för att undersöka hur datakälla och segmentering påverkar klassificeringsprestanda, vilket sammanfattas i tabell 2.

Tabell 2: Översikt över experimentella metoder och datakonfigurationer.

Metod	Datakälla	Segmentering	Syfte och karaktär
1	Word-filer	Ingen	Test av hela intervjutext med rik kontext.
2	Excel	Ingen	Test av korta, manuellt sammanfattade orsaker.
3A	Word-filer	Meningar	Uppdelning i meningar för fler och mer fokuserade datapunkter.
3B	Excel	Meningar	Uppdelning av korta texter för att öka datamängden ytterligare.

I metod 3A och 3B delades texterna upp i enskilda meningar och varje mening klassificerades separat, varefter prediktionerna kombinerades med majoritetsröstning för att ge en slutlig prediktion per intervju (se avsnitt 3.6.2).

3.6.1 Klassificeringsmetoder

För att klassificera intervjuerna används **Multinomial Naive Bayes-modellen** i ekvation (4) med TF-IDF-vektorer som input i ekvation (2). Multinomial Naive Bayes valdes eftersom det är en enkel och beräkningsmässigt effektiv modell som ofta fungerar väl som en stark baslinje i textanalys, vilket gör den lämplig att jämföra med logistisk regression med L2-regularisering. Dessutom är den särskilt lämpad för textklassificering med högdimensionella, glesa data och används ofta för textklassificering tack vare goda prestanda i bag-of-words-baserade representationer (Jurafsky & Martin, 2009).

Multinomial logistisk regression valdes som en av de primära klassificeringsmetoderna eftersom den möjliggör en direkt sannolikhetsmodellering över flera kategorier med softmax-funktionen (6). Modellen valdes även för att dess koefficienter medger en god tolkningsbarhet av vilka ord i TF-IDF-vektorer (2) som starkast driver klassificeringen till en viss kategori (Levy et al., 2018).

För att minska risken för överanpassning inkluderades L2-regularisering (Ridge) i ekvation (7). Detta val gjordes för att hantera den höga dimensionaliteten i textdatan genom att bestraffa stora koefficientvärden. Då studiens syfte var att jämföra särdragsrepresentationer användes standardvärdet på regulariseringsstyrkan $C = 1$ ($\lambda = 1$) som en enhetlig baslinje, snarare än att genomföra en individuell parametersökning.

Modellen utvärderades med viktat F_1 -mått som primärt prestationsmått enligt ekvation (10),

vilket är motiverat av den klassobalans som föreligger i datamängden (se avsnitt 2.1.3). Modellen tränades och utvärderades med 5-faldig korsvalidering för att garantera att resultaten är stabila och inte beroende av en specifik uppdelning av träningsdaten.

3.6.2 Meningsuppdelning som metodförbättring

För att undersöka om klassificeringen kunde förbättras delades texten upp i mindre enheter genom att skapa nya meningar separerade vid varje punkt, frågetecken och utropstecken. Varje mening klassificerades separat, och prediktionerna kombinerades sedan med majoritetsröstning: den kategori som förekom flest gånger bland meningarnas prediktioner valdes som den slutliga prediktionen för hela intervjun. Vid lika antal röster, exempelvis kunde en intervju delas upp i två meningarna "Lägenheten var för liten." och "Vi behövde flytta närmare familjen.". Om modellen då klassificerade de två meningar som *bostaden* och *familjeskäl* respektive, avgjordes fallet genom att välja den kategori som predicerades först i texten. I detta fall blev den slutliga prediktionen *bostaden*. På så sätt tilldelas varje intervju alltid en specifik huvudkategori.

Metoden tillämpades på både fullständiga intervjutexter och korta textbeskrivningar, för både Multinomial Naive Bayes och logistisk regression med L2-regularisering.

4 Resultat

I detta avsnitt presenteras klassificeringsresultaten för samtliga experimentella uppställningar enligt tabell 2. Resultaten redovisas i två delar: klassificering av hela intervjutexter och klassificering av korta textbeskrivningar inklusive meningsuppdelning i varje avsnitt som metodförbättring. För varje uppställning redovisas precision, recall och F_1 -score per kategori, kompletterat med confusion matrix som illustrerar felklassificeringsmönster. Vi prioriterar viktat F_1 -score framför accuracy för att hantera datasetets obalans. Accuracy inkluderas som referensvärde men dess tillförlitlighet är begränsad i detta sammanhang (se avsnitt 2.1.3).


4.1 Klassificeringsresultat – hela intervjutext

Tabell 3: Multinomial Naive Bayes metod 1

Kategori	Precision	Recall	F1
Andra bostadsrelaterade faktorer	0%	0%	0%
Bostaden	52%	84%	64%
Familjeskäl	0%	0%	0%
Området	0%	0%	0%
Renoveringen	29%	45%	35%
Vill bo på annat sätt	0%	0%	0%
Accuracy (genomsnitt)	48%		
Viktat F_1-mått	37%		

Tabell 3 visar att Multinomial Naive Bayes på hela intervjutexter endast lyckas identifiera *bostaden* med ett F_1 -värde på 64% och *renoveringen* med 35%. Övriga fyra kategorier får 0% på

sanatliga mått, vilket innebär att modellen inte identifierar någon enda korrekt observation för dessa klasser. Den totala noggrannheten på 48% är missvisande eftersom den i huvudsak speglar att modellen koncentrerar sina prediktioner till de två dominerande kategorierna. Det viktade F_1 -måttet på 37% visar att modellens totala klassificeringsförmåga är låg, även när hänsyn tas till klassernas storlek.




Figur 1: Confusion Matrix för Multinomial Naive Bayes på hela intervjutexter (metod 1). Rader representerar faktiska kategorier och kolumner representerar predikterade kategorier.

Confusion matrix i figur 1 bekräftar mönstret i tabell 3. Modellen predikterar i stort sett enbart *bostaden* eller *renoveringen*, vilket innebär att diagonalen för övriga kategorier är tom och att observationer tillhörande dessa klasser felklassificeras generellt. Exempelvis klassificeras 50 av 66 observationer i *familjeskäl* som *bostaden* och 16 som *renoveringen*, trots att ingen tillhör dessa kategorier.

Tabell 4: Logistisk regression med L2-regularisering (Ridge) metod 1

Kategori	Precision	Recall	F1
Andra bostadsrelaterade faktorer	0%	0%	0%
Bostaden	54%	86%	66%
Familjeskäl	67%	9%	16%
Området	0%	0%	0%
Renoveringen	43%	64%	52%
Vill bo på annat sätt	100%	10%	18%
Accuracy (genomsnitt)	52%		
Viktat F_1-mått	43%		

Metoden logistisk regression med L2-regularisering på hel intervjutext presenteras i tabell 4 som visar att Ridge fördelar prediktionerna något mer jämnt än Multinomial Naive Bayes, men att *bostaden* och *renoveringen* fortfarande dominerar. Att Ridge klarar att identifiera enstaka observationer i *familjeskäl* och *vill bo på annat sätt* tyder på att modellen är något bättre på att utnyttja svagare signaler i texten, vilket överensstämmer med att regulariseringen stabiliserar modellen i högdimensionell data. Det viktade F_1 -måttet på 43% visar att modellen har en bättre övergripande balans mellan precision och recall jämfört med Multinomial Naive Bayes. F_1 -måttet på dem övriga kategorierna med 0% sker på kategorier med få observationer i datamängden enligt tabell 1.



Figur 2: Confusion matrix för logistisk regression med L2-regularisering på hel intervjutext (metod 1).

Confusion matrix i figur 2 stärker mönstret i tabell 4 där modellen predicerar korrekt på fler kategorier som *familjeskäl* med 6 observationer och *vill bo på annat sätt* med 3 observationer.


Resultaten för meningsuppdelning på hela intervjutexter (metod 3A) redovisas i Appendix (tabell 9 och tabell 10 samt figur 8 och figur 9). Båda modellerna försämrar av meningsuppdelning på hela intervjuer där Multinomial Naive Bayes sjunker från 37% till 27% och Ridge från 43% till 32% i viktat F_1 -mått, vilket tyder på att uppdelningen bryter kontext som är viktig för klassificeringen av långa texter.

4.2 Klassificeringsresultat – korta texter

Tabell 5: Multinomial Naive Bayes metod 2

Kategori	Precision	Recall	F1
Andra bostadsrelaterade faktorer	0%	0,0%	0,0%
Bostaden	63%	87%	73%
Familjeskäl	84%	66%	74%
Området	0%	0%	0%
Renoveringen	63%	78%	70%
Vill bo på annat sätt	75%	10%	18%
Accuracy (genomsnitt)	66%		
Viktat F_1-mått	61%		

Tabell 5 representerar klassificeringsresultat för modellen baserat på korta texter. Multinomial Naive Bayes uppnår 66% accuracy och identifierar nu tre kategorier med F_1 -värden över 70%: *bostaden* (73%), *familjeskäl* (74%) och *renoveringen* (70%). Kategorin *vill bo på annat sätt* uppvisar hög precision (75%) men låg recall (10%), vilket innebär att modellen är restriktiv och bara identifierar ett fåtal fall med relativt hög säkerhet. Kategorierna *området* och *andra bostadsrelaterade faktorer* förblir ej identifierbara. Det viktade F_1 -mättet på 61% visar att modellen uppnår en tydligt bättre övergripande balans mellan precision och recall vid klassificering av korta texter.



Figur 3: Confusion Matrix för Multinomial Naive Bayes på Excel data med korta textbeskrivning.


Figur 3 visar att prediktionerna nu är mer spridda över kategorierna jämfört med hela intervjutexter. Exempelvis klassificeras 53 av 79 observationer i *familjeskäl* korrekt, medan 25 av 79 felklassificeras som *bostaden*. Detta är en tydlig förbättring från hela intervjutexter, där *familjeskäl* inte identifierades alls. Att *området* fortfarande inte identifieras beror sannolikt på att kategorin beskrivs med ett brett och varierat ordförråd utan tydliga signalord, vilket gör det svårt för en bag-of-words-baserad modell att lära sig stabila mönster.

Tabell 6: Logistisk regression med L2-regularisering (Ridge) metod 2

Kategori	Precision	Recall	F1
Andra bostadsrelaterade faktorer	100%	11%	20%
Bostaden	70%	88%	78%
Familjeskäl	78%	73%	75%
Området	75%	13%	22%
Renoveringen	74%	82%	78%
Vill bo på annat sätt	82%	56%	67%
Accuracy (genomsnitt)	73%		
Viktat F_1-mått	71%		

Logistisk regression (tabell 6) uppnår ett viktat F_1 -mått på 71%, vilket är studiens högsta resultat. En central skillnad mot Multinomial Naive Bayes är att Ridge här identifierar samtliga kategorier, om än med varierande precision. Kategorierna *Bostaden* och *renoveringen* når båda 78% i F_1 -score, vilket kan förklaras av en homogen terminologi med specifika nyckelord som skapar en tydlig separation i TF-IDF-representationens vektorrum. Som framgår av figur 10 i Appendix, definieras dessa av entydiga tekniska särdrag; för *renoveringen* har ord som **”evalueras”** och **”renoveringen”** mycket hög prediktiv kraft.

Kategorierna *området* (22%) och *andra bostadsrelaterade faktorer* (20%) förblir svaga. Detta beror dels på klassobalans enligt tabell 1, men också på en mer heterogen vokabulär (hög intern varians) som gör det svårt för modellen att definiera ett enhetlig beslutsområde. Detta syns tydligt för *andra bostadsrelaterade faktorer* där de starkaste ord, såsom **”ut”** och **”ändrahandskontrakt”**, är mer generiska. För denna kategori är precisionen 100% men recall endast 11%, vilket visar att modellen är mycket selektiv och endast predikterar kategorin vid hög statistisk säkerhet.



Figur 4: Confusion Matrix för logistisk regression (Ridge) på korta textbeskrivningar.


Figur 4 visar en tydligt mer balanserad fördelning av prediktioner jämfört med tidigare konfigurationer. Diagonalen är markant mörkare, vilket indikerar fler korrekta prediktioner. De vanligaste felklassificeringarna sker mellan *bostaden* och *renoveringen* (12 observationer i *bostaden* predikteras som *renoveringen*), vilket är förståeligt eftersom dessa kategorier kan innehålla överlappande ordförråd när intervjupersoner diskuterar renoveringar av sina bostäder.

Tabell 7: Multinomial Naive Bayes metod 3B

Kategori	Precision	Recall	F1
Andra bostadsrelaterade faktorer	0%	0%	0%
Bostaden	67%	87%	76%
Familjeskäl	81%	70%	75%
Området	0%	0%	0%
Renoveringen	67%	86%	75%
Vill bo på annat sätt	92%	33%	49%
Accuracy (genomsnitt)	70%		
Viktad F_1-mått	66%		

Tabell 7 visar att meningsuppdelning förbättrar Multinomial Naive Bayes på korta texter. Den markanta förbättringen för *vill bo på annat sätt* (från F_1 18% i tabell 5 till 49%) tyder på att denna kategori innehåller specifika meningar med starka signalord som lyfts fram tydligare när texten delas upp. Den höga precisionen (92%) men låga recall (33%) indikerar att modellen

är mycket säker när den väl predikterar denna kategori, men missar många fall. Det viktade F_1 -måttet på 66% visar att modellen har en god övergripande balans mellan precision och recall när meningsuppdelning används.



Figur 5: Confusion matrix för Multinomial Naive Bayes med meningsuppdelning på korta text-beskrivningar.


Figur 5 visar att meningsuppdelning förbättrar identifieringen av *renoveringen* markant där 68 av 79 observationer klassificeras nu korrekt jämfört med 58 utan uppdelning i figur 3. Däremot kvarstår svårigheterna med *området* och *andra bostadsrelaterade faktorer*, som fortsätter att klassificeras som *bostaden* eller *renoveringen*.

Tabell 8: Logistisk regression med L2-regularisering (Ridge) metod 3B

Kategori	Precision	Recall	F1
Andra bostadsrelaterade faktorer	100%	19%	32%
Bostaden	70%	87%	78%
Familjeskäl	77%	77%	77%
Området	20%	5%	8%
Renoveringen	71%	80%	75%
Vill bo på annat sätt	80%	49%	61%
Accuracy (genomsnitt)	72%		
Viktad F_1-mått	69%		


Tabell 8 visar att meningsuppdelning har försumbar effekt på logistisk regression. Accuracy sjun-

ker från 73% till 72%, och F_1 -värdena förändras lite för de flesta kategorier. Kategorin *vill bo på annat sätt* försämras från 67% i tabell 6 till 61%, medan *familjeskäl* förbättras marginellt från 75% i tabell 6 till 77% för deras F_1 -mått. Att Ridge är relativt opåverkad av meningsuppdelning är förenligt med att L2-regulariseringen stabiliserar modellen mot variationer i textrepresentationen, till skillnad från Multinomial Naive Bayes som gynnas mer av kortare textsegment. Det viktade F_1 -måttet på 69% visar att modellen har en stabil och övergripande god balans mellan precision och recall för meningsuppdelning på logistisk regression.



Figur 6: Confusion Matrix för Logistisk regression (Ridge) på Excel data, med meningsuppdelning.

Figur 6 visar ett liknande mönster som utan meningsuppdelning (Figur 4), vilket bekräftar att modellen är relativt okänslig för denna förändring. De vanligaste felklassificeringarna sker fortfarande mellan *bostaden* och *renoveringen*.



Figur 7: Jämförelse av viktad F_1 -värdena för samtliga modeller och datakonfigurationer. Blå staplar representerar Multinomial Naive Bayes och röda staplar representerar logistisk regression med L2-regularisering (Ridge). Ljusare färg indikerar körning med meningsuppdelning.

Figur 7 visar en sammanfattande översikt över viktad F_1 -värde för samtliga testade konfigurationer. Logistisk regression presterar genomgående bättre än Multinomial Naive Bayes, och korta texter ger högre viktad F_1 -värde än hela intervjuer för båda modellerna. Meningsuppdelning förbättrar bara prestandan på Multinomial Naive Bayes för korta texter men försämrar den på hela intervjuer.

5 Diskussion

5.1 Datakällans påverkan och modeljämförelse

Resultaten visar tydliga skillnader i klassificeringsprestanda beroende på datakälla. En genomgående observation är att både Multinomial Naive Bayes och logistisk regression med L2-regularisering presterar avsevärt bättre på korta textbeskrivningar än på hela intervjutexter. För hela intervjutexter uppnår Multinomial Naive Bayes ett viktad F_1 -värde på 37% (tabell 3) och logistisk regression 43% (tabell 4), medan motsvarande värden för korta texter är 61% respektive 71% (tabell 5 och 6).

Förbättringen på modellerna när det tränades på kortare textbeskrivningarna beror på att de specifika nyckelorden framträder tydligare. I figur 10 (i Appendix) ser vi att ordet **'större'** har en vikt på 2,27 för *bostaden*, vilket fungerar som ett kraftfullt signalord. I en kort text med färre irrelevanta inslag dominerar detta ord dokumentvektorn helt och ger tydligare signalordsfrekvenser i TF-IDF-representationen kopplade till respektive kategori, enligt ekvation (2). Däremot innehåller hela intervjuer ofta omfattande brus i form av intervjufrågor och sidospår, vilket sänker signal-brus-förhållandet och försvagar modellernas prediktiva förmåga.

Vid en direkt jämförelse mellan modellerna presterar Logistisk regression med L2-regularisering konsekvent bättre än Multinomial Naive Bayes i de genomförda experimenten, vilket syns tydligt i figur 7. Detta beror på Naive Bayes svaghet vid naturligt språk, där detta blir tydligt när man granskar dess toppord i figur 11 i Appendix. Modellen viktar ord som **'intressant'** och **'letat'** högt för *bostaden*, ord som ofta förekommer i kombination med andra termer. Eftersom

Naive Bayes behandlar dessa som helt oberoende särdrag missar den därmed den kontextuella information som den logistiska regressionen kan fånga upp genom att vikta sammanhängande termer, enligt ekvation (6). Dessutom bidrar L2-regulariseringen i ekvation (7) till att stabilisera modellen trots hög dimensionalitet. Skillnaden är tydligast för korta texter, där Ridge uppnår ett viktat F_1 -mått på 71% jämfört med Multinomial Naive Bayes 61% (tabell 6 och 5 respektive). Medan skillnaden är mindre för hela intervjuer, 43% mot 37% (tabell 4 och 3 respektive). Detta indikerar att logistisk regression med L2-regularisering mer precist kan väga de tydliga särdragen mot varandra när bruset är begränsat.

Ur ett teoretiskt perspektiv kan detta belysas genom avvägningen mellan varians och bias. Resultaten tyder på att den logistiska regressionen, som är en mer flexibel modell, lider av hög varians när den appliceras på hela intervjutexter på grund av det stora antalet särdrag i förhållande till antalet observationer. Multinomial Naive Bayes, som är en stelare modell med högre bias till följd av sitt strikta oberoendebegrepp, uppvisar däremot en mer stabil prestanda i förhållande till indatans brus. Detta illustrerar den statistiska principen att modeller med högre bias ofta kan överträffa mer komplexa modeller när antalet observationer är liten eller när signal-brus-förhållandet är lågt, då de är mindre benägna att överanpassas till specifika särdrag i bruset.

5.1.1 Meningsuppdelningens effekt

Meningsuppdelning ger blandade resultat för de två modellerna. För Multinomial Naive Bayes på korta texter förbättrades det viktade F_1 -mått från 61% till 66%, medan för hela intervjuer sjönk prestandan från 37% till 27%, enligt figur 7. Detta beror på att de långa intervjuerna innehåller mycket irrelevant information. I en hel text kan de viktiga orden tillsammans övervinna detta brus, men när texten delas upp blir de enskilda segmenten för svaga för att klassificeras korrekt. För de korta texterna är förhållandet det motsatta, där finns inget brus, och uppdelningen hjälper istället modellen att fokusera på de mest betydelsefulla orden. För logistisk regression är effekten av meningsuppdelning svagt negativt för det viktade F_1 -mått för båda datakällorna, enligt tabell 7. Till skillnad från Multinomial Naive Bayes, kan modellen under träningen lära sig att vissa ord ofta förekommer tillsammans i en viss kategori men vid meningsuppdelning delas orden upp, vilket medför att modellen går miste om den ackumulerade informationen från hela dokumentet för att göra en stabil prediktion.

I samtliga confusion matriser observerades även att flera intervjuer tenderar att överklassificera intervjuer till kategorin *bostaden*. Detta kan förklaras av klassobalans och statistisk bias eftersom det är den största kategorin i datamängden och när modellen möter osäkerhet i datan väljer den ofta majoritetsklassen (enligt tabell 1) för att maximera sannolikheten för en korrekt gissning, vilket skapar en bias i resultaten. Denna systematiska överklassificeringen av *bostaden* kan även förklaras av figur 10 och figur 11 i appendix att *bostaden* definieras av ord med extremt hög prediktiv kraft. Exempelvis har ordet *större* i den logistiska regressionen en vikt (2,27) som är mer än dubbelt så hög som nästföljande ord. Dessa högpotenta signalord fungerar som dominanta prediktorer som drar hela dokumentet mot kategorin *bostaden*, även om dokumentet i övrigt innehåller neutral text.

Vid meningsuppdelning uppstår dock ett omvänt fenomen där sårbarheten i denna viktfordelning blir tydlig. Eftersom *bostaden* förlitar sig på ett fåtal dominanta nyckelord, leder en fragmentering av texten till att dessa ord isoleras i enskilda segment. De resterande segmenten saknar då tillräcklig signalstyrka för att bibehålla klassificeringen och faller istället ofta in i kategorin *renoveringen*. Detta beror på att *renoveringen* har en mer jämn fördelning av karaktäristiska termer,

vilket gör att den lättare fångar upp neutrala eller fragmenterade segment när de dominanta nyckelorden för *bostaden* saknas.

5.2 Metodernas begränsningar

En central begränsning av projektet är den valda ansatsen om duplicering för att kunna hantera multilabel-klassificeringen. Genom att duplicera träningsdatan så att varje intervju förekommer en gång per kategori innebär det att träningsexemplen inte längre är oberoende av varandra, vilket är ett grundläggande antagande för många statistiska metoder. För Multinomial Naive Bayes påverkar detta direkt sannolikhetssuppskattningarna $P(\omega_i | c)$ i ekvation (3) och ordfrekvensparametrarna p_i i den multinomiala fördelningen i ekvation (4), eftersom modellen tränas upprepande gånger på samma ordmönster, vilket kan leda till att frekventa klasser överrepresenteras. Utöver detta gäller oberoendeantagandet sällan i naturligt språk, där ord ofta förekommer i beroende kontexter. Till exempel har ett dokument som innehåller ordet *renovering* högre sannolikhet att också innehålla ordet *hyresvärd*. Sammantaget innebär detta att Multinomial Naive Bayes lider av två separata problem i detta projekt där ord inte är oberoende av varandra inom ett dokument, och träningsexemplen är inte oberoende av varandra på grund av dupliceringen. Båda problemen tillsammans förklarar varför Multinomial Naive Bayes får lägre F1-värden än logistisk regression med L2-regularisering. Logistisk regression påverkas också av dupliceringen genom att intervjuer med flera kategorier får oproportionerligt stort inflytande på koefficienterna ω_c i ekvation (5), men gör inget oberoendeantagande och kan därmed bättre utnyttja mönster i datan.

En ytterligare begränsning är den lilla datamängden och den tydliga klassobalansen som visas i tabell 1. Modellen riskerar att favorisera de dominerande klasserna, vilket innebär att accuracy enligt ekvation (8) kan vara hög även när modellen i praktiken misslyckas med att identifiera underrepresenterade kategorier. Till exempel kan modellen som alltid predikterar *bostaden* skulle exempelvis uppnå relativt hög accuracy utan att ha lärt sig något om övriga kategorier. Därför används viktat F_1 -mått enligt ekvation (10) som primärt utvärderingsmått, vilket straffar obalans mellan precision och recall och ger en mer rättvisande bild av modellens faktiska klassificeringsförmåga. Korsvalidering minskar osäkerheten i utvärderingen men eliminerar inte denna begränsning.

I samband med samarbetet med byggnadsdesigngruppen har vi även identifierat en begränsning i annoteringen av vissa intervjuer inom *renoveringen*. I flera fall fungerar *renovering* som en utlösande faktor, medan den bakomliggande orsaken egentligen är något annat, exempelvis förändrade behov eller livssituation. Trots detta har intervjuerna märkts som *renoveringen* i facit eftersom detta anges explicit i materialet. Dupliceringen kan förstärka effekten av sådana tvetydiga etiketter i facit. Om en intervju har en etikett som inte helt speglar textens semantiska innehåll tränas modellen upprepade gånger på en potentiellt missvisande signal, vilket påverkar sannolikhetssuppskattningarna $P(\omega_i | c)$ i ekvation (3) och ordfrekvensparametrarna p_i i ekvation (4). Detta visar en generell begränsning i TF-IDF-representationen i ekvation (2) eftersom modellerna baseras på ordfrekvenser snarare än semantisk förståelse kan de inte skilja på om *renovering* används som primär orsak eller som utlösande faktor, vilket kan leda till systematiska felklassificeringar i gränsfall där flera tolkningar är möjliga.

5.3 Förbättringsförslag

Ett centralt förbättringsområde är att utöka datamängden. I den nuvarande studien baseras modellerna på ett begränsat antal intervjuer, vilket gör det svårt att lära sig stabila och generaliserbara mönster, särskilt för underrepresenterade kategorier. Detta återspeglas i att *området* och *andra bostadsrelaterade faktorer* konsekvent fick 0% i F1-mått enligt ekvation (9) i samtliga experiment. En annan möjlig förbättring är att använda mer avancerade metoder för multilabel-klassificering istället för den förenklade dupliceringsstrategin, vilket skulle ge en mer korrekt representation av problemets multilabel-karaktär och därmed en mer rättvisande modellträning.

När det gäller utvärdering skulle leave-one-out-korsvalidering (LOOCV) kunna vara ett alternativ vid små datamängder, eftersom varje observation då används både som träning och test, men till priset av högre beräkningskostnad. Det hade även varit möjligt att undersöka olika värden på regulariseringsparametern λ i ekvation (7), exempelvis med hjälp av korsvalidering, för att hitta en bättre balans mellan överanpassning och modellens generaliseringsförmåga.

Slutligen skulle mer avancerade modeller, exempelvis neurala nätverk, kunna undersökas. Dessa kan fänga mer komplexa språkliga mönster som oberoendeantagandet i ekvation (3) inte kan hantera, men kräver generellt större datamängder för att ge stabila resultat.

5.4 Slutsats

Resultaten visar att både Multinomial Naive Bayes och logistisk regression med L2-regularisering kan återskapa den manuella klassificeringen, men att överensstämmelsen är begränsad och varierar mellan olika kategorier. Modellerna presterar relativt väl för vissa tydliga kategorier, men har svårt att identifiera mer komplexa eller underrepresenterade klasser.

Valet av datakälla har en tydlig påverkan på modellens prestanda. Klassificering baserad på korta textbeskrivningar ger genomgående bättre resultat än klassificering av hela intervjutexter. Detta tyder på att modellen bättre kan fånga samband mellan ord och därmed hantera mer komplexa mönster i texten.

Den begränsade datamängden påverkar modellens stabilitet och tillförlitlighet negativt. Variationer i träningsdata får stor effekt på resultaten, och vissa kategorier saknar tillräckligt med exempel för att modellen ska kunna lära sig robusta mönster.

Vid jämförelse mellan modeller framgår att logistisk regression generellt presterar bättre, särskilt för kortare textbeskrivningar. Detta tyder på att regularisering bidrar till en mer stabil modell som bättre kan hantera både begränsad data och multilabel-problematik.

Sammanfattningsvis visar studien att automatisk textklassificering kan fungera som ett stöd vid analys av intervjubaserat material, men att metodens effektivitet är starkt beroende av datans kvalitet, storlek och struktur.

6 Källförteckning

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). *An Introduction to Statistical Learning: With Applications in R*. Springer, New York.

He, H., & Garcia, E. A. (2009). *Learning from imbalanced data*. IEEE Transactions on Knowledge and Data Engineering, 21(9), 1263–1284. <https://doi.org/10.1109/TKDE.2008.239>

Zhang, M.-L., & Zhou, Z.-H. (2014). *A review on multi-label learning algorithms*. IEEE Transactions on Knowledge and Data Engineering, 26(8), 1819–1837.

Leevy, J. L., Khoshgoftaar, T. M., Bauder, R. A., & Seliya, N. (2018). *A survey on addressing high-class imbalance in big data*. Journal of Big Data, 5(1), 1–30. <https://doi.org/10.1186/s40537-018-0151-6>

Jurafsky, D., & Martin, J. H. (2009). *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition* (2nd ed.). Pearson.

Trevor Hastie, Robert Tibshirani, Jerome Friedman. (2017). *The elements of statistical learning* (2nd ed.).


7 AI-användande

Under arbetet med detta projekt har AI assisterat med programmeringen av meningsuppdelning, tokenisering och duplicering vilket ingår i de slutliga modellerna som används. AI har också hjälpt med att textförbättra slutrapporten genom att korrigera grammatik och omformulera meningar för ökad läsbarhet utan att ändra det faktiska innehållet.

A Appendix

Tabell 9: Multinomial Naive Bayes metod 3A.


Kategori	Precision	Recall	F1
Andra bostadsrelaterade faktorer	0%	0%	0%
Bostaden	54%	31%	40%
Familjeskäl	0%	0%	0%
Området	0%	0%	0%
Renoveringen	29%	92%	44%
Vill bo på annat sätt	100%	4%	7%
Accuracy (genomsnitt)	35%		
Viktat F_1-mått	27%		



Figur 8: Confusion Matrix för Multinomial Naive Bayes på hel intervjutext, med meningsuppdelning.


Tabell 10: Logistisk regression med L2-regularisering (Ridge) metod 3A

Kategori	Precision	Recall	F1
Andra bostadsrelaterade faktorer	0%	0%	0%
Bostaden	56%	41%	48%
Familjeskäl	33%	2%	3%
Området	0%	0%	0%
Renoveringen	31%	91%	46%
Vill bo på annat sätt	100%	4%	7%
Accuracy (genomsnitt)	39%		
Viktat F_1-mått	32%		




Figur 9: Confusion Matrix för logistisk regression (Ridge) på hel intervjutext med meningsuppdelning.

Top 5 ord per kategori – Logistisk regression
Medelvärde över 5 folds (TF-IDF koefficient)




Figur 10: De fem mest signifikanta orden per kategori för logistisk regression baserat på medelvikt (TF-IDF-koefficienter). Diagrammen visar vilka termer som har störst prediktiv kraft för kategorisering av korta fritextsvar.

Top 5 ord per kategori — Naive Bayes
Medelvärde över 5 folds (x vanligare än genomsnittet)




Figur 11: De fem mest signifikanta orden per kategori för Multinomial Naive Bayes baserat på hur vanligt ordet är jämfört med genomsnittet. Diagrammen visar vilka termer som har störst prediktiv kraft för kategoriseringen av korta fritextsvar.



Figur 12: Stapeldiagram för de olika metoderna på hela intervjutext.

Figur 12 visar F1-score för de olika metoderna applicerade på hela intervjutexter, uppdelat per kategori.



Figur 13: Stapeldiagram för dem olika metoderna på korta texter.

Figur 13 visar F_1 -värdena för de olika metoderna applicerade på korta texter, uppdelat per kategori.

Källkod

Listing 1: Klassificeringskod i Python.

```
1
2
3
4
5
6
7
8
9
10
11
12
13
14
15
16
17
18
19
20
21
22
23
24
25
26
27
28
29
30
31
32
33
34
35
36
37
38
39
40
41
42
43
44
45
46
47
48
import os
import re
import numpy as np
import pandas as pd
from docx import Document
from collections import Counter
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.model_selection import StratifiedKFold
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.naive_bayes import MultinomialNB
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import classification_report, confusion_matrix,
    accuracy_score

DOCX_FOLDER = r"C:\Users\sofia\OneDrive\Dokument\Kandidatexamen\Alla
    intervjuer"
FACIT_FOLDER = r"C:\Users\sofia\OneDrive\Dokument\Kandidatexamen\Facit
    Kategorier"
EXCEL_FILE =
    r"C:\Users\sofia\OneDrive\Dokument\Kandidatexamen\Masterfil_230628_energi.xlsx"

HUVUDKATEGORIER = [
    "andra bostadsrelaterade faktorer",
    "bostaden",
    "familjeskäl",
    "området",
    "renoveringen",
    "vill bo på annat sätt",
]

#TEXTBEHANDLING (Kombinerad
    logik)-----
def rensa_text(text, stemming=False):
    if pd.isna(text) or text == "":
        return ""

    text = text.lower()
    text = re.sub(r'[^w\sääöÄÅÖ]', ' ', text)

    tokens = text.split()
    cleaned_tokens = []

    for t in tokens:
        # Filter: Inga rena siffror och ord måste vara minst 2 tecken
        if t.isdigit() or len(t) < 2:
            continue
        if t.isdigit():
            continue
        if not any(v in t for v in 'aeiouyääö'):
```

```

49         continue
50         cleaned_tokens.append(t)
51
52     return " ".join(cleaned_tokens)
53
54
55 # DATAFUNKTIONER (Inläsning &
    Struktur)-----
56 def läs_docx(sökväg):
57     doc = Document(sökväg)
58     return "\n".join(p.text for p in doc.paragraphs)
59
60 def läs_data(excel_path, facit_folder):
61     # Läs Excel
62     df = pd.read_excel(excel_path, sheet_name="Rådata", usecols=["intervju",
        "orsak"])
63     df = df.dropna(subset=["orsak"]).iloc[2:-15]
64     df["intervju"] = df["intervju"].astype(str).str.extract(r"(P\d{3})")
65     df = df.dropna(subset=["intervju"]).rename(columns={"orsak": "text"})
66
67     # Läs Facit
68     records = []
69     for fil in os.listdir(facit_folder):
70         if fil.endswith(".docx"):
71             kat = os.path.splitext(fil)[0].lower().strip()
72             if kat in HUVUDKATEGORIER:
73                 text = läs_docx(os.path.join(facit_folder, fil))
74                 ids = re.findall(r"P\d{3}", text.upper())
75                 for pid in ids:
76                     records.append({"intervju": pid, "kategori": kat})
77
78     return df, pd.DataFrame(records)
79
80
81 def läs_alla_intervjuer(mapp):
82
83     poster = []
84     for fil in os.listdir(mapp):
85         if fil.endswith(".docx"):
86             text = läs_docx(os.path.join(mapp, fil))
87             intervju_id = re.search(r"(P\d{3})", fil)
88             if intervju_id:
89                 poster.append({
90                     "intervju": intervju_id.group(1),
91                     "text": text
92                 })
93     return pd.DataFrame(poster)
94
95 def läs_excel_och_facit(excel_path, facit_folder):
96     # Excel
97     df = pd.read_excel(excel_path, sheet_name="Rådata", usecols=["intervju",
        "orsak"])
98     df = df.dropna(subset=["orsak"]).iloc[2:-15]
99     df["intervju"] = df["intervju"].astype(str).str.extract(r"(P\d{3})")
100    df = df.dropna(subset=["intervju"]).rename(columns={"orsak": "text"})
101
102    # Facit
103    records = []
104    for fil in os.listdir(facit_folder):
105        if fil.endswith(".docx"):
106            kat = os.path.splitext(fil)[0].lower().strip()
107            if kat in HUVUDKATEGORIER:

```

```

108         text = läs_docx(os.path.join(facit_folder, fil))
109         ids = re.findall(r"P\d{3}", text.upper())
110         for pid in ids:
111             records.append({"intervju": pid, "kategori": kat})
112
113     return df, pd.DataFrame(records)
114
115
116 # Confusion Matrix plot & histogram-----
117 def plot_confusion_matrix(y_true, y_pred, classes, title):
118     cm = confusion_matrix(y_true, y_pred, labels=classes)
119     plt.figure(figsize=(10, 8))
120     sns.heatmap(cm, annot=True, fmt='d', cmap='Blues',
121                 xticklabels=classes, yticklabels=classes)
122     plt.title(title)
123     plt.ylabel('Verklig kategori')
124     plt.xlabel('AI:ns gissning')
125     plt.xticks(rotation=45, ha='right')
126     plt.tight_layout()
127     plt.show()
128
129 # K-FOLD MOTORN-----
130
131 def kör_kandidat_analys(df_text, df_facit, modell_typ="NB", k=5):
132
133     print(f"\n{'='*60}\nKÖRNING: {modell_typ} med {k} folds\n{'='*60}")
134
135     kategori_map = df_facit.groupby("intervju")["kategori"].apply(list).to_dict()
136     alla_kat = sorted(df_facit["kategori"].unique())
137     kat_frekvens = df_facit["kategori"].value_counts().to_dict()
138
139     def get_prim_kat(iid):
140         kats = kategori_map.get(iid, [])
141         return max(kats, key=lambda k: kat_frekvens.get(k, 0)) if kats else None
142
143     unika_ids = np.array([i for i in df_text["intervju"].unique() if
144                          get_prim_kat(i)])
145     strat_labels = np.array([get_prim_kat(i) for i in unika_ids])
146
147     skf = StratifiedKFold(n_splits=k, shuffle=True, random_state=42)
148
149     for stemming in [False]:
150         all_true, all_pred = [], []
151
152         for fold, (train_idx, test_idx) in enumerate(skf.split(unika_ids,
153                                                                strat_labels)):
154             #Split baserat på unika ID:n
155             ids_train, ids_test = unika_ids[train_idx], unika_ids[test_idx]
156
157             #Skapa träningsmängd (hanterar flera kategorier per person)
158             df_train =
159                 df_text[df_text["intervju"].isin(ids_train)].merge(df_facit,
160                                                                    on="intervju")
161             df_test = df_text[df_text["intervju"].isin(ids_test)].copy()
162
163             #Vektorisering
164             df_train["proc"] = df_train["text"].apply(lambda x: rensa_text(x,
165                                                                    stemming))
166             df_test["proc"] = df_test["text"].apply(lambda x: rensa_text(x,
167                                                                    stemming))

```

```

164 vec = TfidfVectorizer(max_features=2000)
165 X_train = vec.fit_transform(df_train["proc"])
166 X_test = vec.transform(df_test["proc"])
167
168 #Modellval
169 if modell_typ == "NB":
170     model = MultinomialNB()
171 elif modell_typ == "Ridge":
172     model = LogisticRegression(penalty="l2", max_iter=1000)
173 model.fit(X_train, df_train["kategori"])
174
175 if modell_typ == "Ridge":
176     feature_names = vec.get_feature_names_out()
177
178     # Skapa en dictionary för att lagra aggregerade vikter om du
179     # vill snitta senare,
180     # eller skriv ut för den aktuella folden här:
181     print(f"\n--- Topporde Fold {fold+1} ---")
182     for i, kategori in enumerate(model.classes_):
183         # Hämta koefficienterna för just denna klass (för
184         # Ridge/LogReg)
185         # Vid binär klassificering är coef_ ofta (1, n_features),
186         # vid multiclass är den (n_classes, n_features)
187         if len(model.classes_) <= 2:
188             # LogReg med 2 klasser har bara en rad koefficienter
189             current_coefs = model.coef_[0] if i == 1 else
190             -model.coefs[0]
191         else:
192             current_coefs = model.coef_[i]
193
194             top_indices = np.argsort(current_coefs)[-10:]
195             words = [f"{feature_names[idx]} ({current_coefs[idx]:.2f})"
196                     for idx in reversed(top_indices)]
197             print(f"[{kategori}]: {'', '.join(words)}")
198             # ... inne i fold-loopen efter model.fit()
199
200 elif modell_typ == "NB":
201     feature_names = vec.get_feature_names_out()
202     # Log-sannolikheter
203     log_probs = model.feature_log_prob_
204
205     # Beräkna genomsnittlig log-sannolikheter för ALLA andra klasser
206     # Detta hjälper oss hitta vad som utmärker just denna klass
207     avg_log_prob_others = np.mean(log_probs, axis=0)
208
209     print(f"\n--- Mest särskiljande ord Fold {fold+1} (Naive Bayes)
210     ---")
211     for i, kategori in enumerate(model.classes_):
212         # Vi räknar ut differ: Hur mycket mer sannolikt är ordet här
213         # än i snitt?
214         # I log-världen är subtraktion samma sak som division i
215         # vanliga tal
216         diff = log_probs[i] - avg_log_prob_others
217
218         top10_idx = np.argsort(diff)[-10:]
219
220         # np.exp(diff) visar "Ratio", t.ex. 2.5 betyder "2.5 ggr
221         # vanligare här"
222         words = [f"{feature_names[idx]} ({np.exp(diff[idx]):.1f})x
223                 vanligare)"
224                 for idx in reversed(top10_idx)]
225         print(f"[{kategori}]: {'', '.join(words)}")

```

```

217 # 5. Utvärdering per person (Majoritetsröstning)
218 df_test["pred"] = model.predict(X_test)
219 for iid in ids_test:
220     intervju_rader = df_test[df_test["intervju"] == iid] #för 10
221     missat_intevju
222     preds = df_test[df_test["intervju"] == iid]["pred"].tolist()
223     if not preds: continue
224
225     vinnare = Counter(preds).most_common(1)[0][0]
226     facit_kats = kategori_map.get(iid, [])
227
228     # Spara missar för Renovering
229     if "Renoveringen" in facit_kats and vinnare !=
230         "RenoRenoveringenvering":
231         renovering_missar.append({
232             "id": iid,
233             "ai_trodde": vinnare,
234             "röster": Counter(preds),
235             "text": intervju_rader["text"].iloc[0][:250]
236         })
237
238     # Spara för slutrapport (använder gruppens metodik)
239     all_pred.append(vinnare)
240     all_true.append(vinnare if vinnare in facit_kats else
241         facit_kats[0])
242
243     print(f"\n{'!'*20} 10 RENOVERINGSMISSAR {'!'*20}")
244     for i, m in enumerate(renovering_missar[:10]):
245         print(f"\n{i+1}. ID: {m['id']} | AI GISSADE: {m['ai_trodde']}")
246         print(f"    Röstfördelning: {dict(m['röster'])}")
247         print(f"    Text: \"{m['text']}...\"")
248
249     print(f"\nRESULTAT: {modell_typ}")
250     print(classification_report(all_true, all_pred, labels=alla_kat,
251         zero_division=0))
252     plot_confusion_matrix(all_true, all_pred, alla_kat, f"{modell_typ}")
253
254 %%EXEKVERING-----
255
256 if __name__ == "__main__":
257     df_docx_raw = läs_alla_intervjuer(DOCX_FOLDER)
258     df_excel_raw, df_facit = läs_data(EXCEL_FILE, FACIT_FOLDER)
259
260     print("\n" + "="*40 + "\nDEL A: ANALYS AV HELA INTERVJUER (DOCX)\n" + "="*40)
261     kör_kandidat_analys(df_docx_raw, df_facit, modell_typ="NB")
262     kör_kandidat_analys(df_docx_raw, df_facit, modell_typ="Ridge")
263
264     print("\n" + "="*40 + "\nDEL B: ANALYS AV korta texter (EXCEL)\n" + "="*40)
265     kör_kandidat_analys(df_excel_raw, df_facit, modell_typ="NB")
266     kör_kandidat_analys(df_excel_raw, df_facit, modell_typ="Ridge")
267
268 %% Meningsuppdatering
269 def dela_i_segment(text, metod="meningar"):
270
271     if pd.isna(text) or text == "":
272         return []
273     if metod == "meningar":

```

```

274         return [m.strip() for m in re.split(r'[.!?]', text) if m.strip()] #för
           DOCX (delar på . ! ?)
275     else:
276         return [f.strip() for f in text.split(',') if f.strip()] #metod="fraser"
           för Excel (delar på kommatecken)
277
278 def kör_kandidat_analys_segmenterad(df_text, df_facit, modell_typ="NB",
           segment_metod="meningar", k=5):
279
280     print(f"\n{'='*60}\nSEGMENTERAD ANALYS ({segment_metod}):
           {modell_typ}\n{'='*60}")
281
282     kategori_map = df_facit.groupby("intervju")["kategori"].apply(list).to_dict()
283     alla_kat = sorted(df_facit["kategori"].unique())
284     kat_frekvens = df_facit["kategori"].value_counts().to_dict()
285
286     def get_prim_kat(iid):
287         kats = kategori_map.get(iid, [])
288         return max(kats, key=lambda k: kat_frekvens.get(k, 0)) if kats else None
289
290     unika_ids = np.array([i for i in df_text["intervju"].unique() if
           get_prim_kat(i)])
291     strat_labels = np.array([get_prim_kat(i) for i in unika_ids])
292     skf = StratifiedKFold(n_splits=k, shuffle=True, random_state=42)
293
294     for stemming in [False]:
295         all_true, all_pred = [], []
296
297         for train_idx, test_idx in skf.split(unika_ids, strat_labels):
298             ids_train, ids_test = unika_ids[train_idx], unika_ids[test_idx]
299
300             #Skapa folds
301             df_train_raw =
                 df_text[df_text["intervju"].isin(ids_train)].merge(df_facit,
                 on="intervju")
302             df_test_raw = df_text[df_text["intervju"].isin(ids_test)].copy()
303
304             #SEGMENTERING (Expansion) Vi gör om varje rad till flera rader (en
                 per mening)
305             train_rows = []
306             for _, rad in df_train_raw.iterrows():
307                 for seg in dela_i_segment(rad["text"], segment_metod):
308                     train_rows.append({"text": seg, "kategori": rad["kategori"]})
309             df_train = pd.DataFrame(train_rows)
310
311             test_rows = []
312             for _, rad in df_test_raw.iterrows():
313                 for seg in dela_i_segment(rad["text"], segment_metod):
314                     test_rows.append({"intervju": rad["intervju"], "text": seg})
315             df_test = pd.DataFrame(test_rows)
316
317             #Processa och Vektorisera
318             df_train["proc"] = df_train["text"].apply(lambda x: rensa_text(x,
                 stemming))
319             df_test["proc"] = df_test["text"].apply(lambda x: rensa_text(x,
                 stemming))
320
321             vec = TfidfVectorizer(max_features=2000)
322             X_train = vec.fit_transform(df_train["proc"])
323             X_test = vec.transform(df_test["proc"])
324
325             #Modell

```

```

326         if modell_typ == "NB":
327             model = MultinomialNB()
328         else:
329             model = LogisticRegression(penalty="l2", max_iter=1000)
330
331         model.fit(X_train, df_train["kategori"])
332
333         #Predicera och RÖSTA per person
334         df_test["pred"] = model.predict(X_test)
335         for iid in ids_test:
336             person_preds = df_test[df_test["intervju"] ==
337                                   iid]["pred"].tolist()
338             if not person_preds: continue
339
340             vinnare = Counter(person_preds).most_common(1)[0][0]
341             facit_kats = kategori_map.get(iid, [])
342
343             all_pred.append(vinnare)
344             all_true.append(vinnare if vinnare in facit_kats else
345                             facit_kats[0])
346
347         print(f"\nRESULTAT (Segmentering {segment_metod}):")
348         print(classification_report(all_true, all_pred, labels=alla_kat,
349                                     zero_division=0))
350         plot_confusion_matrix(all_true, all_pred, alla_kat, f"{modell_typ}")
351
352     """
353     if __name__ == "__main__":
354         df_docx_raw = läs_alla_intervjuer(DOCX_FOLDER)
355         df_excel_raw, df_facit = läs_data(EXCEL_FILE, FACIT_FOLDER)
356
357         kör_kandidat_analys_segmenterad(df_excel_raw, df_facit, modell_typ="Ridge",
358                                         segment_metod="fraser")
359
360         kör_kandidat_analys_segmenterad(df_docx_raw, df_facit, modell_typ="Ridge",
361                                         segment_metod="meningar")
362
363         kör_kandidat_analys_segmenterad(df_docx_raw, df_facit, modell_typ="NB",
364                                         segment_metod="meningar")
365
366     """
367     """ Histogram Plot
368
369     #Full intervju text
370     nb_f1 = [0, 64, 0, 0, 35, 0] # NB (full text)
371     logreg_f1 = [0, 66, 16, 0, 52, 18] # Logistisk regression (Ridge)
372     nb_sentence_f1 = [0, 40, 0, 0, 44, 7] # NB + meningsuppdelning
373     lr_sentence_f1 = [0, 48, 3, 0, 46, 7] # Meningsuppdelning + LR
374
375     x = np.arange(len(HUVUDKATEGORIER))
376     width = 0.2
377
378     # Plot
379     plt.figure()
380     plt.bar(x - 1.5*width, nb_f1, width, label="NB", color="blue")
381     plt.bar(x - 0.5*width, logreg_f1, width, label="LR", color="orange")
382     plt.bar(x + 0.5*width, nb_sentence_f1, width, label="NB + meningsuppdelning",
383             color="gray")
384     plt.bar(x + 1.5*width, lr_sentence_f1, width, label="LR + meningsuppdelning",
385             color="green")

```

```

380 plt.xlabel("Kategori")
381 plt.ylabel("F1-score (%)")
382 plt.title("F1-score per kategori (Hel intervjutext)")
383 plt.xticks(x, HUVUDKATEGORIER, rotation=45, ha="right")
384 plt.ylim(0, 100)
385
386 plt.legend(loc="upper center", bbox_to_anchor=(0.5, -0.6), ncol=2)
387 plt.subplots_adjust(bottom=0.35)
388
389 plt.show()
390
391
392 """ Histogram plot
393
394 #Excell
395 # F1-scores
396 nb_f1 = [0, 73, 74, 0, 70, 18] # Multinomial Naive Bayes
397 logreg_f1 = [20, 78, 75, 22, 78, 67] # Logistisk regression (Ridge)
398 nb_sentence_f1 = [0, 76, 75, 0, 75, 49] # Meningsuppdelning + NB
399 lr_sentence_f1 = [32, 78, 77, 8, 75, 61] #Meningsuppdelning + LR
400
401 # Positioner
402 x = np.arange(len(HUVUDKATEGORIER))
403 width = 0.2
404
405 # Plot
406 plt.figure()
407 plt.bar(x - 1.5*width, nb_f1, width, label="NB", color="blue")
408 plt.bar(x - 0.5*width, logreg_f1, width, label="LR", color="orange")
409 plt.bar(x + 0.5*width, nb_sentence_f1, width, label="NB + meningsuppdelning",
410        color="gray")
411 plt.bar(x + 1.5*width, lr_sentence_f1, width, label="LR + meningsuppdelning",
412        color="green")
413
414 plt.xlabel("Kategori")
415 plt.ylabel("F1-score (%)")
416 plt.title("F1-score per kategori (korta texter)")
417 plt.xticks(x, HUVUDKATEGORIER, rotation=45, ha="right")
418 plt.ylim(0, 100)
419
420 plt.legend(loc="upper center", bbox_to_anchor=(0.5, -0.6), ncol=2)
421 plt.subplots_adjust(bottom=0.35)
422
423 plt.show()

```