



Simulering samt prognostisering av temperatur-tidsserier

Simulation and prediction of temperature time series

Kandidatarbete inom civilingenjörsutbildningen vid Chalmers

Nils Brakander
Alexander Ekstedt
Karl Lundberg
Gustav Stålbarm

Simulering samt prognostisering av temperaturtids-serier

Kandidatarbete i matematik inom civilingenjörsprogrammet Kemiteknik med fysik vid Chalmers

Nils Brakander Alexander Ekstedt Karl Lundberg Gustav Stålarin

Handledare: Annika Lang Matematiska vetenskaper

Institutionen för Matematiska vetenskaper
CHALMERS TEKNISKA HÖGSKOLA
GÖTEBORGS UNIVERSITET
Göteborg, Sverige 2026

Förord

Arbetet i gruppen har fungerat väl under våren och vi är alla glada för både det vi åstadkommit och det vi lärt oss. En dagbok har förts vid sidan om arbetet där det framgått hur mycket gruppen jobbat och vad som varit de olika fokusområdena för olika personer. Nedan presenteras även en tabell som visar vilka personer som främst bidragit till olika delar på rapporten. Det skall här sägas att gränsen för vem som bidrag främst till någon del är grov och generellt har alla deltagit till stor grad på de flesta avsnitten. Vi vill även tacka vår handledare Annika Lang för mycket god handledning och stöttning under arbetets gång.

Område	Ansvarig/Ansvariga
Sammandrag	Gustav, Nils
Inledning	Gustav
Bakgrund	Alexander, Karl
Datainsamling och datahantering	Karl
Modell - Markovmodeller	Karl, Gustav, Nils
Modell - AR-modeller	Alexander, Nils
Resultat & Diskussion - Endagarsprognos	Alexander, Karl
Resultat & Diskussion - Karakteristik och fördelning	Gustav, Karl
Slutsats	Gustav
Samhälleliga och etiska aspekter	Alexander
Referenshantering	Nils
Poster	Nils
Kodning	Alla
Korrekturläsning	Alla

Sammandrag

I detta arbete byggs två matematiska modeller för att försöka förutspå morgondagens temperatur samt efterlikna karakteristiken hos verklig temperaturdata i syfte att kunna simulera fiktiva år. Modellerna som jämförs är AR-modeller och en modell baserad på Markovkedjor. Temperaturdata kännetecknas av en kombination av cykliska årstidsmönster och oförutsägbara stokastiska variationer och modelleras därför som en tidsserie. För att modellera tidsserien, bestående av dygnsmedeltemperatur från en väderstation i Malmö, transformeras modellernas träningsdata till en tidsserie med stationära egenskaper. Resultatet visar att vid jämförelse av medelfelet för endagarsprognoser presterade samtliga modeller likvärdigt inom intervallet 1.41–1.47 °C, med en marginell fördel för de autoregressiva modellerna. Både AR- och Markovmodellen visar att dagens temperatur har ett starkt beroende av gårdagens. För just AR-modellen framgår det även att hänsynstagande till fler variabler som vindförhållanden och lufttryck förbättrar resultatet något. Tillgång till temperaturdata äldre än en dag har en högst marginell inverkan på modellens utfall. Karakteristiken och fördelningen för den simulerade datan visar att Markovmodellen ger en bättre representation av utvärderingsdatan då samma skevhet i fördelningskurvan påvisas, medan AR-modellen ger en nästan perfekt normalfördelning av datan. Sammanfattningsvis konstateras att AR-modellerna lämpar sig bäst för dagsprognoser, medan Markovmodellen är att föredra om man vill bibehålla verklighetsförankrad temperaturfördelning vid simulering.

Abstract

In this project, two mathematical models are constructed with the intention of making day-to-day predictions of temperature, as well as being able to capture the characteristic of the same real temperature data with the aim to simulate fictive years. The models being compared are auto regressive AR models and one model based on Markov chains. Temperature data is characterised by a combination of cyclic seasonal patterns and unpredictable stochastic variations, and is therefore modeled as a time series. To model the time series, containing daily mean temperature data from a weather station in Malmö, the training data is transformed to a time series with stationary properties. The results show that by comparing the mean absolute error for day-to-day predictions, all models perform equivalent in the span 1.41–1.47 °C, where the autoregressive models perform slightly better. Both the AR- and Markov models display that the temperature of today depends greatly on the temperature yesterday. For the AR model specifically, it is evident that the consideration of more variables such as wind conditions and air pressure, marginally improve the results. Taking more than one day ago into account has a highly marginal effect on the outcome of the model. The characteristic and distribution of the simulated data show that the Markov model better represents the evaluation data than the AR model, as the skewed nature of the data is better represented by the Markov model while the AR model returns an almost perfect normal distribution. In conclusion, the AR models are better suited for day-to-day predictions, whilst the Markov model is preferred if one wants to retain a realistic distribution when simulating temperature data.

Innehåll

1	Inledning	1
2	Bakgrund	2
3	Datainsamling och datahantering	5
3.1	Transformation av data	5
3.2	Utvärderingsmetodik	5
4	Modeller	6
4.1	Markovmodell	6
4.1.1	Tillämpning av Markovmodellen	7
4.1.2	Simulering och prognos	8
4.2	AR-modeller	9
4.2.1	Skattning	10
5	Resultat & Diskussion	13
5.1	Endagarsprognos	13
5.2	Karakteristik och fördelning	14
6	Slutsats	17
7	Samhälleliga och etiska perspektiv	18
A	Appendix	i
A.1	Användning av AI	i
A.2	Rådata	i
A.3	Källkod	i

1 Inledning

Människan har länge drivits av en vilja att förutspå morgondagen, och historiskt sett har få fenomen varit lika avgörande att kunna förutse som vädret. Att få ett svar på när nästa torka, värmebölja eller storm ska inträffa har varit livsavgörande i många situationer. Men i praktiken har det visat sig vara svårare än man kan tro att kunna förutsäga vädret. Detta beror på att väder är ett tydligt exempel på ett system vars data kännetecknas av en kombination av slumpmässiga variationer och återkommande mönster och trender, där de förutsägbara delarna som säsongsberoende och trender samspelar med oregelbundna stokastiska förändringar. Att förstå, beskriva och förutsäga den sortens system är svårt, men kan hanteras genom att använda matematiska modeller, som har egenskapen att kunna kombinera både de förutsägbara och de slumpartade komponenterna.

Dagens väderprognoser görs med hjälp av superdatorer, som tar in stora mängder data som sedan används för att modellera fysiken i atmosfären. I detta projekt tar vi ett steg bakåt och undersöker hur bra man kan modellera och förutspå temperatur, enbart utifrån den historiska data som finns tillgänglig. Två olika sorters modeller har studerats: en modell baserad på Markovkedjor och en autoregressiv modell med olika påbyggnader.

Markovmodellen som har utvecklats är inspirerad av Eberle et al. [5] som använder sig av bland annat en Markovmodell för modellering av vågor vid en vindkraftspark. Dessa typer av modeller kan även användas för att modellera nederbörd likt Stoner & Economou [11], där de använder en HMM (Hidden Markov Model) och MCMC (Markov Chain Monte Carlo) för att modellera regn på en timbasis. Metoden avser att fånga de huvudsakliga karakteristiska dragen hos regn. Det tas även i åtanke långa perioder av torka samt extrema mängder nederbörd, båda starkt beroende av säsong. Då kandidatarbetet även ämnar att fånga karakteristika hos temperaturdata över tid kan det anses rimligt utifrån Stoner & Economou att använda sig av liknande modeller såsom simulering av en första ordningens Markovmodell för att erhålla fördelningen av datan.

Utöver Markovmodeller är autoregressiva modeller ett kraftfullt verktyg för analys av tidsserier. Metodiken för de autoregressiva modellerna bygger på metoderna som beskrivs av Shumway et al [8], där man utnyttjar antagandet att framtida scenarier kan beskrivas som en linjärkombination av tidigare observationer.

Detta arbete riktar fokus mot hur relativt enkla modeller kan användas för att snabbt utfärda prognoser eller simulera scenarier. Medan tidigare studier med framgång använt sig av Markovbaserade eller autoregressiva modeller saknas en direkt jämförelse av modellerna, vilket gör det intressant att jämföra modellernas prestanda i kortsiktig prediktionsförmåga samt förmåga att göra långsiktiga simuleringar. Genomgående i denna rapport används termen simulering för att beskriva skapandet av långa tidsserier där fördelningen utvärderas, medan termerna prognos och prediktion avser en skattning av temperaturen en dag framåt.

Arbetets syfte är att bygga och utvärdera de två ovan nämnda modelltyperna, där den autoregressiva modellen innefattar flera varianter: AR, ARMA och ARMAX. Detta för att förstå deras olikheter och studera hur väl de lyckas modellera temperatur utifrån olika aspekter. Modellerna kommer att utvärderas i deras prediktions säkerhet för att utfärda prognoser av dygnsmedeltemperaturen en dag framåt. Dessutom kommer Markovmodellen och AR-modellen jämföras i hur väl de fångar karaktäristiken hos temperaturdata genom simuleringar. Målet är därmed att öka förståelsen för de implementerade modellerna, samt ge inblick i hur dessa kan utvärderas på ett korrekt vis.

I följande rapport introduceras först bakgrund och teori, för att sedan övergå till hur data hanteras i arbetet. Sedan presenteras de olika modellerna, följt av resultat, diskussion och slutsatser som dras. Arbetet inkluderar även en analys angående samhälleliga och etiska perspektiv. I appendix hittas ett stycke om hur AI har används i arbetet. Här finns också bifogad källkod och länkar till rådatan som används.

2 Bakgrund

Detta avsnitt presenterar först nödvändig bakgrund om stokastiska processer samt tidsserier och följs sedan av några definitioner av statistiska verktyg som studien utnyttjar.

För att förstå tidsserier uppkomna ur stokastiska processer behöver först en slumpvariabel definieras, för att sedan definiera en stokastisk process. En slumpvariabel X definieras på följande sätt enligt Gut [6]:

Definition 2.1. Låt $(\Omega, \mathbb{F}, \mathbb{P})$ vara ett sannolikhetsrum. En slumpvariabel $X : \Omega \rightarrow \mathbb{R}$ är en mätbar funktion från utfallsrummet Ω till $\mathbb{R}$.


En stokastisk process kan då definieras på följande vis enligt Brockwell & Davis [3]:

Definition 2.2. En stokastisk process är en familj av slumpvariabler $(X_t, t \in T)$ där T är processens tidsmängd.

Ofta är processens tidsmängd kontinuerlig men vi modellerar den diskret på grund av att mätning av en viss process oftast görs diskret. Utfallen av en mätning på X_t är en realisering av processen och definieras på följande vis:

Definition 2.3. För $\omega \in \Omega$, kallas $x_t = X_t(\omega)$ för en realisering av slumpvariabeln X_t vid tidpunkten $t \in T$. Följden $(x_t, t \in T)$ är alltså en realisering av den stokastiska processen $(X_t, t \in T)$.

Tillhandahållna data är därför realiseringen av själva processen och blir en följd av siffror som kallas för en tidsserie. Vidare kommer dock både processen och dess realisation betecknas som tidsserien X_t , med klarifikation vid behov. Den konventionella metoden för visualisering av en tidsserie är med de realiserade värdena längs den lodräta axeln i ett 2D-grafsystem och motsvarande tidsindex längs den vågräta. Ett exempel på en tidsserie visas i figur 1.



Figur 1: Exempel på hur en tidsserie kan se ut, innehållande medeltemperatur för varje dygn vid stationen Malmö A i januari 2023.

En tidsserie bryts ofta ned till att bestå av tre olika delar. En trend, ett säsongsberoende och en stokastisk komponent [3]. Målet med en sådan uppställning är att extrahera trenden och säsongen, som antas vara förutsägbara, för att sedan modellera den stokastiska komponenten.

För analys av en viss tidsserie är autokovariansfunktionen ett användbart verktyg, till stor del för att avgöra stationaritet hos ett dataset. De båda definieras som följande i enlighet med Brockwell & Davis [3].

Definition 2.4 (Autokovariansfunktionen). Låt $\mathbb{E}[X]$ notera väntevärdet av X och $(X_t, t \in T)$ vara en stokastisk process enligt definition 2.2, sådan att $\text{Var}(X_t) < \infty$ för varje $t \in T$. Då definieras autokovariansfunktionen $\gamma_X(\cdot, \cdot)$ för $(X_t, t \in T)$ som

$$\gamma_X(r, s) = \text{Cov}(X_r, X_s) = \mathbb{E}[(X_r - \mathbb{E}[X_r])(X_s - \mathbb{E}[X_s])], \quad r, s \in T. \quad (1)$$

Definition 2.5 (Svag stationaritet). Tidsserien $(X_t, t \in \mathbb{Z})$, där $\mathbb{Z}$ innefattar alla heltal, är svagt stationär om den uppfyller följande villkor:

1. $\mathbb{E}[X_t^2] < \infty$ för alla $t \in \mathbb{Z}$,
2. $\mathbb{E}[X_t] = m$ för alla $t \in \mathbb{Z}$,
3. $\text{Cov}(X_s, X_r) = \gamma_X(r, s) = \gamma_X(r + t, s + t)$ för alla $r, s, t \in \mathbb{Z}$.

Definition 2.5 medför att väntevärdet är konstant och ändligt för alla tidssteg, samt att autokovariansen vid tid r och s är konstant med avseende på t . Det implicerar att beroendet mellan två observationer X_t och X_{t+h} endast är en funktion av deras tidsmässiga avstånd h och inte av den absoluta tiden t .

För analys av tidsserier är det fördelaktigt om dessa är stationära [3]. Verkliga observerade tidsserier är vanligtvis icke-stationära. I många fall kan sådana dataset transformeras till serier med stationära egenskaper. Eberle et al. [5] använder sig av en Z-score-transformation (standardisering) för att transformera ett stokastiskt dataset till en i stort sett stationär tidsserie, där transformationen eliminerar trenden och säsongsbeteendet. Z-score Z_t beskriver hur ovanlig en datapunkt är genom att subtrahera ett rörligt medelvärde $\mu_{\text{moving},t}$ från respektive datapunkt X_t och sedan dividera med en rörlig standardavvikelse $\sigma_{\text{moving},t}$ enligt Brockwell & Davis [3]

$$Z_t = \frac{X_t - \mu_{\text{moving},t}}{\sigma_{\text{moving},t}}. \quad (2)$$

I fallet av en temperaturtidsserie X_t , låt N beteckna antalet år hos datan och t dag på året, sådant att $X_{1,5}$ motsvarar temperaturen första januari det femte året hos den tillgängliga datan. Då definieras $\mu_{\text{moving},t}$ och $\sigma_{\text{moving},t}$ enligt

$$\mu_t = \frac{1}{N} \sum_{n=1}^N X_{t,n}, \quad (3)$$

$$\mu_{\text{moving},t} = \frac{1}{2k+1} \sum_{i=-k}^k \mu_{t'_i}, \quad (4)$$


$$\sigma_t = \sqrt{\frac{1}{N-1} \sum_{n=1}^N (X_{t,n} - \mu_t)^2}, \quad (5)$$

$$\sigma_{\text{moving},t} = \frac{1}{2k+1} \sum_{i=-k}^k \sigma_{t'_i}, \quad (6)$$

där $t'_i = ((t + i - 1) \bmod 365) + 1$ med mod365 för att hantera årscykeln, det vill säga att datapunkt 366 motsvarar 1 januari. Variabeln k betecknar antalet tidssteg innan samt efter den aktuella observationen X_t som det rörliga medelvärdet $\mu_{\text{moving},t}$ respektive den rörliga standardavvikelsen $\sigma_{\text{moving},t}$ är beräknade ifrån. Det rörliga medelvärdet och den rörliga standardavvikelsen

väljs beroende på uppställning, men har hos Eberle et al. [5] ställts upp som ett 30-dagars ($k = 15$) glidande medelvärde. Medelvärdet μ_t beskriver det datumspecifika medelvärdet, vilket definieras som genomsnittet av alla utfall för varje specifik kalenderdag över samtliga år i datasetet. Den datumspecifika standardavvikelsen σ_t följer samma princip. Transformationen i ekvation (2) möjliggör enkel tillbakatransformation av trend och säsong.

Figur 2 illustrerar $\mu_{\text{moving},t}$, μ_t , $\sigma_{\text{moving},t}$ och σ_t som används för att transformera datasetet från X_t till Z_t enligt ekvation (2).



Figur 2: Plot för medelvärden och standardavvikelser som används i Z-transformationen.

Fenomenet att medelvärdet för temperaturen över ett år är cykliskt och skiljer sig mycket från månad till månad är nog något som alla är medvetna om. Att standardavvikelsen däremot också är cyklisk och skiljer sig märkbart under året är något som inte är lika vedertaget, men är något som tydliggörs i figur 2. En hög standardavvikelse som syns under vintermånaderna innebär att temperaturen en viss kalenderdag tenderar att skifta mycket från år till år, till skillnad från sommaren där standardavvikelsen är betydligt lägre. Detta innebär till exempel att en temperaturskillnad på 5 grader mellan samma kalenderdag med ett års mellanrum är betydligt vanligare på vintern jämfört med sommaren.

3 Datainsamling och datahantering

Datan som används kommer från väderstationerna Malmö och Malmö A och hämtas från SMHIs officiella hemsida. För att täcka upp för tidsperioder där data saknas används data från närliggande väderstationer, där stationen Falsterbo används till stor del. Detta ger en komplett fil med dygnsmedeltemperaturen varje dag från juni 1926 till augusti 2024. Eftersom ytterligare variabler som används, såsom vindriktning och nederbörd, saknar data mellan 1926 och 1951, tas enbart denna data från 1951 fram till 2025 och läggs som ett eget dataset. Båda dataseten körs sedan i MATLAB för att ta bort alla datapunkter från den 29:e februari (varje skottår), detta för att säkerställa att alla år skulle vara lika långa. Detta gör det enkelt att hantera och jämföra data under projektets gång. Hädanefter kommer de två olika dataseten att refereras till som dataset A och dataset B där A avser datan från 1926 till 2024 och B avser datan från 1951 till 2025.

3.1 Transformation av data

För att få fram de variabler som behövs för att göra Z-score-transformationen i ekvation (2) behöver $\sigma_{\text{moving},t}$ och $\mu_{\text{moving},t}$ räknas ut från rådatan. Inledningsvis beräknas μ_t och σ_t , och därefter beräknas det rörliga medelvärde $\mu_{\text{moving},t}$ och den rörliga standardavvikelsen $\sigma_{\text{moving},t}$ enligt ekvation (4) och (6). Beräkningen görs med ett fönster på 15 dagar före och 15 dagar efter ($k=15$) centrerat kring den aktuella datapunkten och resultatet visualiseras i figur 2. Med hjälp av ekvation (2) beräknas sedan det stationära datasetet Z_t .

3.2 Utvärderingsmetodik

Modellerna som undersöks i denna studie tränas på befintlig data för att identifiera underliggande mönster och parametrar. De utvärderas sedan genom att jämföra den modellerade datan med existerande data och för att inte träna modellerna på data som de sedan ska jämföras med, delas datan in i träningsdata och utvärderingsdata. Utvärderingsdatan väljs till var femte år av den extraherade datan, och träningsdatan de resterande fyra åren för varje femårsperiod. Även $\mu_{\text{moving},t}$ och $\sigma_{\text{moving},t}$ som används för Z-score-transformationen beräknas från träningsdatan. Träningsdatan består alltså av 80% av tillgängliga datan medan utvärderingsdatan består av 20%. Det bör här nämnas att modellen som tar hänsyn till ytterligare vädervariabler inte utvärderas på exakt samma tidsperiod som resterande på grund av begränsad tillgänglighet av data. Som sagt benämns de olika dataseten som A eller B där det också kan refereras till träningsdata A eller utvärderingsdata A som avser tränings- eller utvärderingsdata för dataset A. Skillnaden i användningen av data är främst relevant under avsnitten ARMA-modeller samt resultatet, där det framgår hur det har påverkat. Rapporten gör dock bedömningen att det inte har en påtaglig effekt på resultatet.

Modellerna utvärderas utifrån två huvudkriterier: deras precision gällande endagarsprognoser samt deras förmåga att generera långsiktiga tidsserier som bibehåller det ursprungliga datasetets fördelning.

Vid utvärdering av endagarsprognoser genererar modellerna deterministiska utfall, vilket möjliggör en direkt jämförelse mellan de förutsagda värdena och den faktiska utvärderingsdatan. För att däremot utvärdera modellernas förmåga att bibehålla fördelningen över ett helt år, krävs ett annat tillvägagångssätt. Vid simulering av hela år innehåller modellerna stokastiska komponenter, vilket gör att en enskild simulering inte ger en tillräcklig bild av modellens generella beteende. För att garantera ett statistiskt signifikant underlag tillämpas därför Monte Carlo-simuleringar. Respektive modell används för att generera 1000 oberoende simuleringar av ett helt år. Genom att utvärdera dessa 1000 simuleringar skapas en stabil fördelning som kan jämföras med tränings- och utvärderingsdatans historiska fördelning. Tabell 1 presenterar varians samt medelvärde för den transformerade träningsdatan och utvärderingsdatan.

Tabell 1: Varians och medelvärde för den transformerade temperaturdatan (Z-score).

Dataset	Varians	Medelvärde
Träningsdata A	1.0021	0.0038
Utvärderingsdata A	1.0063	0.0046

Tabell 1 visar hur variansen och medelvärdet för den Z-transformerade träningsdatan och utvärderingsdatan ser ut. Att variansen är nära 1 och medelvärdet nära 0 är ett kvitto på att Z-transformationen fungerar väl för att standardisera datasetet.

4 Modeller

I detta kapitel presenteras de två grenarna av matematiska modeller som utvärderats i denna studie: AR-baserade modeller, samt en Markovmodell. För att skapa en sammanhängande struktur och underlätta förståelsen behandlas varje modell enskilt i varsitt underkapitel. I respektive underkapitel presenteras teorin bakom modellen i fråga, tillämpning samt resultat från respektive modell.

4.1 Markovmodell

En Markovkedja är en stokastisk process där sannolikheten för framtida tillstånd endast beror på nuvarande tillstånd. För en diskret tidsserie innebär en första ordningens Markovkedja att den betingade sannolikheten för nästkommande tidssteg Z_{n+1} endast beror på nuvarande värde Z_n [4].

För att modellera en Markovkedja definieras ett ändligt tillståndsrum $S = \{s_1, s_2, \dots, s_k\}$, där $\{s_1, s_2, \dots, s_k\}$ är alla möjliga utfall av Z . Om Z är en kontinuerlig process kan tillstånden $\{s_1, s_2, \dots, s_k\}$ diskretiseras genom att varje s_k består av ett intervall av utfall. Processen sägs befinna sig i tillståndsrummet s_i vid tidpunkten n om $Z_n = y$ och $y \in s_i$. Övergångssannolikheten p_{ij} definieras som sannolikheten att processen rör sig till tillstånd s_j vid tidpunkt $n + 1$, givet att den befinner sig i tillstånd s_i vid tidpunkt n :

$$p_{ij} = \mathbb{P}(Z_{n+1} \in s_j \mid Z_n \in s_i). \quad (7)$$

Dessa sannolikheter måste uppfylla villkoren $p_{ij} \geq 0$ för alla i, j samt att summan av sannolikheterna från ett givet tillstånd till alla möjliga efterföljande tillstånd är lika med ett, det vill säga $\sum_{j=1}^k p_{ij} = 1$ [4].

Samtliga möjliga övergångssannolikheter i systemet kan sammanställas i en kvadratisk matris P , känd som en övergångsmatris. Varje element (i, j) i matrisen representerar sannolikheten för en direkt övergång från tillstånd i till tillstånd j :

$$P = \begin{pmatrix} p_{11} & p_{12} & \cdots & p_{1k} \\ p_{21} & p_{22} & \cdots & p_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ p_{k1} & p_{k2} & \cdots & p_{kk} \end{pmatrix}. \quad (8)$$

Genom att observera antalet faktiska övergångar från tillstånd i till tillstånd j , betecknat n_{ij} , kan sannolikheten p_{ij} skattas som kvoten mellan antalet specifika övergångar och det totala antalet gånger processen har befunnit sig i tillstånd i [1]:

$$\hat{p}_{ij} = \frac{n_{ij}}{\sum_{j=1}^k n_{ij}}. \quad (9)$$


För att en Markovkedja ska vara en tillförlitlig modell krävs att tillståndsvariabeln är definierad på ett sätt som gör observationer över tid jämförbara. I tidsreorier som uppvisar säsongsvariationer i både medelvärde och volatilitet är rådata sällan lämplig som direkt tillståndsvariabel, då

övergångssannolikheterna riskerar att variera med tiden (icke-homogena Markovkedjor). Genom att transformera tidsserien till en stationär process, exempelvis via en Z-score-transformation, kan säsongsberoenden elimineras. Detta resulterar i en tidsserie med konstant medelvärde och varians, vilket möjliggör definitionen av ett fixerat tillståndsrum där övergångssannolikheterna kan antas vara tidsberoende [3].

4.1.1 Tillämpning av Markovmodellen

För att få fram övergångsmatrisen definieras tillstånden $\{s_1, s_2, \dots, s_k\}$ som Z-score på intervallet från -5 till +5 med steglängd 0.1, där $\{-5.0 \leq s_1 < -4.9, \dots, 4.9 \leq s_k \leq 5.0\}$. Detta görs då det går att utläsa att högsta absolutvärdet för den transformerade datan är 5, således garanteras att alla möjliga utfall inkluderas i intervallet. Varje tillstånd representeras av sitt intervalls mittpunkt, vilket därmed utgör det faktiska värdet vid modellering. Genom att låta MATLAB räkna antalet övergångar mellan varje tillstånd tillhandahålls övergångsmatrisen i enlighet med ekvation (8) där sannolikheterna ges av (9).

Figur 3 visar en heatmap för tillståndsmatrisen för den historiska datan. Varmare färger innebär högre sannolikhet och figuren ska läsas radvis, där varje rads celler summeras till 1.



Figur 3: Heatmap för tillståndsmatrisen där färgerna beskriver sannolikhet för varje övergång med intervallstorlek 0.1 och gränser på $[-5, 5]$ för Z-score, baserat på träningsdata A.

Från figur 3 syns en tydlig fördelning av färger. De ljusare färgerna syns som en tjock linje dragen från övre vänstra hörnet ner till nedre högra hörnet. Detta säger att Z-scoren för en dag oftast efterföljs av en Z-score med liknande värde nästkommande dag. Att det uppvisas ett tydligt mönster innebär att användningen av en Markovkedja av första ordningen som modell är relevant för tidsserien i fråga.


Det är intressant att analysera vad som händer om man går mot randen i y-led av plotten. Där blir den ljusa linjen tjockare. Slutsatsen som kan dras av det är att normal temperatur (Z-score nära noll) är mer stabil och ändras generellt mindre för nästa dag, medan extremtemperatur oftare ger drastiska ändringar och stora dagsförändringar, vilket leder till en mer utsmetad del av ljus färg. Allra längst ut i hörnen blir några rutor plötsligt gröna, gula och röda. Dessa rutor representerar

de tillstånd som endast uppnåtts ett fåtal gånger: de mest extrema temperaturövergångarna. Detta gör att färgerna blir mycket varma på heatmap-visualiseringen, då modellen bara har ett fåtal punkter att utgå från. Om en Z-score av exempelvis 4.9 endast uppmätts en gång kommer nästa dags temperatur att vara den enda observerade övergången, vilket enligt ekvation (9) kommer att ge sannolikhet 1 att denna övergång sker.

4.1.2 Simulering och prognos

Med hjälp av övergångsmatrisen kan ett stokastiskt brus $\tilde{Z}_t$ med en given längd simuleras. Detta görs genom att ge en datapunkt ur det transformerade datasetet Z_1 som utgångspunkt, $Z_1 = \tilde{Z}_1$, vilket blir första elementet i $\tilde{Z}$. Detta placerar processen i ett givet tillstånd s_n enligt $\tilde{Z}_1 \in s_n$. Därefter genereras nästkommande tidssteg $\tilde{Z}_2$ slumpvis med sannolikhet enligt övergångsmatrisen, vilket placerar processen i ett nytt tillstånd. Detta upprepas 365 gånger för att möjliggöra modellering av ett helt år. Därefter återinförs trenden och säsongsb beroendet enligt ekvation (2). Eftersom de skapade vektorerna $\tilde{Z}$ genereras slumpvis, skapas olika vektorer varje gång simuleringen genomförs. För att utvärdera datan och få ett enhetligt resultat görs, som nämnt, 1000 simuleringar med hjälp av Markovmodellen. På så vis kan resultatet utvärderas utifrån hur modellen bibehåller statistiska egenskaper. Dessa resultat presenteras längre fram, tillsammans med resultat från övriga modeller.

Figur 4 visar ett exempel på ett års simulerade Z-score jämfört med riktiga värden från 2023. Den simulerade grafen ger förståelse för Z-transformationen och är ett exempel på en av de 1000 simuleringarna som gjordes.



Figur 4: Exempel på hur en simulerad Z-score för ett godtyckligt år ser ut jämfört med riktiga värden från år 2023.

För att göra endagarsprognoser med hjälp av Markovmodellen, tillhandahålls modellen löpande

gårdagens observerade Z-score, Z_t . Detta placerar processen i tillstånd s_i enligt $Z_t \in s_i$. För att generera nästkommande datapunkt $\hat{Z}_{t+1}$ utnyttjas två olika metoder. Första metoden, benämnd Markov₁, utgår ifrån att den mest sannolika övergången valdes, d.v.s det s_j som maximerar p_{ij} i ekvation (7) givet att $Z_t \in s_i$. Den andra metoden, benämnd Markov₂, grundar sig i att morgondagens temperatur beräknas som ett väntevärde av samtliga möjliga utfall. Istället för att enbart välja det enskilt mest sannolika utfallet, viktas varje potentiellt utfall mot dess sannolikhet enligt övergångsmatrisen ($\hat{Z}_{t+1} = \sum_j p_{ij} \cdot \bar{s}_j$, där $\bar{s}_j$ är mittpunkten i tillstånd j). För att sedan generera $\hat{Z}_{t+2}$ tillhandahålls modellerna den observerade datapunkten Z_{t+1} . Resultatet för endagarsprognoserna presenteras senare i rapporten tillsammans med resultat för andra modeller.

4.2 AR-modeller

En AR-modell (autoregressiv modell) är en modell som bygger på att nuvarande och även framtida data kan beskrivas som en linjärkombination av tidigare datapunkter [8]. Ordningen på en sådan modell bestäms av hur många tidigare punkter som tas i hänsyn i modellen; första ordningen tar en dag bakåt, andra ordningen två dagar bakåt och så vidare. Här presenteras konstruktionen av sådana modeller och följande definitioner fastslås i enlighet med Shumway och Stoffer [8].

Definition 4.1. En tidsserie Z_t är en autoregressiv modell av ordning p , AR(p), om den är stationär samt

$$Z_t = \phi_1 Z_{t-1} + \phi_2 Z_{t-2} + \dots + \phi_p Z_{t-p} + \omega_t, \quad (10)$$

där $\phi_1, \phi_2, \dots, \phi_p$ är konstanta koefficienter, $\phi_p \neq 0$ och $\omega_t \sim \text{wn}(0, \sigma_\omega^2)$ är bruset vid tiden t där $\text{wn}(0, \sigma_\omega^2)$ avser ett normalfördelat vitt brus med medelvärde 0 och varians σ_ω^2 .

En MA-modell (moving average-modell) bygger på att nuvarande värde kan beskrivas som en funktion av tidigare avvikelser (fel) från det faktiska värdet. Tidigare avvikelser eller fel kan även benämnas som brus.

Definition 4.2. En tidsserie Z_t är en moving average-modell av ordning q , MA(q), om den är stationär samt

$$Z_t = \omega_t + \theta_1 \omega_{t-1} + \theta_2 \omega_{t-2} + \dots + \theta_q \omega_{t-q}, \quad (11)$$

där $\omega_t \sim \text{wn}(0, \sigma_\omega^2)$ är bruset vid tiden t och $\theta_1, \theta_2, \dots, \theta_q$ är konstanta koefficienter med $\theta_q \neq 0$.

Notera att i ekvationerna (10) och (11) antas det att Z_t har medelvärde 0, om så ej är fallet substitueras Z_t mot $Z_t - \mu$ där μ är medelvärdet hos tidsserien i fråga.

Återigen i enlighet med Shumway och Stoffer [8] kombineras de två modellerna i följande definition.

Definition 4.3. En tidsserie Z_t är en ARMA(p, q) process om den är stationär, samt

$$Z_t = \phi_1 Z_{t-1} + \phi_2 Z_{t-2} + \dots + \phi_p Z_{t-p} + \omega_t + \theta_1 \omega_{t-1} + \theta_2 \omega_{t-2} + \dots + \theta_q \omega_{t-q}, \quad (12)$$

där variablerna är definierade som ovan, och Z_t antas ha medelvärde 0.

En ARMA(2, 1) process ser alltså ut på följande vis:

$$Z_t = \phi_1 Z_{t-1} + \phi_2 Z_{t-2} + \omega_t + \theta_1 \omega_{t-1}, \quad (13)$$

och hur skattaren för en sådan process ser ut diskuteras i det nästkommande avsnittet.

Ytterligare en påbyggnad som utforskades var att addera fler variabler till ekvation (12) i enlighet med Box & Jenkins [2], vilket ofta kallas för en ARMAX-modell. Där bokstaven X står för exogena variabler som adderas. Den ser ut på följande vis:

$$Z_t = \sum_{j=1}^p \phi_j Z_{t-j} + \sum_{k=1}^r \beta_k M_{t-1,k} + \omega_t + \sum_{l=1}^q \theta_l \omega_{t-l}, \quad (14)$$

där r är antalet ytterligare variabler som adderats, $M_1, M_2, \dots, M_r$ är variablerna och $\beta_1, \beta_2, \dots, \beta_r$ är koefficienterna framför variablerna. Ordningen på AR- respektive MA-delen är som tidigare p och q och $\omega_t \sim \text{wn}(0, \sigma_\omega^2)$ är felet vid tid t .

Notationen som används senare i rapporten för ARMAX-modellen är $\text{ARMAX}(p, r, q)$ där p är AR-delens ordning, r antalet exogena variabler och q är MA-delens ordning.

4.2.1 Skattning

Parametrarna ϕ, θ och σ_ω^2 skattas alla med hjälp av maximum likelihood-skattare på träningsdatan, och rent praktiskt används MATLABs inbyggda ARIMA-funktion. Då ytterligare variabler adderas till ARMAX-modellen, skattas parametrarna på liknande sätt med maximum likelihood-skattaren och görs med MATLABs inbyggda ARMAX-funktion. De skattade parametrarna betecknas med hattnotation som $\hat{\phi}, \hat{\theta}$ och $\hat{\sigma}_\omega^2$.

Den här rapporten utvärderar två olika typer av prediktioner med autoregressiva modeller och beroende på vilken man har valt, skattas Z_t i ekvation (13) på två olika sätt. Första metoden som utvärderas är att låta modellen förutspå nästa datapunkt givet alla tidigare datapunkter. I fallet av att förutspå temperatur innebär det att hela tiden förutspå morgondagens temperatur givet tidigare temperaturer. Skattaren för nästa dag ser då ut på följande sätt [3]:

$$\hat{Z}_t = \hat{\phi}_1 Z_{t-1} + \hat{\phi}_2 Z_{t-2} + \hat{\theta}_1 (Z_{t-1} - \hat{Z}_{t-1}), \quad (15)$$


där felet vid tid t , ω_t , är okänt och skattas till att vara noll. Felet vid tiden $t-1$ är känt och blir $Z_{t-1} - \hat{Z}_{t-1}$. Skattaren konstrueras på likvärdigt sätt för AR-modeller alternativt ARMAX-modeller.

Den andra metoden som utforskas är att simulera längre tidsperioder med hjälp av en AR(4)-modell för att se hur väl den modellerar data och fångar karaktäristiken hos den. Det blir då inte en skattare i klassisk bemärkelse utan en simulerad tidsserie $\tilde{Z}_t$ som konstrueras på följande vis:

$$\tilde{Z}_t = \hat{\phi}_1 \tilde{Z}_{t-1} + \hat{\phi}_2 \tilde{Z}_{t-2} + \hat{\phi}_3 \tilde{Z}_{t-3} + \hat{\phi}_4 \tilde{Z}_{t-4} + \hat{\omega}_t. \quad (16)$$

Här är felet $\hat{\omega}_t$ fortfarande okänt men har skattats till ett lämpligt slumpmässigt brus enligt ovan. Ekvation (16) kan alltså generera ny data framåt baserat på sin egen data, med reservation för att den behöver matas med 4 startpunkter. Det bör även här nämnas att en ARMAX-modell inte kan användas för att simulera karaktäristiken hos temperatur då modellen som utnyttjas i denna rapport inte modellerar alla variabler utan endast temperatur. Det hade därför blivit ekvivalent med att simulera en AR-modell.

Box & Jenkins [2] beskriver hur både autokorrelationsfunktionen (ACF) samt den partiella autokorrelationsfunktionen (PACF) har stor betydelse för att bestämma vad för typ av process en tidsserie är, samt av vilken ordning den är. Om PACF är 0 för dagar större än p indikerar det en $\text{AR}(p)$, medan om ACF är 0 för dagar större än q indikerar det en $\text{MA}(q)$. Om processen är en ARMA-process har varken ACF eller PACF en tydlig avslutning, utan avtar istället exponentiellt alternativt sinusoidalt. Figur 5 nedan visar både ACF och PACF för Z-score-transformerade dygnsmedeltemperaturer.



Figur 5: Autokorrelation och partiell autokorrelation för Z-score-transformerad data.

Figur 5 visar att temperaturen bör vara en AR(1)-process då PACF i princip är 0 för alla dagar utom föregående dag. Detta säger alltså att temperaturen beror nästan enbart på dagen innan, och det som visas i ACF-ploten är främst kvarhängande beroende av föregående dagar. Rapporten undersöker dock och jämför några olika ordningar och modeller för att säkerställa korrekt ordning samt modell.

I tabell 2 presenteras värdena på de skattade parametrarna för AR- och ARMA-modellerna.

Modell	$\hat{\phi}_1$	$\hat{\phi}_2$	$\hat{\phi}_3$	$\hat{\phi}_4$	$\hat{\theta}_1$	$\hat{\sigma}_\omega$
AR(1)	0.7899	—	—	—	—	0.6139
AR(2)	0.8234	-0.0424	—	—	—	0.6134
AR(3)	0.8267	-0.1066	0.0779	—	—	0.6116
AR(4)	0.8239	-0.1027	0.0475	0.0367	—	0.6111
ARMA(2,1)	0.3419	0.3328	—	—	0.4940	0.6127

Det syns i tabell 2 att AR-modellerna blir mycket lika parametermässigt. Det beror till stor del på att det främst är föregående dag som bidrar, alltså ϕ_1 , och de efterkommande koefficienterna blir därför nära 0. Det är alltså som förväntat enligt Box & Jenkins [2] resonemang för ACF och PACF. Det är även värt att observera att koefficienterna för alla AR-modeller summerar till mindre än 1, vilket får effekten att skattaren dämpar föregående värde och närmar sig därmed medelvärdet 0. Samma gäller för ARMA-modellen där AR-biten summerar till betydligt mindre än 1 eftersom MA-biten sedan kommer att bidra med ytterligare en faktor. Standardavvikelsen hos felet, $\hat{\sigma}_\omega$, är i princip densamma för alla modeller som jämförs i tabell 2, där alla befinner sig inom ett spann av bredd $2.8 \cdot 10^{-3}$.

De ytterligare variabler som adderas för att bygga upp ARMAX-modellen är vindriktning angivet i grader, vindhastighet givet i m/s, lufttryck i hPa, molnmängd i % där 100% motsvarar helt molnigt samt nederbörd i mm/dygn. All data är baserad på dagsmedel eller över ett dygns spann. Innan parametrarna för ARMAX-modellen bestäms Z-transformeras alla exogena variabler för att erhålla standardiserad data. Vindhastighet samt vindriktning kombineras även till två andra variabler som motsvarar vindhastighet i nord-sydlig respektive öst-västlig riktning för att erhålla bättre resultat med modellen [10]. Det gjordes på följande sätt i enlighet med SMHI [10]:

Låt M_{vindR} motsvara variabeln för vindriktning och M_{vindH} motsvara variabeln för vindhastighet. De kombineras på följande sätt för att erhålla M_{vindNS} och M_{vindOV} som är vindhastigheten i

nord-sydlig respektive öst-västlig riktning:

$$M_{\text{vindNS}} = M_{\text{vindH}} \cdot \cos(M_{\text{vindR}}),$$

$$M_{\text{vindOV}} = M_{\text{vindH}} \cdot \sin(M_{\text{vindR}}),$$

där 0 grader motsvarar nordlig vind och 90 grader motsvarar östlig vind. I tabell 3 presenteras de skattade parametrarna för ARMAX-modellen.

Tabell 3: Skattade parametrar för ARMAX-modellen.

	AR-del		MA-del	Exogena koefficienter					Brus
Modell	$\hat{\phi}_1$	$\hat{\phi}_2$	$\hat{\theta}_1$	$\hat{\beta}_{\text{vindNS}}$	$\hat{\beta}_{\text{vindOV}}$	$\hat{\beta}_{\text{lufttryck}}$	$\hat{\beta}_{\text{moln}}$	$\hat{\beta}_{\text{ned}}$	$\hat{\sigma}_\omega$
ARMAX	0.4376	0.2634	0.4029	-0.0786	0.0437	0.1755	0.02613	0.0363	0.5950

Det kan konstateras från tabell 3 att de ytterligare vädervariabler som adderats bidrar en del till att modellera temperaturen. Slutsatsen dras utifrån att några av de exogena koefficienterna har en inverkan på modellen, det vill säga att de inte är 0. Den främsta variabeln som spelar roll är lufttrycket, följt av vindarna i de olika riktningarna. Att $\hat{\beta}_{\text{vindNS}}$ blir negativt är rimligt då det innebär att nordliga vindar generellt bidrar negativt till temperaturutvecklingen medan sydliga vindar bidrar positivt. Att $\hat{\beta}_{\text{vindOV}}$ är positiv innebär att ostliga inlandsvindar överlag höjer temperaturen och västliga kustvindar sänker den. Det är inte lika uppenbart att det bör vara så, men det är vad modellen kommer fram till. Nederbörd har en rätt så liten effekt och moln har ännu mindre. Det är rimligt att lufttrycket har den största inverkan eftersom temperaturen till stor del beror på om det är högttryck eller lågttryck, vilket också är vad Hou et al. [7] har kommit fram till, där de har konstaterat att lufttryck är den starkaste exogena variabeln för temperatur. Det bör dock observeras att även lufttrycket har en relativt liten koefficient här och det är alltså fortfarande främst AR- samt MA-delen som dominerar, vilket indikerar att temperaturens beroende av sig själv är det starkaste förhållandet. Det är även intressant att notera att standardavvikelsen hos bruset är lägre jämfört med modellerna presenterade i tabell 2. Det beror troligtvis på att det finns mindre oförklarligt brus i tidsserien och att de ytterligare variablerna kan förklara delar av det som tidigare framstått som brus. I tabell 4 presenteras att ARMAX-modellen får lite bättre resultat, vilket då är i linje med ett mindre avvikande brus.

Tabell 4: Jämförelse av absolut medelfel MAE, för samtliga testade AR-modeller. AR(1), AR(2), AR(3), AR(4) och ARMA(2,1) har tränats på träningsdata A och utvärderats mot utvärderingsdata A. ARMA(2,1)_B samt ARMAX(2,5,1) har tränats på träningsdata B och utvärderats mot utvärderingsdata B.

Modelltyp	MAE (°C)
AR(1)	1.4315
AR(2)	1.4297
AR(3)	1.4270
AR(4)	1.4263
ARMA(2,1)	1.4280
ARMA(2,1) _B	1.4352
ARMAX(2,5,1)	1.4086

Tabell 4 illustrerar att de olika envariata AR-modellerna, samt ARMA-modellen, presterar mycket likvärdigt vid jämförelse av det absoluta medelfelet, förkortat MAE. AR(4) är den som har lägst av modellerna med rätt så liten marginal. Detta beror på tidigare diskussion om att de högre ordningarnas koefficienter har liten effekt. Den multivariata ARMAX(2,5,1)-modellen är dock den som presterar bäst totalt sett, tack vare att den har ytterligare variabler att försöka modellera vad

som ser ut som brus. Skillnaden är dock inte jättestor vilket innebär att de andra variablerna kan förklara mindre mönster men inga större trender hos temperaturen. Eftersom ARMAX-modellen utvärderas på det aningen kortare datasetet B programmeras även en ARMA(2,1)-modell som utvärderas mot samma dataset, vilket betecknas med $\text{ARMA}(2,1)_B$. Detta för att säkerställa att ARMAX-modellen faktiskt erhåller bättre resultat.

Trots att partiella autokorrelationsfunktion (PACF) i figur 5 indikerar att AR(1) modellen är mest lämplig, visar utvärderingen av prognosfelen i tabell 4 att en ökning av modellens ordning gradvis sänker felet. Detta kan förklaras av att högre ordningens termer fångar upp ett mycket svaga mönster i väderdata som inte är tillräckligt tydliga för att stå ut som signifikanta i ett PACF-diagram. Det framgår av tabell 2 att koefficienterna $\hat{\phi}_2$, $\hat{\phi}_3$ och $\hat{\phi}_4$ är små i förhållande till $\hat{\phi}_1$, vilket bekräftar PACF-analysens slutsats om att majoriteten av det inneboende beroendet ligger i gårdagens värde.

5 Resultat & Diskussion

Här presenteras resultat och diskussion i två olika sektioner. I den första jämförs modellerna vid endagensprognoser, och i den andra jämförs de i deras förmåga att fånga karaktistiken vid simulering.

5.1 Endagensprognos

Modellerna jämförs i sin förmåga att göra en prognos för medeltemperaturen en dag framåt. Utav AR-modellerna inkluderas AR(4), ARMA(2,1) och ARMAX(2,5,1) för att täcka de olika modelltyperna. Då resultatet för de övriga AR-modellerna är likställt, inkluderas dessa ej då det blir överflödigt.

Tabell 5: MAE för temperaturprediktion en dag framåt jämfört med utvärderingsdata för de olika modelltyperna.

Modelltyp	MAE (°C)
Kalendermedel	2.4134
Gårdagsgissning	1.4648
Markov ₁	1.4692
Markov ₂	1.4309
AR(4) Modell	1.4263
ARMA(2,1) Modell	1.4280
ARMAX(2,5,1)	1.4086


Ur tabell 5 kan det konstateras att samtliga utvärderade modeller presterar väl i förhållande till en enkel prognos baserad på kalendermedel μ_t . Vidare framgår att de mer avancerade modellerna överträffar gårdagsgissningen, bortsett från Markov₁.

Att Markov₁ presterar nästan identiskt med gårdagsgissningen kan härledas till att modellen konsekvent väljer det mest sannolika tillståndet. I väderdata innebär detta ofta en gissning på oförändrat väder, vilket återspeglas i det dominanta diagonala bandet i figur 3. Att Markov₂ däremot uppvisar ett lägre medelfel visar att väntevärdet av övergångsmatrisen är en bättre skattare. Genom att vikta samtliga möjliga utfall efter deras sannolikhet tar Markov₂ hänsyn till fördelningens hela form, inklusive eventuell skevhet, vilket ger en mer nyanserad prognos än att enbart följa det mest frekventa tillståndet.

När det gäller de autoregressiva modellerna framgår det att ordningens betydelse för prediktionsstyrkan är marginell. Detta resultat är i linje med den partiella autokorrelationsfunktionen (PACF) i figur 5, som tidigare nämnt indikerar att majoriteten av informationsvärdet sitter i gårdagens temperatur. Slutligen uppvisar ARMAX-modellen det lägsta genomsnittliga felet 1.4086, vilket bekräftar att inkludering av ytterligare variabler såsom lufttryck och vind bidrar med ytterligare information som inte enbart kan utläsas ur historiska temperaturdata.

Det tydligaste resultatet som presenteras är att kalendermedlet är en avsevärt sämre gissning än de studerade modellerna, vilket visar på relativt stor variation de olika åren sinsemellan och att gissningen inte kan kompensera för de något avvikande åren.

Nedan illustreras hur gårdagens temperaturgissning och några av modellerna ser ut i förhållande till faktisk temperatur i april 2010.




Figur 6: Den faktiska temperaturen i april 2010 jämfört med prognosvärdet för AR(4), ARMA(2,1), ARMAX(2,5,1), Markov₁ och gårdagsgissningen.

AR-modellerna ser till stor del ut som gårdagsgissningen fast med en dämpande faktor som går mot medelvärdet, vilket är i linje med vad AR-koefficienterna visar i tabell 2 och 3. Som nämnt tidigare summerar koefficienterna till mindre än 1, vilket gör att AR-modellerna får den karaktären att de sällan antar mer extrema värden än den verkliga datan. Samt är det vanligt för modellerna att de får en fördröjning på detta vis vid endagarsprognoser då temperaturen har ett starkt beroende på gårdagens värde [3]. Markovmodellen uppvisar liknande karakteristik som AR-modellerna men uppvisar inte alltid samma inbyggda dämpning.

Det kan sammanfattningsvis konstateras att ARMAX-modellen ger bäst prognos av de utvärderade modellerna, men att det generellt ser mycket likt ut. Ett intressant resultat är att båda Markovmodellerna som prövades presterar relativt väl i förhållande till de autoregressiva modellerna. Markov₂ presterar i princip lika bra som de flesta AR- samt ARMA-modellerna vilket är intressant då den typen av probabilistisk modell inte på förhand tros vara den starkaste för just endagarsprognoser. Oavsett kan man konstatera att det är svårt att förutspå temperaturer med de analyserade modellerna, där ingen av dem ger en riktigt stor ökning i träffsäkerhet.

5.2 Karakteristik och fördelning

I figur 7 nedan illustreras fördelningen för utvärderingsdatan, träningsdatan och 1000 års simulerad data för de båda modellerna jämfört med en $N(0,1)$ -fördelad kurva.



Figur 7: Fördelningen för antalet dagar med Z-score per intervall (intervallstorlek 0.1 och gränser på $[-5, 5]$). Notera skillnaden i värde på y-axeln, antal utfall, då storleksordningen skiljer sig avsevärt mellan de fyra histogrammen. Detta beror på att utvärderingsdatan innefattar ett mycket mindre antal utfall då den bara tagits från vart femte år av den ursprungliga datan. Träningsdatan är också storleksordningar mindre än de simulerade fördelningarna, som båda innehåller 1000 års utfall. AR-modellen som användes var AR(4).

Tabell 6 är sammanhängande med figur 7 och visar hur stor andel av datapunkterna som är inom 1, 2 och 3 standardavvikelser för träningsdatan, utvärderingsdatan och simulerad data för de olika modellerna jämfört med det teoretiska värdet för en $N(0, 1)$ -fördelad kurva.


Tabell 6: Jämförelse av Z-score-fördelning mellan teoretiskt värde, träningsdata, utvärderingsdata, simulerad data för Markovmodellen och simulerad data för AR-modellen, där det teoretiska värdet är det motsvarande värdet för en $N(0, 1)$ -fördelning.

Intervall	Teoretiskt	Utv. data	Träningsdata	Markov	AR(4)
Mellan $\pm 1\sigma$	$\sim 68.3\%$	69.55%	69.37%	69.38%	68.17%
$< -1\sigma$	$\sim 15.9\%$	15.08%	15.34%	15.32%	15.78%
$> +1\sigma$	$\sim 15.9\%$	15.37%	15.29%	15.30%	16.05%
Mellan $\pm 2\sigma$	$\sim 95.4\%$	94.98%	95.42%	95.44%	95.44%
$< -2\sigma$	$\sim 2.3\%$	2.68%	2.67%	2.66%	2.22%
$> +2\sigma$	$\sim 2.3\%$	2.34%	1.91%	1.91%	2.34%
Mellan $\pm 3\sigma$	$\sim 99.7\%$	99.51%	99.44%	99.45%	99.72%
$< -3\sigma$	$\sim 0.13\%$	0.30%	0.37%	0.36%	0.14%
$> +3\sigma$	$\sim 0.13\%$	0.19%	0.19%	0.19%	0.14%

Båda modellerna lyckas med att skapa ny data för att simulera väder över ett år. Med hjälp av att göra 1000 simuleringar tas fördelningen för den simulerade datan fram. Det går att utläsa från figur 7 att Z-scorens fördelning för träningsdatan och simulerad data för Markovmodellen är väldigt lik. Detta visar också tabell 6, som ger i stort sett identiska värden. Detta är i linje med vad som förväntas eftersom Markovmodellen bygger på just träningsdatan. Att dessa två däremot skiljer sig mer om man jämför dem med utvärderingsdatan beror helt enkelt på att träningsdatan och utvärderingsdatan har lite varierande fördelning. Detta är rimligt eftersom utvärderingsdatan endast består av 19 år jämfört med träningsdatans 79 år, vilket gör fördelningen på utvärderingsdatan mer osäker. Något värt att notera är att det finns en tydlig skevhet i fördelningen för Markovmodellen och träningsdatan. Tabell 6 visar tydligt att antalet datapunkter mindre än -2 och -3 standardavvikelser är betydligt större än antalet datapunkter större än $+2$ och $+3$. Skevheten återfinns även hos utvärderingsdatan i lite mindre utsträckning. Av tabellen framgår även att träningsdatan, utvärderingsdatan samt den Markovsimulerade datan har fler datapunkter mellan ± 1 standardavvikelse jämfört med normalfördelningskurvan. För intervallet mellan ± 2 har träningsdatan och Markovsimuleringen lika andel punkter som för en normalfördelning, vilket i kombination med att de har fler punkter mellan ± 1 indikerar en glesare fördelning av datapunkter i intervallen $[1, 2]$ och $[-1, -2]$ standardavvikelser. Detta stärks också av att andelen mätpunkter större än ± 3 standardavvikelser är större för träningsdatan och Markovdatan. Sammantaget kan fördelningen för den Markovsimulerade datan i jämförelse med en normalfördelningskurva konstateras som tjockare i centrum, glesare i intervallen $[1, 2]$ och $[-1, -2]$ och tjockare igen i svansarna.

AR-modellen utmärker sig däremot genom att generera en fördelning som nästan identiskt följer en $N(0, 1)$ -fördelning. Modellen tränas på det Z-score-transformerade datasetet ($\mu \approx 0$ och $\sigma \approx 1$), vilket liknar en $N(0, 1)$ -fördelning. Vid skattning av parametrarna ϕ och σ_ω bestämmer modellen parametrar för att bibehålla den ursprungliga fördelningen, alltså nära $N(0, 1)$. Då bruset sedan modelleras som en perfekt normalfördelning gör det att AR-modellen blir mycket lik en perfekt $N(0, 1)$ -fördelning. Det kan därför konstateras att den inte riktigt lyckas fånga karakteristiken hos den modellerade datan och även om fördelningen på det stora hela är korrekt, får den inte med skevheten som Markovmodellen lyckas modellera.

Figur 8 illustrerar det 95% konfidensintervallet beroende på hur många dagar framåt modellen gör en prognos.



Figur 8: 95% konfidensintervall för de två simulerade modellerna som illustrerar hur osäkerheten beror på antalet dagar från startpunkten.

Det är tydligt att osäkerheten hos prediktionen snabbt ökar och vid ungefär 8 dagar har konfidensintervallet konvergerat vid ± 2 i Z-score. Det implicerar att den genererade datan vid simulering efter 8 dagar inte längre har något beroende av vad startvärdet var. Att det 95% konfidensintervallet konvergerar mot just ± 2 i Z-score stärker att originaldatan är lik en normalfördelning, då tabell 6 visar att en perfekt normalfördelningskurva har 95.4% av datan inom ± 2 standardavvikelser. Vad som är värt att notera är att Markovmodellens konfidensintervall är förskjutet aningen neråt. Detta kan förklaras av den tidigare nämnda skevheten i fördelningen hos datasetet.

6 Slutsats

Sammantaget kan det konstateras att simulering med Markovmodellen ger bättre representation av temperaturdata, då den till skillnad från AR-modellen fångar upp skevheten som återfinns i både tränings- och utvärderingsdatan. Detta är en önskvärd egenskap som AR-modellen missar, vilket understryker att Markovmodellen lämpar sig bättre för simulering av längre perioder med data. För dagsprognoser är däremot alla modeller i stort sätt likvärdiga, med marginell fördel för ARMAX-modellen, vilket främst beror på att den får tillgång till gårdagens lufttryck. Intressant är att båda Markov- och AR-modellerna påvisar en stark koppling mellan gårdagens och dagens temperatur.

Markovmodellens styrka i att kunna efterlikna träningsdatan vid simulering bygger dock på att träningsdatan och utvärderingsdatan har samma fördelning. I denna rapport har det inte undersökts på djupet hur fördelningen av temperaturdata förändras över tid, vilket hade varit en relevant frågeställning vid fortsatt arbete inom detta område, då man förslagsvis hade kunnat hitta trender eller mönster hos fördelningen, vilket skulle kunna förbättra möjligheterna att skapa simuleringar som efterliknar framtida års väder på ett bättre sätt.

Ur näringslivets och organisationers perspektiv är möjligheten att bygga en matematisk modell som kan simulera fiktivt väder mycket användbar. Det gör att du kan rusta din produktion för att tåla vissa fluktuationer i exempelvis temperatur och även se hur ofta du bör räkna med höga temperaturer. För detta ändamål är Markovmodellen bäst och den kan även för framtida studier

byggas på med multivariat analys för att kunna simulera fler parametrar. I och med ytterligare parametrar kan det vara av intresse att göra högre ordningens modeller för att eventuellt fånga mer komplexa mönster, och studien uppmanar till vidare undersökning av detta.

För att förbättra den kortsiktiga prognosen skulle det vara möjligt att ta hänsyn till vädret på andra ställen i kombination med fler väderparametrar. Detta är vad flera av de väletablerade numeriska modellerna som SMHI använder sig av gör [9]. Med det menas att vädret på flera närliggande platser används för att förutspå vädret på en annan plats, med hjälp av geografiska modeller. Detta skulle dock innebära hantering av extremt mycket data och kräva mycket datorkraft. Att inkludera allt detta skulle även kräva arbete som inte är inom ramen för ett kandidatarbete.

7 Samhälleliga och etiska perspektiv

Projektet har avsett att bidra till förståelsen för hur redan befintliga matematiska modeller kan appliceras på verkliga dataset i tidsserieformat, som väder, och i vilken utsträckning korrekta prognoser kan erhållas. Gruppen argumenterar därför att det legat i projektets grund att göra nytta eftersom förståelse rörande vädret eller liknande är av intresse på ett nationellt plan. Detta har gjorts med hjälp av öppen data inhämtad från SMHI som modellerna har låtit tränas och testas mot.

Gällande datahantering har ingen personlig data, eller data som kan uppfattas som inskränkande använts. Som nämnt har endast allmänt tillgänglig väderdata utnyttjats och användningen av den datan har skett i enlighet med eventuella licenser eller avtal, och studien anser att den presenterat en tydlig struktur där det framgått varifrån datan är inhämtad.

Ytterligare en aspekt att nämna är att studien avsett framställa resultat och utvärdering av erhållna modellerna på ett fullständigt och korrekt sätt. Det finns till viss del ett intresse i att uppnå modeller med hög pricksäkerhet gällande prognostisering i och med att det finns både ett nationellt, samt individuellt, intresse för datan som skall hanteras. Med det i åtanke har modellerna rättvist utvärderats vilket också, förhoppningsvis, framgår på ett matematiskt mindre ingående sätt ty resultaten kan vara av vikt för allmänheten.

De erhållna resultaten berör främst forskare och andra ämneskunniga men kan även till viss del påverka samhället i stort. I så fall är det endast på ett gott vis då det skulle indikera att studien bidragit till förståelsen för simulering och prognostisering av temperatur. Studien anser därför att det inte finns någon aspekt av den som kan leda till etiska problem eller liknande.

Referenser

- [1] T. W. Anderson and L. A. Goodman. Statistical inference about Markov chains. *Ann. Math. Statist.*, 28:89–110, 1957. ISSN 0003-4851. doi: 10.1214/aoms/1177707039.
- [2] G. E. P. Box, G. M. Jenkins, and G. C. Reinsel. *Time Series Analysis Forecasting and Control*. Prentice Hall, 3rd edition, 1994. ISBN 0-13-060774-6. doi: 10.1002/9781118619193.
- [3] P. J. Brockwell and R. A. Davis. *Time Series: Theory and Methods*. Springer Series in Statistics. Springer New York, 1991. ISBN 978-1-4419-0319-8 978-1-4419-0320-4. doi: 10.1007/978-1-4419-0320-4.
- [4] R. Durrett. *Essentials of Stochastic Processes*. Springer Texts in Statistics. Springer International Publishing : Imprint: Springer, 3rd ed. 2016 edition, 2016. ISBN 978-3-319-45614-0. doi: 10.1007/978-3-319-45614-0.
- [5] S. Eberle, D. Cevasco, M.-A. Schwarzkopf, M. Hollm, and R. Seifried. Multivariate Simulation of Offshore Weather Time Series: A Comparison between Markov Chain, Autoregressive, and Long Short-Term Memory Models. *Wind*, 2(2):394–414, 2022. ISSN 2674-032X. doi: 10.3390/wind2020021.
- [6] A. Gut. *Probability: A Graduate Course: A Graduate Course*, volume 75 of *Springer Texts in Statistics*. Springer New York, 2013. ISBN 978-1-4614-4707-8 978-1-4614-4708-5. doi: 10.1007/978-1-4614-4708-5.
- [7] J. Hou, Y. Wang, J. Zhou, and Q. Tian. Prediction of hourly air temperature based on CNN-LSTM. *Geomatics, Natural Hazards and Risk*, 13(1):1962–1986, 2022. ISSN 1947-5705, 1947-5713. doi: 10.1080/19475705.2022.2102942.
- [8] R. H. Shumway and D. S. Stoffer. *Time Series Analysis and Its Applications: With R Examples*. Springer Texts in Statistics. Springer Nature Switzerland, 2025. ISBN 978-3-031-70583-0 978-3-031-70584-7. doi: 10.1007/978-3-031-70584-7.
- [9] SMHI. Metodik och modeller inom meteorologisk forskning. Sveriges meteorologiska och hydrologiska institut, 2024. URL <https://www.smhi.se/forskning/om-oss/forskningsenheter/meteorologi/metodik-och-modeller-inom-meteorologisk-forskning>. Uppdaterad 2025-03-12.
- [10] SMHI. Hur är en numerisk väderprognosmodell uppbyggd? Sveriges meteorologiska och hydrologiska institut, Utan datum. URL <https://www.smhi.se/kunskapsbanken/meteorologi/meteorologiska-modeller/hur-ar-en-numerisk-vaderprognosmodell-uppbyggd>.
- [11] O. Stoner and T. Economou. An advanced hidden Markov model for hourly rainfall time series. *Computational Statistics & Data Analysis*, 152:107045, 2020. ISSN 0167-9473. doi: 10.1016/j.csda.2020.107045.

A Appendix

A.1 Användning av AI

Väderdatan som har använts kommer från SMHI:s hemsida, där man kan ladda ner väderdata från specifika väderstationer. I flertalet av datafilerna saknades mätpunkter vilka hämtades från närliggande väderstationer. För att lägga ihop datafilerna och generera en CSV-fil innehållande all väderdata användes Googles AI-verktyg Gemini. OpenAI:s modell ChatGPT samt Googles modell Gemini har använts för stöd i programmering i MATLAB genom att komma med idéer på hur man förbättrar och förenklar själva koden. De har även hjälpt till med att skapa grunden för tabeller och diagram i MATLAB. De har dessutom använts i rapporten i syfte att skapa strukturerade tabeller i latex. AI-modeller har använts ytterst marginellt i rapportskrivningen som stöd till att strukturera styckesindelning i inledningen.

A.2 Rådata

Här länkas all data använd och som krävs för att köra koden. Även MATLAB-filen är bifogad. Endast personer med chalmerskonton kommer åt datan.

https://chalmers-my.sharepoint.com/:f:/g/personal/ekstedta_chalmers_se/IgDDTtQ72ZisTIwXAVBqs7G2ATXy4T0kQnHpVG12XkkmKfA?e=uCnMTQ

Nedan länkas SMHI:s sida för nedladdning av den tidigare bifogade rådatan, från både aktiva och inaktiva väderstationer.

<https://www.smhi.se/data/hitta-data-for-en-plats/ladda-ner-vaderobservationer/airtemperatureInstant>

A.3 Källkod

```
1 %% Skapa vektorer med datum, temp, z-score
2 clc; clear; clf; close all;
3
4 % Läs av filens struktur och ange att semikolon är kolumnavskiljare
5 opts = detectImportOptions('temp_datum.csv', 'Delimiter', ';');
6
7 %Tvinga MATLAB att hantera 'Temperatur' som siffror (double)
8 opts = setvartype(opts, 'Temperatur', 'double');
9
10 %Ange att kommatecknet är decimal
11 opts = setvaropts(opts, 'Temperatur', 'DecimalSeparator', ',');
12
13 %Läs in tabellen
14 T = readtable('temp_datum.csv', opts);
15
16 %Plocka ut datum och temperatur i var sin vektor
17 raw_tider = datetime(T.Datum);
18 raw_temp = T.Temperatur;
19
20 behall_index = ~(month(raw_tider) == 2 & day(raw_tider) == 29);
21 % Hitta alla rader som inte är 29 feb
22
23 tider_rensad = raw_tider(behall_index);
24 %Skapa rensade vektorer utan skottår
25
26 temp_rensad = raw_temp(behall_index);
27
28 TT_Dygn = timetable(tider_rensad, temp_rensad);
29 % Konvertera temp och datum till timetable
30
31 index_20 = mod(year(TT_Dygn.tider_rensad), 5) == 0;
32 % Skapa index för utvärderingsdatan
33
34 TT_20 = TT_Dygn(index_20, :);
```

```

35 % Skapa en egen timetable för uterderingsdatan
36 index_80 = ~index_20;
37
38 TT_80 = TT_Dygn(index_80, :);
39 % Skapa en egen timetable för träningsdatan
40
41 window = [15 15];
42 % Moving average fönster (15 framför 15 bakom).
43
44 doy20 = day(TT_20.tider_rensad, 'dayofyear');
45 % Vilken dag på året (från 0 till 365)
46
47 y_vec20 = year(TT_20.tider_rensad);
48 % Vilket år
49
50 is_lp20 = (mod(y_vec20, 4) == 0 & mod(y_vec20, 100) ~= 0) | (mod(y_vec20, 400) ==
    0);
51 %löser så att om det är skottår hoppar
52
53 doy20(is_lp20 & doy20 > 60) = doy20(is_lp20 & doy20 > 60) - 1;
54 %inte doy direkt från 59 till 61
55
56 doy80 = day(TT_80.tider_rensad, 'dayofyear');
57 %vilken dag på året (från 0 till 365)
58
59 y_vec = year(TT_80.tider_rensad);
60 %vilket år
61
62 is_lp = (mod(y_vec, 4) == 0 & mod(y_vec, 100) ~= 0) | (mod(y_vec, 400) == 0);
63 %löser så att om det är skottår hoppar
64
65 doy80(is_lp & doy80 > 60) = doy80(is_lp & doy80 > 60) - 1;
66 %inte doy direkt från 59 till 61
67
68 klimat_medel_ra = accumarray(doy80, TT_80.temp_rensad, [365 1], @mean);
69 % Skapar medeltemperaturen för varje år för varje dag i
70 % en vektor (för träningsdatan)
71
72 klimat_std_ra = accumarray(doy80, TT_80.temp_rensad, [365 1], @std);
73 % Skapar standardavvikelsen för varje år för varje dag i
74 % en vektor (för träningsdatan)
75
76 klimat_medel_ra20 = accumarray(doy20, TT_20.temp_rensad, [365 1], @mean);
77 %Skapar medeltemperaturen för varje år för varje dag i
78 % en vektor (för utvärderingsdatan)
79
80 klimat_std_ra20 = accumarray(doy20, TT_20.temp_rensad, [365 1], @std);
81 %Skapar standardavvikelsen för varje år för varje dag i
82 % en vektor (för utvärderingsdatan)
83
84 temp_medel_wrap = [klimat_medel_ra(end-14:end); klimat_medel_ra; klimat_medel_ra
    (1:15)];
85 % Ger klimat_medel_ra 15 dagar innan och 15 dagar efter för att kunna räkna
86 % ut glidande medel på medelvärdena för träningsdatan
87
88 temp_std_wrap = [klimat_std_ra(end-14:end); klimat_std_ra; klimat_std_ra(1:15)];
89 % Samma för std
90
91 temp_medel_wrap20 = [klimat_medel_ra20(end-14:end); klimat_medel_ra20;
    klimat_medel_ra20(1:15)];
92 % Ger klimat_medel_ra 15 dagar innan och 15 dagar efter för att kunna räkna
93 % ut glidande medel på medelvärdena för utvärderingsdatan
94
95 temp_std_wrap20 = [klimat_std_ra20(end-14:end); klimat_std_ra20; klimat_std_ra20
    (1:15)];
96 % Samma för std
97
98 klimat_medel_smooth = movmean(temp_medel_wrap, 30, 'omitnan');
99 %Räknar mu_moving för träningsdatan
100

```

```

101 klimat_std_smooth = movmean(temp_std_wrap, 30, 'omitnan');
102 %Räknar sigma_moving för träningsdatan
103
104 klimat_medel_smooth20 = movmean(temp_medel_wrap20, 30, 'omitnan');
105 %Räknar mu_moving för utvärderingsdatan
106
107 klimat_std_smooth20 = movmean(temp_std_wrap20, 30, 'omitnan');
108 %Räknar sigma_moving för utvärderingsdatan
109
110 klimat_medel_smooth = klimat_medel_smooth(16:end-15);
111 %Tar bort de extrainklustrade dagarna
112
113 klimat_std_smooth = klimat_std_smooth(16:end-15);
114 %Tar bort de extrainklustrade dagarna
115
116 klimat_medel_smooth20 = klimat_medel_smooth20(16:end-15);
117 %Tar bort de extrainklustrade dagarna
118
119 klimat_std_smooth20 = klimat_std_smooth20(16:end-15);
120 %Tar bort de extrainklustrade dagarna
121
122 TT_80.KlimatMean = klimat_medel_smooth(doy80);
123 TT_80.KlimatStd = klimat_std_smooth(doy80);
124 %Lägger sigma_moving och mu_moving i TT_80
125
126 TT_80.ZScore = (TT_80.temp_rensad - TT_80.KlimatMean) ./ TT_80.KlimatStd;
127 %Lägger in z-score i TT_80
128
129 zscore = TT_80.ZScore;
130
131 TT_20.KlimatMean = klimat_medel_smooth20(doy20);
132 TT_20.KlimatStd = klimat_std_smooth20(doy20);
133 %Lägger sigma_moving och mu_moving i TT_20
134
135 TT_20.ZScore = (TT_20.temp_rensad - TT_20.KlimatMean) ./ TT_20.KlimatStd;
136 %Lägger in z-score i TT_20
137
138 zscore20 = TT_20.ZScore;
139 zscore80 = TT_80.ZScore;
140 %% Exempelplot tidsserie
141 start_datum = datetime(2023, 1, 1);
142 slut_datum = datetime(2023, 2, 1);
143 %Välj start och slutdatum för plot av exempel av en tidsserie
144
145 tidsperiod = timerange(start_datum, slut_datum);
146 %Plocka ut tidsperioden
147
148
149 TT_Plot = TT_80(tidsperiod, :);
150 %Ny timetable med enbart vald period
151
152
153 figure(1)
154 %Plot för att visa vad en tidsserie är
155 plot(TT_Dygn.tider_rensad(tidsperiod), TT_Dygn.temp_rensad(tidsperiod), 'ro', '
    MarkerFaceColor', 'r', 'MarkerSize', 10);
156 title(['Temperatur väderstation Malmö B Januari 2023'], 'FontSize', 16);
157 xlabel('Datum', 'FontSize', 16);
158 ylabel('Temperatur', 'FontSize', 16);
159
160 %% Markovmatris
161
162
163 edges = -5 : 0.1 : 5;
164 %Definera intervall för varje fack
165
166 antal_states = length(edges) - 1;
167 %Antal fack
168
169 states = discretize(zscore, edges);

```

```

170 %Gör om kontinuerliga z-scores till heltal (state ID)
171
172
173 Counts = zeros(antal_states, antal_states);
174 %Skapa en tom matris för att räkna antalet övergångar
175
176 fprintf('Räknar övergångar...\n');
177
178
179 for i = 1:length(states)-1
180     %For-loop för att räkna historiska övergångar
181
182     nuvarande = states(i);
183     nasta     = states(i+1);
184
185
186     if ~isnan(nuvarande) && ~isnan(nasta)
187         % Om båda inte är NAN
188
189         Counts(nuvarande, nasta) = Counts(nuvarande, nasta) + 1;
190         % Öka counts med 1 för varje övergång
191     end
192 end
193
194
195
196 MarkovMatris = Counts ./ sum(Counts, 2);
197 %dela varje övergång med totala antalet övergångar för den raden för
198 %att få "sannolikhet"
199 MarkovMatris(isnan(MarkovMatris)) = 0;
200 %fixa division med noll
201
202 %% Markov Simulering
203
204
205 Nsim=1000;
206 %Antal simulationer
207
208 antal_dagar = 365;
209 %Antal dagars simulering
210
211 start_z = 0;
212 %Börja simuleringen vid "normalt" väder
213
214 [~, current_state] = min(abs(edges(1:end-1) - start_z));
215 %Sätter current state till rätt rad beroende på start_z
216
217 sim_zscores = zeros(antal_dagar, Nsim);
218 sim_temps    = zeros(antal_dagar, Nsim);
219 %Gör tomma matriser för simuleringen
220
221 for k=1:Nsim
222     simulated_states = zeros(antal_dagar, 1);
223     %Gör nollvektorer för varje simulerat år
224
225     for t = 1:antal_dagar
226         %Vandringsloopen för markovmatrisen
227
228         probs = MarkovMatris(current_state, :);
229         %Alla kolumners sannolikhet för raden vi står i just nu
230
231         cum_probs = cumsum(probs);
232         %Gör om sannolikheterna raden till en "trappa"
233
234         r = rand();
235         %Dra ett slumpstal (0.0 till 1.0)
236
237         next_state = find(cum_probs >= r, 1);
238         %Hitta första facket där trappan är högre än slumpstalet
239

```

```

240     simulated_states(t) = next_state;
241     %Spara
242
243     current_state = next_state;
244     %Uppdatera var vi står
245 end
246
247     stegstorlek = edges(2) - edges(1);
248     %Steglängden
249
250     zscore_fiktiv = edges(simulated_states)' + rand(antal_dagar, 1).*stegstorlek;
251     %Gör tillbaka till en vektor med z-score
252     %och slumpar vart i facket som z-scoren hamnar
253
254     sim_zscores(:, k) = zscore_fiktiv;
255     %Lägger in varje års simulerad z-score i en egen vektor
256
257     temp_fiktiv = zscore_fiktiv .* klimat_std_smooth + klimat_medel_smooth;
258     %Tillbakatransformerar till temperatur
259
260     sim_temps(:, k) = temp_fiktiv;
261     %Lägger in varje års simulerad temperatur i en egen vektor
262 end
263
264 ci_sim = prctile(sim_zscores(:, [2.5, 97.5]));
265 %Hittar var 95% av de simulerade datans z-score befinner sig
266
267 ci_hist = prctile(zscore, [2.5, 97.5]);
268 %Hittar var 95% av träningsdatans z-score befinner sig
269
270 %% Markov Heatmap
271
272
273 figure(2); clf;
274 labels = string(edges(1:end-1));
275 visnings_labels = labels;
276
277 visnings_labels(mod(1:length(labels), 10) ~= 1) = "";
278 %Visa bara var 10:e fack för att det inte ska bli kladdigt
279
280 h = heatmap(MarkovMatris);
281 %Skapa heatmap
282
283 h.XDisplayLabels = visnings_labels;
284 h.YDisplayLabels = visnings_labels;
285 h.XLabel = 'Z-score Imorgon';
286 h.YLabel = 'Z-score Idag';
287 h.Title = 'Heatmap för tillståndsmatrisen';
288 h.Colormap = jet;
289 %Vilken typ av färgpool som ska användas
290
291 h.GridVisible = 'off';
292
293 %% Plot för mu_moving, sigma_moving
294
295 figure(3)
296
297 subplot(4,1,1)
298 plot(klimat_medel_ra, 'linewidth', 1.5, 'Color', [1,0,0]);
299 %Plottar mu_t
300
301 xlim([1 365])
302 title('\mu_t', 'FontSize', 16);
303
304 ylabel('Temperatur', 'FontSize', 16);
305 grid on;
306
307 subplot(4,1,3)
308 plot(klimat_std_ra, 'linewidth', 1.5, 'Color', [1,0,0]);
309 %Plottar sigma_t

```

```

310
311 title('\sigma_t', 'FontSize', 16);
312 xlim([1 365])
313 ylabel('Standardavvikelse', 'FontSize', 16);
314 grid on;
315
316 subplot(4,1,2)
317 plot( klimat_medel_smooth,'linewidth',1.5, 'Color',[1,0,0])
318 %Plottar mu_moving
319
320 title('\mu_{moving,t}', 'FontSize', 16);
321 xlim([1 365])
322 ylabel('Temperatur', 'FontSize', 16);
323 grid on;
324
325
326 subplot(4,1,4)
327 plot( klimat_std_smooth,'linewidth',1.5, 'Color',[1,0,0])
328 %Plottar sigma_moving
329
330 title('\sigma_{moving,t}', 'FontSize', 16);
331 xlabel('Dag på året', 'FontSize', 16);
332 ylabel('Standardavvikelse', 'FontSize', 16);
333 grid on;
334 xlim([1 365])
335
336 %% Exempel på simulerad z-score
337 index_2023 = year(TT_80.tider_rensad) == 2023;
338 % Hitta alla rader som är år 2023
339
340 z_score_2023 = TT_80.ZScore(index_2023);
341 %z-scores för 2023
342
343 datum_2023 = TT_80.tider_rensad(index_2023);
344 %Datum 2023
345
346 figure(4)
347 subplot(2,1,1)
348 %Plottar den simulerade z-scoren
349
350 plot( datum_2023,zscore_fiktiv,'linewidth',1.5, 'Color',[1,0,0])
351 title('Simulerad Z-score för ett år.', 'FontSize', 16);
352 xlabel('Dag på året', 'FontSize', 16);
353 ylabel('Z-score', 'FontSize', 16);
354 ax = gca;
355 ax.XAxis.SecondaryLabel.String = '';
356 grid on;
357
358
359 subplot(2,1,2)
360 %Plottar den riktiga z-scoren 2023
361
362 plot( datum_2023, z_score_2023,'linewidth',1.5, 'Color',[1,0,0])
363 title('Verklig Z-score för året 2023.', 'FontSize', 16);
364 xlabel('Dag på året', 'FontSize', 16);
365 ylabel('Z-score', 'FontSize', 16);
366 grid on;
367
368
369 %% AR-modeller samt ACF och PACF
370 %Skapa fyra AR-modellerna, med olika många AR-termer beroende, och
371 %ARMA-modellen
372
373 model_ar1 = ar(zscore, 1);
374 %1 AR-term
375
376 model_ar2 = ar(zscore, 2);
377 %2 AR-termer
378
379 model_ar3 = ar(zscore, 3);

```



```

380 %3 AR-termer
381
382 model_ar4 = ar(zscore, 4);
383 %4 AR-termer
384
385 model_arma21 = armax(zscore, [2 1]);
386 % ARMA(2,1): 2 AR-termer, 1 MA-term
387
388 % Hämta phi-koefficienterna för varje modell. Hämta theta-koeff för ARMA.
389 phi_1 = -model_ar1.A(2:end);
390 phi_2 = -model_ar2.A(2:end);
391 phi_3 = -model_ar3.A(2:end);
392 phi_4 = -model_ar4.A(2:end);
393 phi_arma = -model_arma21.A(2:end);
394 theta_arma = model_arma21.C(2:end);
395
396 figure(5);
397 subplot(2,1,1);
398 %Plotta autokorrelationen för z-score för träningsdatan
399
400 autocorr(zscore);
401 title('Autokorrelationsfunktion (ACF)', 'FontSize', 16);
402 xlabel('Tidsfördröjning (dagar)', 'FontSize', 16);
403 ylabel('Korrelation', 'FontSize', 16);
404 set(gca, 'FontSize', 14);
405 % Gör skalstegen (siffrorna) lite större för balans
406
407 legend({'Autokorrelation'}, 'FontSize', 16, 'Location', 'northeast');
408
409 subplot(2,1,2);
410 parcorr(zscore);
411 %Plotta partiell autokorrelation för z-score för träningsdatan
412
413 title('Partiell Autokorrelationsfunktion (PACF)', 'FontSize', 16);
414 xlabel('Tidsfördröjning (dagar)', 'FontSize', 16);
415 ylabel('Partiell Korrelation', 'FontSize', 16);
416 legend({'Partiell Korrelation'}, 'FontSize', 16, 'Location', 'northeast');
417 set(gca, 'FontSize', 14);
418
419
420 Q = length(zscore20);
421 z_pred1 = nan(Q, 1);
422 z_pred2 = nan(Q, 1);
423 z_pred3 = nan(Q, 1);
424 z_pred4 = nan(Q, 1);
425 z_pred_arma = nan(Q, 1);
426 eps_k = zeros(Q, 1);
427 %Vektor för att spara historiska felet för ARMA
428
429
430 for t = 5:Q
431     %Börjar på index 5 eftersom AR(4) kräver 4 historiska dagar
432     z_pred1(t) = phi_1(1)*zscore20(t-1);
433     %AR(1)
434
435     z_pred2(t) = phi_2(1)*zscore20(t-1) + phi_2(2)*zscore20(t-2);
436     %AR(2)
437
438     z_pred3(t) = phi_3(1)*zscore20(t-1) + phi_3(2)*zscore20(t-2) + phi_3(3)*
        zscore20(t-3);
439     %AR(3)
440
441     z_pred4(t) = phi_4(1)*zscore20(t-1) + phi_4(2)*zscore20(t-2) + phi_4(3)*
        zscore20(t-3) + phi_4(4)*zscore20(t-4);
442     %AR(4)
443
444     z_pred_arma(t) = phi_arma(1)*zscore20(t-1) + phi_arma(2)*zscore20(t-2) +
        theta_arma(1)*eps_k(t-1);
445     %ARMA(2,1)

```

```

447
448
449     eps_k(t) = zscore20(t) - z_pred_arma(t);
450     %Räkna ut och spara felet för ARMA-modellen inför nästa tidssteg
451 end
452
453 mean80_length20 = klimat_medel_smooth(doy20);
454 %Ta medel och std från träningsdatan men gör den i samma
455 % längd som utvärderingsdatan så det går att tillbakatransformera.
456
457 std80_length20 = klimat_std_smooth(doy20);
458
459
460 %Konvertera predikerade z-scores till temperatur för varje modell
461 temp_pred1 = z_pred1 .* std80_length20 + mean80_length20;
462 temp_pred2 = z_pred2 .* std80_length20 + mean80_length20;
463 temp_pred3 = z_pred3 .* std80_length20 + mean80_length20;
464 temp_pred4 = z_pred4 .* std80_length20 + mean80_length20;
465 temp_pred_arma = z_pred_arma .* std80_length20 + mean80_length20;
466
467 %Lägg in värdena i TT_20
468 TT_20.Pred_Temp_AR1 = temp_pred1;
469 TT_20.Pred_Temp_AR2 = temp_pred2;
470 TT_20.Pred_Temp_AR3 = temp_pred3;
471 TT_20.Pred_Temp_AR4 = temp_pred4;
472 TT_20.Pred_Temp_ARMA = temp_pred_arma;
473
474 TT_20.Pred_Temp_Gardagen = [NaN; TT_20.temp_rensad(1:end-1)];
475 %Lägg in en vektor som är gårdagens temperatur
476
477 %% Markov day-to-day
478 disp('Gör day-to-day prediktion med Markovmodell 1');
479 states20 = discretize(zscore20, edges);
480 %Hitta vilken bin datan ligger i för teståren
481
482 z_pred_markov = nan(Q, 1);
483 stegstorlek = edges(2) - edges(1);
484
485 for t = 2:Q
486     curr_state = states20(t-1);
487     % Gårdagens state
488
489     if ~isnan(curr_state)
490
491         [max_prob, next_state] = max(MarkovMatris(curr_state, :));
492         %Hitta det mest sannolika nästa tillståndet
493
494         if max_prob > 0
495             %Säkerställ att det fanns tidigare data för detta tillstånd
496
497             z_pred_markov(t) = edges(next_state) + stegstorlek/2;
498             %Gör om state tillbaka till Z-score. Tar mitten av facket
499         else
500             %Om vi hamnar i ett fack som aldrig syns i träningsdatan
501             % antar vi att vädret är oförändrat.
502             z_pred_markov(t) = zscore20(t-1);
503         end
504     end
505 end
506
507
508 temp_pred_markov = z_pred_markov .* std80_length20 + mean80_length20; % Konvertera
509     till faktisk temperatur
510 TT_20.Pred_Temp_Markov = temp_pred_markov;
511 %Lägg in i TT_20
512
513 disp('Gör day-to-day prediktion med Markovmodell 2');
514 states20_2 = discretize(zscore20, edges);
515 % Hitta vilken bin datan ligger i för teståren
516 z_pred_markov_2 = nan(Q, 1);

```

```

516 bin_centers = edges(1:end-1) + stegstorlek/2;
517 %Förberedd en vektor med mittpunkterna för alla bins
518
519 for t = 2:Q
520 curr_state_2 = states20_2(t-1);
521 %Gårdagens state
522
523 if ~isnan(curr_state_2)
524 probs_2 = MarkovMatris(curr_state_2, :);
525 %Hämta hela sannolikhetsraden för det nuvarande tillståndet
526
527 if sum(probs_2) > 0
528     %Säkerställ att raden inte är tom
529
530 z_pred_markov_2(t) = sum(bin_centers .* probs_2);
531 %Beräkna väntevärdet genom att multiplicera varje bins
532 % mittpunkt med dess sannolikhet
533 else
534
535 z_pred_markov_2(t) = zscore20_2(t-1);
536 %Om vi hamnar i ett fack som aldrig syns i träningsdatan
537 % antar vi att vädret är oförändrat
538 end
539 end
540 end
541 temp_pred_markov_2 = z_pred_markov_2 .* std80_length20 + mean80_length20;
542 %Gör tillbaka till temperatur
543
544 TT_20.Pred_Temp_Markov_2 = temp_pred_markov_2;
545
546 %% ARMAX
547 disp('Laddar och förbereder exogen data för ARMAX...');
548 opts = detectImportOptions('armax_data.csv');
549 % Läs in ny data för ARMAX
550
551 opts.VariableNamingRule = 'preserve';
552 T_exog = readtable('armax_data.csv', opts);
553 T_exog.Datum = datetime(T_exog.Datum, 'InputFormat', 'M/d/yyyy');
554 TT_exog = table2timetable(T_exog);
555 % Gör till en TT
556
557 TT_exog = retime(TT_exog, 'daily', 'mean');
558
559 theta_rad = deg2rad(TT_exog.Vindriktning);
560 % Här görs vinddatan om från 0-360 grader till nordväst,
561 % nordost, sydväst och sydost.
562
563 hastighet = TT_exog.Vindhastighet;
564 TT_exog.Vind_U = hastighet .* cos(theta_rad);
565 TT_exog.Vind_V = hastighet .* sin(theta_rad);
566
567 active_exog = {'Vind_U', 'Vind_V', 'Lufttryck (hPa)', 'Moln', 'Nederbörd'};
568 TT_80_armax = synchronize(TT_80, TT_exog(:, active_exog), 'intersection');
569 % Synka datum (så skottår försvinner)
570
571 TT_20_armax = synchronize(TT_20, TT_exog(:, active_exog), 'intersection');
572
573 TT_80_armax = rmmissing(TT_80_armax);
574 % Rensa NaNs
575
576 TT_20_armax = rmmissing(TT_20_armax);
577
578 doy80_armax = day(TT_80_armax.Properties.RowTimes, 'dayofyear');
579 % Ta fram day-of-year (doy) för ARMAX för att matcha kalenderdagar
580
581 y_vec80_armax = year(TT_80_armax.Properties.RowTimes);
582
583 is_lp80_armax = (mod(y_vec80_armax, 4) == 0 & mod(y_vec80_armax, 100) ~= 0) | (mod(
584     y_vec80_armax, 400) == 0);

```

```

585 %Ta bort skottår från doy
586 doy80_armax(is_lp80_armax & doy80_armax > 60) = doy80_armax(is_lp80_armax &
    doy80_armax > 60) - 1;
587 %Ändra så skottår ej gör så att doy hoppar över en dag
588
589 doy20_armax = day(TT_20_armax.Properties.RowTimes, 'dayofyear');
590 %Här görs samma sak för träningsdatan
591
592 y_vec20_armax = year(TT_20_armax.Properties.RowTimes);
593 is_lp20_armax = (mod(y_vec20_armax, 4) == 0 & mod(y_vec20_armax, 100) ~= 0) | (mod(
    y_vec20_armax, 400) == 0);
594 doy20_armax(is_lp20_armax & doy20_armax > 60) = doy20_armax(is_lp20_armax &
    doy20_armax > 60) - 1;
595
596 %Skapa tomma matriser för Z-score
597 train_exog_Z = zeros(height(TT_80_armax), length(active_exog));
598 test_exog_Z = zeros(height(TT_20_armax), length(active_exog));
599
600 %Loopa igenom varje variabel och applicera kalendermedel och movmean för
601 %att få mu_moving och sigma_moving enl definition
602 for i = 1:length(active_exog)
603     var_name = active_exog{i};
604     var_data_80 = TT_80_armax(:, var_name);
605     var_data_20 = TT_20_armax(:, var_name);
606
607     % Kalendermedel & std per dag baserat på träningsdatan
608     medel_ra = accumarray(doy80_armax, var_data_80, [365 1], @mean);
609     std_ra = accumarray(doy80_armax, var_data_80, [365 1], @std);
610
611     %Wrap för moving average (15 dagar)
612     medel_wrap = [medel_ra(end-14:end); medel_ra; medel_ra(1:15)];
613     std_wrap = [std_ra(end-14:end); std_ra; std_ra(1:15)];
614
615     %Movmean (rörligt fönster 30 dagar)
616     medel_smooth = movmean(medel_wrap, 30, 'omitnan');
617     std_smooth = movmean(std_wrap, 30, 'omitnan');
618
619     %Ta bort extra inklistrade dagar
620     medel_smooth = medel_smooth(16:end-15);
621     std_smooth = std_smooth(16:end-15);
622
623     %Räkna ut Z-scores
624     train_exog_Z(:, i) = (var_data_80 - medel_smooth(doy80_armax)) ./ std_smooth(
        doy80_armax);
625     test_exog_Z(:, i) = (var_data_20 - medel_smooth(doy20_armax)) ./ std_smooth(
        doy20_armax);
626 end
627
628 %Målvariabeln är den redan uträknade Z-score för temperatur
629 target_train_Z = TT_80_armax.ZScore;
630 target_test_Z = TT_20_armax.ZScore;
631
632 %Skapa iddata och träna ARMAX(2,5,1)
633 data_train_armax = iddata(target_train_Z, train_exog_Z, 1);
634 data_test_armax = iddata(target_test_Z, test_exog_Z, 1);
635
636 nk_armax = [1, 1, 1, 1, 1];
637 %Dessa två rader säger till modellen att ta hänsyn till datapunkten en
638 %dag tidigare för varje variabel och att datan har en dags fördröjning
639
640 nb_armax = ones(1, length(nk_armax));
641 sys_armax = armax(data_train_armax, [2 nb_armax 1 nk_armax]);
642 %Detta skapar alla parametrar för modellen
643
644
645 pred_obj_armax = predict(sys_armax, data_test_armax, 1);
646 %Predikera 1 dag framåt
647
648 z_pred_armax_test = pred_obj_armax.OutputData;
649

```

```

650 %Tillbakatransformerar med träningsdatans parametrar
651 %Mappar klimat_std_smooth och klimat_medel_smooth till rätt dag på året
652 temp_pred_armax = z_pred_armax_test .* klimat_std_smooth(doy20_armax) +
        klimat_medel_smooth(doy20_armax);
653
654 %Spara i TT_20
655 TT_20.Pred_Temp_ARMAX = nan(height(TT_20), 1);
656 %Skapa tom matris med längd av TT_20
657
658 [~, idx_in_TT20] = ismember(TT_20_armax.Properties.RowTimes, TT_20.Properties.
        RowTimes);
659 %Se till att datumen matchar
660
661 TT_20.Pred_Temp_ARMAX(idx_in_TT20(idx_in_TT20 > 0)) = temp_pred_armax(idx_in_TT20 >
        0);
662 %Lägg in predictions i TT_20
663 %där resterande dagar blir NaN
664
665
666 %% Plot för AR-modeller under april 2010
667
668 start_plotAR = datetime(2010, 4, 1);
669 slut_plotAR = datetime(2010, 4, 31);
670 tidsperiod_plotAR = timerange(start_plotAR, slut_plotAR);
671 TT_Plot_AR = TT_20(tidsperiod_plotAR, :);
672
673 figure(6);
674 plot(TT_Plot_AR.tider_rensad, TT_Plot_AR.temp_rensad, 'k', 'LineWidth', 4); hold on
        ;
675 plot(TT_Plot_AR.tider_rensad, TT_Plot_AR.Pred_Temp_AR4, 'b', 'LineWidth', 2);
676 plot(TT_Plot_AR.tider_rensad, TT_Plot_AR.Pred_Temp_ARMA, 'm', 'LineWidth', 2);
677 plot(TT_Plot_AR.tider_rensad, TT_Plot_AR.Pred_Temp_ARMAX, 'y', 'LineWidth', 2);
678 plot(TT_Plot_AR.tider_rensad, TT_Plot_AR.Pred_Temp_Markov, 'c', 'LineWidth', 2);
679 plot(TT_Plot_AR.tider_rensad, TT_Plot_AR.Pred_Temp_Gardagen, 'g', 'LineWidth', 2);
680 plot(TT_Plot_AR.tider_rensad, TT_Plot_AR.KlimatMean, 'Color', '#999999', 'LineWidth'
        , 1.5)
681 legend('Faktisk Temperatur', 'AR(4)', 'ARMA(2,1)', 'ARMAX(2,5,1)', 'Markov_1', 'Gå
        rdagen', 'Medelvärde', 'FontSize', 16);
682 ylabel('Temperatur(\circC)', FontSize=16);
683 title('Jämförelse mellan verklig temperatur och olika modellers prognoser för en
        godtycklig månad (april 2010)', FontSize=16)
684
685
686 %% Plot för differens (används ej i rapport) och räkna ut MAE för alla modeller
687
688 %Beräkna differensen (Faktisk temp - predikerad temp) för hela perioden
689 diff_AR1 = TT_20.temp_rensad - TT_20.Pred_Temp_AR1;
690 diff_AR2 = TT_20.temp_rensad - TT_20.Pred_Temp_AR2;
691 diff_AR3 = TT_20.temp_rensad - TT_20.Pred_Temp_AR3;
692 diff_AR4 = TT_20.temp_rensad - TT_20.Pred_Temp_AR4;
693 diff_ARMA = TT_20.temp_rensad - TT_20.Pred_Temp_ARMA;
694 diff_ARMAX = TT_20.temp_rensad - TT_20.Pred_Temp_ARMAX;
695 diff_Markov = TT_20.temp_rensad - TT_20.Pred_Temp_Markov;
696 diff_Markov_2 = TT_20.temp_rensad - TT_20.Pred_Temp_Markov_2;
697 diff_Gardagen = TT_20.temp_rensad - TT_20.Pred_Temp_Gardagen;
698
699 %Beräkna diffen för den valda tidsperioden
700 lokdiff_AR1 = TT_Plot_AR.temp_rensad - TT_Plot_AR.Pred_Temp_AR1;
701 lokdiff_AR2 = TT_Plot_AR.temp_rensad - TT_Plot_AR.Pred_Temp_AR2;
702 lokdiff_AR3 = TT_Plot_AR.temp_rensad - TT_Plot_AR.Pred_Temp_AR3;
703 lokdiff_AR4 = TT_Plot_AR.temp_rensad - TT_Plot_AR.Pred_Temp_AR4;
704 lokdiff_ARMA = TT_Plot_AR.temp_rensad - TT_Plot_AR.Pred_Temp_ARMA;
705 lokdiff_Markov = TT_Plot_AR.temp_rensad - TT_Plot_AR.Pred_Temp_Markov;
706 lokdiff_Gardagen = TT_Plot_AR.temp_rensad - TT_Plot_AR.Pred_Temp_Gardagen;
707
708 %Skapa en ny figur för subplots
709
710 %AR(1)
711 figure(7);
712 subplot(7,1,1);

```

```

713 plot(TT_Plot_AR.tider_rensad, lokdiff_AR1, 'r');
714 title('AR(1): Differens (Används ej i rapport)');
715 ylabel('\Delta T (\circC)');
716 grid on;
717
718 % AR(2)
719 subplot(7,1,2);
720 plot(TT_Plot_AR.tider_rensad, lokdiff_AR2, 'g');
721 title('AR(2): Differens (Används ej i rapport)');
722 ylabel('\Delta T (\circC)');
723 grid on;
724
725 % AR(3)
726 subplot(7,1,3);
727 plot(TT_Plot_AR.tider_rensad, lokdiff_AR3, 'b');
728 title('AR(3): Differens (Används ej i rapport)');
729 ylabel('\Delta T (\circC)');
730 grid on;
731
732 % AR(4)
733 subplot(7,1,4);
734 plot(TT_Plot_AR.tider_rensad, lokdiff_AR4, 'm');
735 title('AR(4): Differens (Används ej i rapport)');
736 ylabel('\Delta T (\circC)');
737 xlabel('Datum');
738 grid on;
739
740 % ARMA
741 subplot(7,1,5);
742 plot(TT_Plot_AR.tider_rensad, lokdiff_ARMA, 'm');
743 title('ARMA: Differens (Används ej i rapport)');
744 ylabel('\Delta T (\circC)');
745 xlabel('Datum');
746 grid on;
747
748
749 %Markov differens
750 subplot(7,1,6);
751 plot(TT_Plot_AR.tider_rensad, lokdiff_Markov, 'c');
752 title('Markov: Differens (Används ej i rapport)');
753 ylabel('\Delta T (\circC)'); grid on;
754
755 %Gårdagsgissning
756 subplot(7,1,7);
757 plot(TT_Plot_AR.tider_rensad, lokdiff_Gardagen, 'm');
758 title('Gårdagens: Differens (Används ej i rapport)');
759 ylabel('\Delta T (\circC)');
760 xlabel('Datum');
761 grid on;
762
763 % Lägg till en övergripande rubrik för hela figuren
764 sgtitle('Residualanalys: Hur mycket fel gissade AR-modellerna?');
765
766 antal_dagar_AR = height(TT_20);
767
768 %Beräkna MAE (Mean Absolute Error) för de olika modellerna över hela perioden
769 MAE_AR1 = sum(abs(diff_AR1), 'omitnan') / antal_dagar_AR;
770 MAE_AR2 = sum(abs(diff_AR2), 'omitnan') / antal_dagar_AR;
771 MAE_AR3 = sum(abs(diff_AR3), 'omitnan') / antal_dagar_AR;
772 MAE_AR4 = sum(abs(diff_AR4), 'omitnan') / antal_dagar_AR;
773 MAE_ARMA = sum(abs(diff_ARMA), 'omitnan') / antal_dagar_AR;
774 MAE_Markov = sum(abs(diff_Markov), 'omitnan') / antal_dagar_AR;
775 MAE_Markov_2 = sum(abs(diff_Markov_2), 'omitnan') / antal_dagar_AR;
776 MAE_Gardagen = sum(abs(diff_Gardagen), 'omitnan') / antal_dagar_AR;
777
778 antal_dagar_ARMAX = sum(~isnan(diff_ARMAX));
779 % Räkna antalet värden som finns för ARMAX
780
781 MAE_ARMAX = sum(abs(diff_ARMAX), 'omitnan') / antal_dagar_ARMAX;
782

```

```

783 % Beräkna baslinjen (hur mycket fel har vi om vi bara gissar på kalendermedel?)
784 MAE_Klimat = mean(abs(TT_20.temp_rensad - TT_20.KlimatMean), 'omitnan');
785
786 %Disp i command window för den simulerade datan
787 fprintf('\n=====\\n');
788 fprintf('    RESULTAT: GENOMSNITTLIGT FEL (MAE) I GRADER \\n');
789 fprintf('=====\\n');
790 fprintf('%-25s | %-10s\\n', 'Modelltyp', 'Medelfel ( C )');
791 fprintf('-----\\n');
792 fprintf('%-25s | %10.4f\\n', 'Kalendermedel (Baslinje)', MAE_Klimat);
793 fprintf('%-25s | %10.4f\\n', 'Gårdagsgissning', MAE_Gardagen);
794 fprintf('%-25s | %10.4f\\n', 'AR(1) Modell', MAE_AR1);
795 fprintf('%-25s | %10.4f\\n', 'AR(2) Modell', MAE_AR2);
796 fprintf('%-25s | %10.4f\\n', 'AR(3) Modell', MAE_AR3);
797 fprintf('%-25s | %10.4f\\n', 'AR(4) Modell', MAE_AR4);
798 fprintf('%-25s | %10.4f\\n', 'ARMA(2,1) Modell', MAE_ARMA);
799 fprintf('%-25s | %10.4f\\n', 'Markov 1', MAE_Markov);
800 fprintf('%-25s | %10.4f\\n', 'Markov 2', MAE_Markov_2);
801 fprintf('%-25s | %10.4f\\n', 'ARMAX(2,5,1)', MAE_ARMAX);
802 fprintf('=====\\n\\n');
803
804
805 %% Simulering för AR(4)
806 %sim_z_arma är "fel namn" på
807 % variabeln då det egentligen är AR(4) som simuleras
808 N_arma_sim = 3650000;
809 % Antal dagar att simulera
810
811 sim_z_arma = zeros(N_arma_sim, 1);
812 sim_e_arma = zeros(N_arma_sim, 1);
813 %Skapar nollvektorer att fylla med data
814
815 %Hämta hur mycket vitt brus den riktiga datan har från modellen
816 sigma_e = sqrt(model_ar4.NoiseVariance);
817
818 % Generera normalfördelat vitt brus för alla 365 000 dagar
819 sim_e_arma = randn(N_arma_sim, 1) * sigma_e;
820
821 % Loopa framåt. Modellen matas med sina egna tidigare värden + dagens brus.
822 for t = 5:N_arma_sim
823     sim_z_arma(t) = phi_4(1)*sim_z_arma(t-1) + phi_4(2)*sim_z_arma(t-2) + phi_4(3)*
        sim_z_arma(t-3) + phi_4(4)*sim_z_arma(t-4) + sim_e_arma(t);
824 end
825
826
827 %% Print för fördelningsstatistik
828
829
830 fprintf('\n=====\\n');
831 fprintf('    STATISTISK FÖRDELNING OCH ASYMMETRI (SKEWNESS) \\n');
832 fprintf('=====\\n');
833
834 %Träningsdata
835 N_80 = length(zscore80);
836 %längd
837
838 ci_80 = prctile(zscore80, [2.5, 97.5]);
839 %hitta konfidensintervall från z-scoren
840
841 pct1_80 = sum(zscore80 >= -1 & zscore80 <= 1) / N_80 * 100;
842 %hitta procent av data innanför +- 1 std
843
844 pct_o1_80 = sum(zscore80 > 1) / N_80 * 100;
845 %hitta procent av data större än 1 std
846
847 pct_u1_80 = sum(zscore80 < -1) / N_80 * 100;
848 %hitta procent av data mindre än -1 std
849
850 pct2_80 = sum(zscore80 >= -2 & zscore80 <= 2) / N_80 * 100;
851 %hitta procent av data innanför +- 2 std

```

```

852
853 pct_o2_80 = sum(zscore80 > 2) / N_80 * 100;
854 %hitta procent av data större än 2 std
855
856 pct_u2_80 = sum(zscore80 < -2) / N_80 * 100;
857 %hitta procent av data mindre än -2 std
858
859 pct3_80 = sum(zscore80 >= -3 & zscore80 <= 3) / N_80 * 100;
860 %hitta procent av data innanför +- 3 std
861
862 pct_o3_80 = sum(zscore80 > 3) / N_80 * 100;
863 %hitta procent av data större än 3 std
864
865 pct_u3_80 = sum(zscore80 < -3) / N_80 * 100;
866 %hitta procent av data mindre än -3 std
867
868 %printa i command window
869 fprintf('\n--- 1. TRÄNINGSDATA (TT_80, %d dagar) ---\n', N_80);
870 fprintf('95% CI: [%3f, %3f]\n', ci_80(1), ci_80(2));
871 fprintf('Mellan +/- 1 std: %5.2f%% (Teoretiskt: ~68.3%%)\n', pct1_80);
872 fprintf('    -> Under -1: %5.2f%% (Teor: ~15.9%%)\n', pct_u1_80);
873 fprintf('    -> Över +1: %5.2f%% (Teor: ~15.9%%)\n', pct_o1_80);
874 fprintf('Mellan +/- 2 std: %5.2f%% (Teoretiskt: ~95.4%%)\n', pct2_80);
875 fprintf('    -> Under -2: %5.2f%% (Teor: ~2.3%%)\n', pct_u2_80);
876 fprintf('    -> Över +2: %5.2f%% (Teor: ~2.3%%)\n', pct_o2_80);
877 fprintf('Mellan +/- 3 std: %5.2f%% (Teoretiskt: ~99.7%%)\n', pct3_80);
878 fprintf('    -> Under -3: %5.2f%% (Teor: ~0.13%%)\n', pct_u3_80);
879 fprintf('    -> Över +3: %5.2f%% (Teor: ~0.13%%)\n', pct_o3_80);
880
881 % Utvärderingsdata (samma kod så kommenteras ej)
882 N_20 = length(zscore20);
883 ci_20 = prctile(zscore20, [2.5, 97.5]);
884
885 pct1_20 = sum(zscore20 >= -1 & zscore20 <= 1) / N_20 * 100;
886 pct_o1_20 = sum(zscore20 > 1) / N_20 * 100;
887 pct_u1_20 = sum(zscore20 < -1) / N_20 * 100;
888
889 pct2_20 = sum(zscore20 >= -2 & zscore20 <= 2) / N_20 * 100;
890 pct_o2_20 = sum(zscore20 > 2) / N_20 * 100;
891 pct_u2_20 = sum(zscore20 < -2) / N_20 * 100;
892
893 pct3_20 = sum(zscore20 >= -3 & zscore20 <= 3) / N_20 * 100;
894 pct_o3_20 = sum(zscore20 > 3) / N_20 * 100;
895 pct_u3_20 = sum(zscore20 < -3) / N_20 * 100;
896
897 fprintf('\n--- 2. UTVÄRDERINGSDATA (TT_20, %d dagar) ---\n', N_20);
898 fprintf('95% CI: [%3f, %3f]\n', ci_20(1), ci_20(2));
899 fprintf('Mellan +/- 1 std: %5.2f%% (Teoretiskt: ~68.3%%)\n', pct1_20);
900 fprintf('    -> Under -1: %5.2f%% (Teor: ~15.9%%)\n', pct_u1_20);
901 fprintf('    -> Över +1: %5.2f%% (Teor: ~15.9%%)\n', pct_o1_20);
902 fprintf('Mellan +/- 2 std: %5.2f%% (Teoretiskt: ~95.4%%)\n', pct2_20);
903 fprintf('    -> Under -2: %5.2f%% (Teor: ~2.3%%)\n', pct_u2_20);
904 fprintf('    -> Över +2: %5.2f%% (Teor: ~2.3%%)\n', pct_o2_20);
905 fprintf('Mellan +/- 3 std: %5.2f%% (Teoretiskt: ~99.7%%)\n', pct3_20);
906 fprintf('    -> Under -3: %5.2f%% (Teor: ~0.13%%)\n', pct_u3_20);
907 fprintf('    -> Över +3: %5.2f%% (Teor: ~0.13%%)\n', pct_o3_20);
908
909 % Simulerad markov (samma kod så kommenteras ej)
910 monte_carlo_z = sim_zscores(:);
911 N_markov = length(monte_carlo_z);
912 ci_markov = prctile(monte_carlo_z, [2.5, 97.5]);
913
914 pct1_m = sum(monte_carlo_z >= -1 & monte_carlo_z <= 1) / N_markov * 100;
915 pct_o1_m = sum(monte_carlo_z > 1) / N_markov * 100;
916 pct_u1_m = sum(monte_carlo_z < -1) / N_markov * 100;
917
918 pct2_m = sum(monte_carlo_z >= -2 & monte_carlo_z <= 2) / N_markov * 100;
919 pct_o2_m = sum(monte_carlo_z > 2) / N_markov * 100;
920 pct_u2_m = sum(monte_carlo_z < -2) / N_markov * 100;
921

```



```

922 pct3_m = sum(monte_carlo_z >= -3 & monte_carlo_z <= 3) / N_markov * 100;
923 pct_o3_m = sum(monte_carlo_z > 3) / N_markov * 100;
924 pct_u3_m = sum(monte_carlo_z < -3) / N_markov * 100;
925
926 fprintf('\n--- 3. SIMULERAD MARKOV (%d dagar) ---\n', N_markov);
927 fprintf('95% CI: [%3f, %3f]\n', ci_markov(1), ci_markov(2));
928 fprintf('Mellan +/- 1 std: %5.2f%% (Teoretiskt: ~68.3%)\n', pct1_m);
929 fprintf('    -> Under -1: %5.2f%% (Teor: ~15.9%)\n', pct_u1_m);
930 fprintf('    -> Över +1: %5.2f%% (Teor: ~15.9%)\n', pct_o1_m);
931 fprintf('Mellan +/- 2 std: %5.2f%% (Teoretiskt: ~95.4%)\n', pct2_m);
932 fprintf('    -> Under -2: %5.2f%% (Teor: ~2.3%)\n', pct_u2_m);
933 fprintf('    -> Över +2: %5.2f%% (Teor: ~2.3%)\n', pct_o2_m);
934 fprintf('Mellan +/- 3 std: %5.2f%% (Teoretiskt: ~99.7%)\n', pct3_m);
935 fprintf('    -> Under -3: %5.2f%% (Teor: ~0.13%)\n', pct_u3_m);
936 fprintf('    -> Över +3: %5.2f%% (Teor: ~0.13%)\n', pct_o3_m);
937
938 % Simulerad AR (samma kod så kommenteras ej). sim_z_arma är "fel namn" på
939 % variabeln då det egentligen är AR(4) som simuleras
940 N_ar = length(sim_z_arma);
941 ci_ar = prctile(sim_z_arma, [2.5, 97.5]);
942
943 pct1_ar = sum(sim_z_arma >= -1 & sim_z_arma <= 1) / N_ar * 100;
944 pct_o1_ar = sum(sim_z_arma > 1) / N_ar * 100;
945 pct_u1_ar = sum(sim_z_arma < -1) / N_ar * 100;
946
947 pct2_ar = sum(sim_z_arma >= -2 & sim_z_arma <= 2) / N_ar * 100;
948 pct_o2_ar = sum(sim_z_arma > 2) / N_ar * 100;
949 pct_u2_ar = sum(sim_z_arma < -2) / N_ar * 100;
950
951 pct3_ar = sum(sim_z_arma >= -3 & sim_z_arma <= 3) / N_ar * 100;
952 pct_o3_ar = sum(sim_z_arma > 3) / N_ar * 100;
953 pct_u3_ar = sum(sim_z_arma < -3) / N_ar * 100;
954
955 fprintf('\n--- 4. SIMULERAD AR (%d dagar) ---\n', N_ar);
956 fprintf('95% CI: [%3f, %3f]\n', ci_ar(1), ci_ar(2));
957 fprintf('Mellan +/- 1 std: %5.2f%% (Teoretiskt: ~68.3%)\n', pct1_ar);
958 fprintf('    -> Under -1: %5.2f%% (Teor: ~15.9%)\n', pct_u1_ar);
959 fprintf('    -> Över +1: %5.2f%% (Teor: ~15.9%)\n', pct_o1_ar);
960 fprintf('Mellan +/- 2 std: %5.2f%% (Teoretiskt: ~95.4%)\n', pct2_ar);
961 fprintf('    -> Under -2: %5.2f%% (Teor: ~2.3%)\n', pct_u2_ar);
962 fprintf('    -> Över +2: %5.2f%% (Teor: ~2.3%)\n', pct_o2_ar);
963 fprintf('Mellan +/- 3 std: %5.2f%% (Teoretiskt: ~99.7%)\n', pct3_ar);
964 fprintf('    -> Under -3: %5.2f%% (Teor: ~0.13%)\n', pct_u3_ar);
965 fprintf('    -> Över +3: %5.2f%% (Teor: ~0.13%)\n', pct_o3_ar);
966 fprintf('=====\n');
967
968
969
970 %Plot för histogram
971 figure(8); clf;
972
973 %Utvärderingsdata
974 subplot(4,1,1)
975 histogram(zscore20, edges, 'FaceColor', [0.2 0.6 0.8], 'EdgeColor', 'k', '
    DisplayName', 'Verklig data');
976 hold on;
977 %verklig data för var femte år
978
979 x_kurva = linspace(min(edges), max(edges), 1000);
980 %skapa en jämn x-axel
981
982
983 stegstorlek = edges(2) - edges(1);
984 %bredden på varje stapel
985
986 antal_datapunkter = length(zscore20);
987 %totalt antal dagar i datan
988
989 y_kurva = normpdf(x_kurva, 0, 1) * antal_datapunkter * stegstorlek;

```

```

990 %normpdf skapar en normal 01 fördelad kurva. Den har area 1. Gångrar sedan med
    arean
991 %för histogrammet för att få samma skala.
992
993 plot(x_kurva, y_kurva, 'LineWidth', 2.5, 'Color', [0.9 0.4 0.1], 'DisplayName', '
    Perfekt normalfördelningskurva');
994 %plotta på histogrammet
995
996 xline(0, 'r--', 'LineWidth', 1.5, 'LabelVerticalAlignment', 'top', '
    HandleVisibility', 'off');
997 title('Fördelning av Z-scores för utvärderingsdata (antal utfall per intervall)', '
    FontSize', 16); %titel
998 xlabel('Z-score')
999 ylabel('Antal utfall (Dagar)');
1000 legend('Location', 'northeast', 'FontSize', 12);
    %visar vilken färg som är vad
1001 grid on;
1002
1003 %Träningsdata
1004 subplot(4,1,2)
1005 histogram(zscore80, edges, 'FaceColor', [0.2 0.6 0.8], 'EdgeColor', 'k', '
    DisplayName', 'Träningsdata');
1006 hold on;
1007 %Verklig data
1008
1009 x_kurva = linspace(min(edges), max(edges), 1000);
1010 %Skapa en jämn x-axel
1011
1012
1013 stegstorlek = edges(2) - edges(1);
1014 %bredden på varje stapel
1015
1016 antal_datapunkter = length(zscore80);
1017 %totalt antal dagar i datan
1018
1019 y_kurva = normpdf(x_kurva, 0, 1) * antal_datapunkter * stegstorlek;
1020 %normpdf skapar en normal 01 fördelad kurva. Den har area 1.
1021 % Gångrar sedan med arean för histogrammet för att få samma skala.
1022
1023 plot(x_kurva, y_kurva, 'LineWidth', 2.5, 'Color', [0.9 0.4 0.1], 'DisplayName', '
    Perfekt normalfördelningskurva');
1024 %plotta på histogrammet
1025
1026 xline(0, 'r--', 'LineWidth', 1.5, 'LabelVerticalAlignment', 'top', '
    HandleVisibility', 'off');
1027 title('Fördelning av Z-scores för träningsdata (antal utfall per intervall)', '
    FontSize', 16);
1028 %titel
1029
1030 xlabel('Z-score')
1031 ylabel('Antal utfall (Dagar)');
1032 legend('Location', 'northeast', 'FontSize', 12);
1033 %visar vilken färg som är vad
1034
1035 grid on;
1036
1037 %Simulerad Markov
1038 subplot(4,1,3)
1039 histogram(sim_zscores, edges, 'FaceColor', [0.2 0.6 0.8], 'EdgeColor', 'k', '
    DisplayName', 'Markov simulerad data');
1040 hold on;
1041
1042 x_kurva2 = linspace(min(edges), max(edges), 1000);
1043 %skapa en jämn x-axel
1044
1045
1046 antal_datapunkter2 = length(monte_carlo_z);
1047 %totalt antal dagar i din data
1048
1049 y_kurva2 = normpdf(x_kurva2, 0, 1) * antal_datapunkter2 * stegstorlek;

```

```

1050 %normpdf skapar en normal 01 fördelad kurva. Den har area 1.
1051 % Gångrar sedan med arean för histogrammet för att få samma skala.
1052
1053 plot(x_kurva2, y_kurva2, 'LineWidth', 2.5, 'Color', [0.9 0.4 0.1], 'DisplayName', '
    Perfekt normalfördelningskurva');
1054 %plotta på histogrammet
1055
1056 xline(0, 'r--', 'LineWidth', 1.5, 'LabelVerticalAlignment', 'top', '
    HandleVisibility', 'off');
1057 title('Fördelning av Z-scores för simulerad Markovmodell (antal utfall per
    intervall)', 'FontSize', 16); %
    titel
1058 xlabel('Z-score');
1059 ylabel('Antal utfall (Dagar)');
1060 legend('Location', 'northeast', 'FontSize', 12);
1061 %visar vilken färg som är vad
1062
1063 grid on;
1064
1065
1066 subplot(4,1,4) %Simulerad AR(4)
1067
1068 histogram(sim_z_arma, edges, 'FaceColor', [0.2 0.6 0.8], 'EdgeColor', 'k', '
    DisplayName', 'AR(4) simulerad data');
1069 hold on;
1070
1071 % Skapa perfekt normalfördelningskurva som referens
1072 x_kurva_arma = linspace(min(edges), max(edges), 1000);
1073 stegstorlek = edges(2) - edges(1);
1074 y_kurva_arma = normpdf(x_kurva_arma, 0, 1) * N_arma_sim * stegstorlek;
1075
1076 plot(x_kurva_arma, y_kurva_arma, 'LineWidth', 2.5, 'Color', [0.9 0.4 0.1], '
    DisplayName', 'Perfekt normalfördelningskurva');
1077 xline(0, 'r--', 'LineWidth', 1.5, 'HandleVisibility', 'off');
1078 % Mitten
1079
1080 title('Fördelning av Z-scores för simulerad AR(4)-modell (antal utfall per
    intervall)', 'FontSize', 16);
1081 xlabel('Z-score', 'FontSize', 14);
1082 ylabel('Antal utfall (Dagar)', 'FontSize', 14);
1083 legend('Location', 'northeast', 'FontSize', 12);
1084 grid on;

```