



CHALMERS



GÖTEBORGS UNIVERSITET

Prediktera framtida aktieavkastning med linjär regression

Predicting Future Stock Returns Using Linear Regression

Examensarbete för kandidatexamen i matematik vid Göteborgs universitet

Kandidatarbete inom civilingenjörsutbildningen vid Chalmers

Olle Görefält

Gabriella Hogmalm

Ella Jansson

Elizabeth Nguyễn

Vilgot Parsmo

Mingyuan Tom Xu

Prediktera framtida aktieavkastning med linjär regression

Examensarbete för kandidatexamen i matematik vid Göteborgs universitet

Vilgot Parsmo

Kandidatarbete i matematik inom civilingenjörsprogrammet Teknisk fysik vid Chalmers

Olle Görefält Gabriella Hogmalm Ella Jansson

Kandidatarbete i matematik inom civilingenjörsprogrammet Teknisk matematik vid Chalmers

Elizabeth Nguyễn Mingyuan Tom Xu

Handledare: Carl Lindberg

Institutionen för Matematiska vetenskaper
CHALMERS TEKNISKA HÖGSKOLA
GÖTEBORGS UNIVERSITET
Göteborg, Sverige 2026

Förord

Detta kandidatarbete har genomförts vid Institutionen för Matematiska vetenskaper på Chalmers Tekniska Högskola och Göteborgs Universitet. Arbetet undersöker möjligheten att prediktera framtida aktieavkastning med hjälp av linjära regressionsmetoder baserade på finansiella och makroekonomiska variabler.

Under arbetets gång har vi haft möjlighet att kombinera finansiell teori, programmering i Python samt datahantering. Projektet har varit både lärorikt och utmanande, speciellt eftersom det har inneburit hantering av stora datamängder och flera olika modellval. En loggbok har förts kontinuerligt under arbetet för att dokumentera de enskilda deltagarnas insatser under projektets gång. I tabell 1 presenteras de ansvarsområden som respektive deltagare har haft under projektets gång, och i tabell 2 presenteras huvudförfattare för respektive avsnitt i rapporten.

Vi vill avsluta genom att rikta ett stort tack till vår handledare för vägledning och stöd under projektets gång.

Tabell 1: Tabellen presenterar de ansvarsområden som respektive person har haft under projektet.

Namn	Ansvarsområden i projektet
Olle Görefält	Kontakt med handledare, datainsamling, branschindelning, valideringsfunktioner, portföljkonstruktion, introducering av makrofaktorer, resultathantering, resultattolkning.
Gabriella Hogmalm	Boka lokal, administration, planering, ansvarig över rapportstruktur, programmering, utveckling av FactorinvestingModel-klass, parameterhantering (Enum)
Ella Jansson	Programmering, utveckla idéer för kod, utveckling av FactorinvestingModel-klass, prediktiva mått, struktur på GitHub, uppkoppling mot MLflow, testscript, resultathantering, datamerge
Elizabeth Nguyễn	Programmering, faktorberäkning, sammanställning och preprocessing (winsoriering och z-standardisering) av finansiella, makro- och sentimentfaktorer.
Vilgot Parsmo	Datainsamling, datahantering, programmering
Mingyuan Tom Xu	Val av vissa finansiella faktor, introducering av sentimentfaktorer, design och motivering samt validering av faktorgruppen (FGU) och interaktionsgruppen (IG), datainsamling för VIX och VVIX, matematiska teorin bakom z-standardisering och vinstsortering (inte implementeringen i kod)

Tabell 2: Tabellen presenterar vem som har varit huvudansvarig författare för respektive avsnitt i slutrapporten.

Namn	Huvudansvarig författare avsnitt
Olle Görefält	2.5.2, 2.6, 2.6.1, 2.6.2, 2.6.3, 2.6.4, 3.3.3, 3.4, 4.2, 4.3, 5.2, 5.4, 5.5, 5.6, 5.7, 7, D,
Gabriella Hogmalm	1, 3, 3.1.1, 3.2, 3.2.1, 3.2.2, 3.2.3, 3.3, 3.3.1, 3.4, 3.4.3, A.2, förord, sammandrag, abstract
Ella Jansson	2.5.1, 3.1, 3.1.1, 3.3.2, 3.4, 4, 4.1, 5.1, 5.3
Elizabeth Nguyễn	2.3, 2.3.3, 2.4, 2.4.1, 2.4.2, 3.1.2, 6, 8, A, A.1, A.2, A.4
Vilgot Parsmo	2.1, 2.3.1, 2.3.2, 2.4, 2.4.2, 2.5.2
Mingyuan Tom Xu	2.1, 2.2, 2.3.3, 2.3.4, 2.3.5, 2.7, A.2, A.3, A.4, A.5 B, B.1, B.2, C, C.1, C.2, C.3

Sammandrag

Att prediktera framtida aktieavkastning är en central men komplex uppgift inom finansiell ekonomi. Finansmarknaden påverkas av flera faktorer, där både makroekonomiska och företagsspecifika variabler bidrar till variationer i aktiemarknaden. Inom finansiell ekonomi används så kallade faktormodeller, där företagsspecifik information används för att hitta systematiska mönster i marknaden. Trots omfattande forskning är det dock fortsatt svårt att konstruera modeller som konsekvent genererar tillförlitliga prediktioner.

Syftet med detta arbete är att undersöka möjligheten att prediktera framtida aktieavkastning med hjälp av linjära regressionsmetoder, med målet att konstruera en modell med hög prediktiv förmåga som samtidigt kan identifiera undervärderade aktier med hög framtida avkastning. För att möjliggöra detta har 22 finansiella faktorer och nio makro-/sentimentfaktorer använts som indata i modellen. Modellen implementerades i programmeringsspråket Python, där regressionsmetoderna minsta kvadratmetoden (OLS), Ridge-regression, Lasso-regression samt Elastic Net användes. Flera olika parametrar analyserades för att undersöka hur dessa påverkar modellens prediktiva förmåga. Bland dessa analyserades olika kombinationer av finansiella faktorer, uppdelningar av tränings- och valideringsdata, prediktionshorisonter, branschindelningar och regressionsmetoder. Resultaten sparades på plattformen MLflow för att möjliggöra systematisk jämförelse och analys av modellerna. Modellerna utvärderades genom konstruktion av en likviktad long/short-portfölj, där de 10 procent högst respektive lägst rankade aktierna, baserat på predikerad avkastning, användes för portföljkonstruktionen.

Resultaten visar främst att faktorkombinationen *Interaktionsgruppen*, där åtta finansiella faktorgrupper multiplicerades med nio makro-/sentimentfaktorer, konsekvent uppvisar hög prediktiv styrka. Detta gäller både när modellen tränas med samtliga aktier i aktieindexet S&P 500, och när modellen tränas inom vissa valda branscher. Interaktionsgruppen uppvisade konsekvent hög prediktiv styrka samtidigt som portföljen genererade en avkastning på mellan 3 och 7 procentenheter över medelavkastningen för samtliga aktier, när modellen tränades på längre träningsfönster och samtliga aktier. Den regressionsmetod som uppvisade bäst prediktiv förmåga varierade beroende på om träningsmängden bestod av samtliga aktier, eller om modellen tränades inom specifika branscher. När samtliga aktier användes presterade samtliga fyra regressionsmetoder väl, med undantag för OLS, medan OLS presterade bäst vid en branschspecifik träning. Vid långa prediktionshorisonter och träningsfönster presterade modeller som tränades med samtliga aktier och med branschspecifika aktier snarlikt. Vid dessa tidsspann påträffades oftast den högsta prediktiva evidensen. En möjlig förklaring är att kortare prediktionshorisonter inte innehåller nog med information för att bekräfta korrelation mellan prediktioner och verklighet, även när resultaten tyder på det. De modeller som gav högst prediktiv styrka och högst aktieavkastning vid träning med kortare prediktionshorisonter, var de modeller som branschtränades, vilket tyder på att modeller som tränas på ett homogent urval av aktier lättare plockar upp kortsiktiga fluktuationer och sentiment.

Sammanfattningsvis föreslås en investeringsstrategi som kombinerar breda modeller med branschspecifika. Detta för att kunna dra nytta av perioder med tydliga branschrörelser, samtidigt som breda modeller kan vara mer stabila då branscher är i volatila perioder.

Abstract

Predicting future stock returns is a central yet complex task within financial economics. Financial markets are influenced by several factors, where both macroeconomic and company-specific variables contribute to variations in the stock market. In financial economics, so-called factor models are used, where company-specific information is utilized to identify systematic patterns in the market. Despite extensive research, it remains difficult to construct models that consistently generate reliable predictions.

The purpose of this study is to investigate the possibility of predicting future stock returns using linear regression methods, with the goal of constructing a model with high predictive capability that can simultaneously identify undervalued stocks with high future returns. To enable this, 22 financial factors and nine macroeconomic-/sentiment factors were used as input variables in the model. The model was implemented in the Python programming language, using the regression methods Ordinary Least Squares (OLS), Ridge regression, Lasso regression, and Elastic Net. Several different parameters were analyzed to investigate how these affect the predictive performance of the model. These included different combinations of financial factors, splits of training and validation data, prediction horizons, industry classifications, and regression methods. The results were logged on the MLflow platform to enable systematic comparison and analysis of the models. The models were evaluated through the construction of an equally weighted long/short portfolio, where the top 10 percent and bottom 10 percent of stocks, ranked based on predicted returns, were used to construct the portfolio.

The results primarily show that the factor combination referred to as the *Interaction Group*, in which eight financial factor groups were multiplied by nine macroeconomic/sentiment factors, consistently demonstrates high predictive performance. This applies both when the model is trained using all stocks in the S&P 500 index and when the model is trained within selected industries. The Interaction Group consistently exhibited strong predictive performance, while the corresponding portfolio generated returns between 3 and 7 percentage points above the average return of all stocks when the model was trained on longer training windows using the full stock universe. The regression method demonstrating the strongest predictive performance varied depending on whether the training set consisted of all stocks or only stocks within specific industries. When all stocks were included, all four regression methods performed well, with the exception of OLS, whereas OLS achieved the best performance in industry-specific training. For long prediction horizons and training windows, models trained on all stocks and models trained on industry-specific stocks performed similarly. It was often for these time frames that the highest predictive evidence occurred. A possible explanation is that shorter time frames do not contain enough information to conclude whether the predictions and reality correlates, even if indicated. The models that achieved the highest predictive strength and the highest stock returns when trained with shorter prediction horizons were the industry-trained models, suggesting that models trained on a homogeneous selection of stocks more easily capture short-term fluctuations and sentiment.

In conclusion, an investment strategy combining broad market models with industry-specific models is proposed. Such a strategy makes it possible to benefit from periods characterized by strong industry-specific movements, while broader models may offer greater stability during periods of high volatility within individual sectors.

Innehåll

1	Inledning	1
2	Teori/bakgrund	1
2.1	Prediktion och faktormodeller	1
2.2	Skattning av faktormodeller	2
2.3	Faktors egenskaper och samspel	2
2.3.1	Finansiella faktorer	2
2.3.2	Makro- och sentimentfaktorer	3
2.3.3	Standardisering av faktorer	3
2.3.4	Faktorgrupper	3
2.3.5	Interaktionsgrupper	4
2.4	Linjära regressionsmetoder	4
2.4.1	Minsta kvadratmetoden och dess begränsningar	4
2.4.2	Regularisering och regulariserade regressionsmetoder	5
2.5	Effektivitetsmått	5
2.5.1	Korrelationsmått	5
2.5.2	Portföljmått	5
2.6	Portföljkonstruktioner	6
2.6.1	Long/short tio procent likviktad	6
2.6.2	Sigmoidfunktion	7
2.6.3	Rankingbaserad	7
2.6.4	Linjär funktion	7
2.7	Modellval i högdimensionella faktormodeller	8
3	Metod	8
3.1	Datahantering	9
3.1.1	Datainsamling	9
3.1.2	Databehandling	9
3.2	Modellkonstruktion	9
3.2.1	Matriskonstruktion	9
3.2.2	Linjära regressionsmetoder	9
3.2.3	Modellprediktion	10
3.3	Parameterval	10
3.3.1	Faktorkombinationer	10
3.3.2	Hyperparametrar	10
3.3.3	Branschindelning	11
3.4	Modellutvärdering	11
4	Resultat	12
4.1	Parameteranalys	12
4.2	Branschspecifik analys	14
4.3	Jämförelse av portföljkonstruktioner	15
5	Diskussion	16
5.1	Signalsökning	16
5.2	Risker med lågt antal bolag i en portfölj	16
5.3	Tolkning av resultat för parametrar	17
5.4	Tolkning av resultat för branschindelning	17
5.5	Branschindelning kontra brett urval ur investeringssynpunkt	18
5.6	Olika portföljkonstruktioner	19
5.7	Transaktionskostnader	19
6	Samhälleliga och etiska aspekter	19
7	Slutsats	20

Referenser	20
AI-användande	22
A Variabler och faktorkonstruktion	i
A.1 Grundvariabler till finansiella faktorer	i
A.2 Finansiella faktorer	i
A.3 Faktorgrupper	ii
A.4 Makro- och sentimentfaktorer	ii
A.5 Faktoruppsättningar	iii
B Empirisk motivation och validering av FGU	iv
B.1 Motivation	iv
B.2 Validering	vii
C Empirisk motivation och validering av IG	viii
C.1 Metod	viii
C.2 Resultat	ix
C.3 Diskussion	xi
D Branschtester	xii

1 Inledning

Att förutsäga framtida aktieavkastning är en central men svår uppgift inom finansiell ekonomi. Den finansiella marknaden påverkas av flera faktorer där både makroekonomiska och företagsspecifika faktorer samt oförutsägbara världshändelser kan spela en stor roll. Trots omfattande forskning inom detta område, är det fortfarande svårt att konstruera modeller som kan generera tillförlitliga prediktioner konsekvent. En vanlig tillämpning inom finansiell ekonomi är så kallade faktormodeller, där egenskaper hos företag används för att förklara variationer i aktieavkastning. Genom att kombinera dessa faktorer kan systematiska mönster i marknaden försöka kartläggas.

I detta arbete undersöks möjligheten att prediktera framtida aktieavkastning med linjära regressionsmodeller. Ett urval av 22 finansiella faktorer och nio makro-/sentimentfaktorer används som indata i modellen. Metoden implementeras i Python, där olika regressionsmetoder såsom minsta kvadratmetoden och regulariserade metoder används. Syftet med arbetet är att utvärdera hur väl dessa modeller kan prediktera framtida avkastning, samt att analysera hur olika faktorer, såsom finansiella faktorer, träningsmängd, prediktionshorisont och regressionsmetod, påverkar modellens prediktiva förmåga. Målet med arbetet är att konstruera en modell som har en hög prediktiv styrka, och som samtidigt hittar undervärderade aktier som genererar hög avkastning.

2 Teori/bakgrund

Detta avsnitt presenterar den teoretiska bakgrund som ligger till grund för arbetet. Inledningsvis beskrivs teorier kring prediktion av aktieavkastning och utveckling av faktorbaserade modeller inom finansiell ekonomi. Därefter introduceras finansiella-, makroekonomiska- och sentimentbaserade faktorer och deras roll i att förklara variationer i aktieavkastning. Avsnittet behandlar även metodologiska principer för standardisering av variabler och deras kombination i faktor- och interaktionsgrupper. Vidare presenteras de regressionsmetoder som används för modellering. Avslutningsvis beskrivs utvärderingsmått, portföljkonstruktioner och de utmaningar som uppstår i högdimensionella faktormodeller samt strategier för att hantera dem.

2.1 Prediktion och faktormodeller

Att förutsäga aktieavkastningar har länge varit en central fråga inom finansiell ekonomi. Sharpe [1] formaliserade redan år 1964 ett tidigt ramverk för tillgångsprissättning i Capital Asset Pricing Model (CAPM), som kopplade förväntad avkastning till risk. Modellen säger att en tillgångs förväntade överavkastning är proportionell mot dess samvariation med marknadsportföljen. Detta bygger på antagandet att investerare är rationella och har homogena förväntningar, antaganden som implicit förutsätter att marknadspriser reflekterar tillgänglig information.

År 1970 gav Fama [2] denna grundidé en tydlig teoretisk förklaring i den effektiva marknadshypotesen, som säger att det är svårt att överträffa marknaden då priser innehåller relevant information. En relaterad idé är att aktiepriser kan beskrivas som en stokastisk process, modellerad som en slumpvandring enligt Malkiel [3]. Slumpvandringen innebär att framtida prisförändringar i stor utsträckning är oberoende av historiska rörelser, vilket försvårar prediktion av framtida avkastningar.

Senare empirisk forskning visade dock att CAPM inte fångade den fulla tvärsnittliga variationen i avkastningar. Under senare delen av 1970-talet och genom 1980-talet dokumenterades en serie systematiska avvikelser från CAPM som blev kända som anomalier. Basu [4] dokumenterade en värdeeffekt baserad på P/E, Banz [5] påvisade en storlekseffekt där mindre företag historiskt genererat högre riskjusterad avkastning än vad CAPM förutsäger, och De Bondt och Thaler [6] visade att aktier med svag långsiktig utveckling tenderar att överpresterar framåt, en så kallad reversal-effekt. Dessa upptäckter utmanade den effektiva marknadshypotesen, och pekade på att tvärsnittliga karakteristika hos företag systematiskt samvarierar med framtida avkastning.

År 1993 introducerade Fama och French [7] sin trefaktormodell, som tar hänsyn till empiriska anomalier genom att förklara aktiers avkastning utifrån tre systematiska faktorer: marknadsrisk, företagsstorlek och värdering. Senare forskning identifierade även momentum som en viktig förklaringsfaktor [8]. Detta ledde till Carharts fyrfaktormodell [9], där Fama och Frenchs tre faktorer kompletterades med en momentumfaktor. Fama och French [10] utvecklade senare sin modell till en femfaktormodell genom att lägga till faktorer för lönsamhet och investering, och slutligen inkluderades även momentumfaktorn i femfaktormodellen för att bilda en sexfaktormodell [11].

Schwert [12] sammanfattar denna utveckling och indikerar att marknaden inte är helt effektiv. Schwert menar att återkommande mönster i avkastningar observeras över tid. Resultaten visar att det i viss utsträckning finns möjlighet till prediktion, men dessa samband är ofta instabila och kan variera över tid. Detta betyder att modeller som bygger på historisk data måste hanteras med försiktighet, men också att möjligheten till prediktion inte helt kan avvisas på teoretiska grunder.

2.2 Skattning av faktormodeller

Lärdomen från utvecklingen av faktormodeller är att förväntad avkastning kan kopplas till flera systematiska egenskaper hos enskilda aktier. Ett etablerat sätt att utnyttja denna information är tvärsnittlig regression, där många aktiers avkastning vid en given tidpunkt relateras till deras egenskaper. Logiken introducerades av Fama och MacBeth [13], som skattade en separat regression vid varje tidpunkt och därefter aggregerade koefficienterna över tid. För varje tidpunkt t skattas

$$R_{i,t+dt} = \lambda_{0,t} + \sum_{j=1}^k \lambda_{j,t} x_{i,j,t} + \varepsilon_{i,t}, \quad (1)$$

där koefficienterna $\hat{\lambda}_{j,t}$ därefter aggregeras över tid. Detta gör det möjligt att undersöka vilka aktieegenskaper som har ett återkommande samband med framtida avkastning, snarare än att endast analysera en enskild tidsperiod.

I modellen relateras varje akties framtida avkastning över horisonten dt till observerbara faktorer vid tidpunkt t . Faktorerna kan exempelvis avse värdering, storlek, tillväxt eller, mer traditionellt, risk. Koefficienterna $\hat{\lambda}_{j,t}$ beskriver det genomsnittliga sambandet mellan en faktor och framtida avkastning över tvärsnittet vid tidpunkt t , medan residualen $\varepsilon_{i,t}$ samlar aktiespecifik variation som inte fångas av faktorerna. Eftersom skattningen bygger på tvärsnittlig variation mellan aktier är den predikterade avkastningen $\hat{R}_{i,t+dt}$ konstruerad för att beskriva hur aktie i förhåller sig till övriga aktier i universumet, inte för att rekonstruera dess absoluta utveckling.

Den predikterade avkastningen tolkas därför inte som en exakt prognos för en enskild akties faktiska avkastning, utan som ett relativt mått på hur attraktiv aktien är jämfört med övriga aktier i samma universum. Avkastningar för enskilda aktier präglas av nyhetsflöde, marknadsrörelser, sentiment och brus, komponenter som ingen uppsättning observerbara karakteristika kan reproducera fullt ut. Förklaringsgraden i prediktiva modeller på aktienivå blir därför låg, även när faktorerna är ekonomiskt välmotiverade. Detta är konsistent med Grinold och Kahns fundamental law of active management [14], där det förväntade informationsförhållandet ges av

$$IR \approx IC \cdot \sqrt{N}, \quad (2)$$

och där en låg men stabil informationskoefficient IC , presenteras i avsnitt 2.5.2, i kombination med ett stort tvärsnitt N kan ge ett ekonomiskt meningsfullt resultat. En modell kan därmed vara svag som punktprognos och samtidigt innehålla tillräckligt mycket signal för att rangordna aktier på ett ekonomiskt meningsfullt sätt.

2.3 Faktorerers egenskaper och samspel

Faktorer beskriver olika egenskaper hos företag och marknaden, exempelvis värdering, lönsamhet, tillväxt, momentum och risk. Dessa egenskaper påverkar inte aktieavkastning var för sig utan kan även samverka och förstärka eller försvaga varandras effekter. Sambanden mellan faktorer kan dessutom variera över tid och mellan olika marknader. I detta avsnitt presenteras de finansiella, makroekonomiska och sentimentbaserade faktorer samt hur deras egenskaper och samspel kan bidra till att förklara variationer i aktieavkastning.

2.3.1 Finansiella faktorer

Finansiella faktorer utgör kvantitativa mått på ett företags egenskaper som kan härledas från marknadsdata och finansiella rapporter. Faktorerna används som förklarande variabler i prediktiva modeller, med syfte att identifiera systematiska skillnader mellan bolag och relatera dessa till framtida avkastning [7]. Vanliga dimensioner av finansiella faktorer presenteras i tabell 1.

Tabell 1: Vanliga grupper av finansiella faktorer.

Dimension	Beskrivning
Värdering	Identifierar potentiellt över- eller undervärderade aktier.
Storlek	Särskiljer små och stora företag.
Momentum	Fångar trender i tidigare prisutveckling.
Kvalitet	Beskriver företags lönsamhet och operationella styrka.
Tillväxt	Mäter förändringar i företagets verksamhet över tid.
Reversal	Fångar kortsiktiga prisreverseringar.
Likviditet	Beskriver hur aktivt en aktie handlas.
Risk	Mäter finansiell risk och volatilitet.

2.3.2 Makro- och sentimentfaktorer

Finansiella faktorer beskriver skillnader mellan enskilda bolag, men fångar inte den övergripande marknadsmiljön. Aktieavkastning påverkas även av makroekonomiska förhållanden och investerares beteende, vilket innebär att en modell med endast företagsdata riskerar att missa viktiga drivkrafter [15]. Makroekonomiska faktorer, såsom räntor, inflation och konjunkturindikatorer påverkar företagens framtida kassaflöden. Förändringar i dessa faktorer kan därför påverka hela marknaden samtidigt [15]. Sentimentfaktorer syftar till att fånga investerares osäkerhet. Mått som VIX (CBOE Volatility Index) och relaterade volatilitetsmått används som indikatorer på marknadens förväntade volatilitet och risknivå [16]. Dessa faktorer kan bidra till att förklara kortsiktiga prISRörelser, som inte kan härledas till företagsdata. En fullständig lista över de makro- och sentimentfaktorer som används finns presenterade i tabell 17 i Appendix A.

2.3.3 Standardisering av faktorer

Faktorvariabler inom finansiell prediktion mäts ofta i olika enheter och skalor. Exempelvis antar värderingsmått som book-to-market ofta små värden medan market capitalization kan vara mycket större. I regressionsmodellerna med regularisering såsom Ridge-, Lasso- och Elastic Net regression, kan skillnaden i skala göra att vissa variabler får större påverkan på modellens skattningar eftersom dessa metoder inför ett straff på koefficienternas storlek [17]. Standardisering används därför för att omvandla variablerna till en gemensam skala och göra dem mer jämförbara.

Innan standardisering behandlas faktorvariablerna med winsorisering för att minska påverkan från extrema observationer. Finansiella data kännetecknas ofta av skeva fördelningar och extremvärden, exempelvis extrema förändringar i avkastning. Sådana observationer kan påverka medelvärde och standardavvikelse kraftigt, vilket i sin tur kan göra standardiseringen instabil. Winsorisering innebär att observationer utanför ett valt percentilintervall ersätts med närmaste gränsvärde istället för att tas bort från datamängden [18]. Detta begränsar extremvärdens påverkan utan att observationer tas bort från datamängden.

Beroende på faktorernas specifika struktur kan olika former av z-standardisering tillämpas för att göra data jämförbara: tvärsnittlig standardisering och tidsstandardisering. Tvärsnittlig standardisering tillämpas på finansiella faktorer. Metoden innebär att varje akties faktorvärde jämförs med motsvarande faktorvärden för samtliga andra aktier vid samma tidpunkt. Syftet är att beskriva en akties relativa position på marknaden under en given tid. Z-standardisering innebär att variabeln centreras kring sitt medelvärde och skalas med standardavvikelsen. Enligt Lima och Souza [19], beräknas standardiseringen enligt följande ekvation:

$$z_{j,i,t} = \frac{x_{j,i,t} - \bar{x}_{j,t}}{\sigma_{j,t}} \quad (3)$$

där $x_{j,i,t}$ representerar faktor j för aktie i vid tidpunkt t , medan $\bar{x}_{j,t}$ och $\sigma_{j,t}$ anger medelvärde respektive standardavvikelse beräknade över samtliga aktier under samma tid.

För makro- och sentimentbaserade variabler används istället tidsstandardisering eftersom variabler antar samma värde för samtliga aktier vid en given tidpunkt och kan därför inte standardiseras tvärsnittligt. Istället jämförs varje observation med variabelns historiska fördelning enligt följande ekvation:

$$z_{m,t} = \frac{x_{m,t} - \bar{x}_m}{\sigma_m} \quad (4)$$

där $\bar{x}_m$ och σ_m representerar variabelns historiska medelvärde och standardavvikelse över tid. Detta gör det möjligt att uttrycka hur mycket en enskild observation avviker från sitt historiska genomsnitt.

2.3.4 Faktorgrupper

Många finansiella faktorer fångar överlappande information. Värderingsmått som BM, EP och CFP (Appendix A.2) speglar besläktade ekonomiska egenskaper, liksom faktorer inom lönsamhet, momentum och risk. Hög korrelation mellan prediktorer leder till instabila koefficientskattningar i regression och försvårar tolkningen av enskilda faktorer [20].

För att hantera detta kan ekonomiskt besläktade faktorer slås samman till sammansatta faktorgrupper. Tanken är att enskilda faktorer inom samma område innehåller delvis samma signal men olika typer av brus. Genom medelvärdesbildning reduceras bruset, samtidigt som den gemensamma ekonomiska signalen bevaras. Grupperingen minskar även antalet prediktorer och ger en mer ekonomiskt tolkbar variabeluppsättning. Dock innebär medelvärdesbildning inom grupperna även att skillnader mellan enskilda faktorer kan döljas. Faktorer med olika prediktiv styrka viktas lika, vilket kan försvaga gruppens signal. Liknande aggregering används av Asness, Moskowitz och Pedersen [21], som konstruerar globala värde- och momentum faktorer genom att kombinera flera underliggande mått inom respektive område.

En faktorgrupp definieras som det medelvärdesbildade z-standardiserade värdet av de ingående finansiella faktorerna.

För grupp g med k_g faktorer ges värdet för aktie i vid tidpunkt t av

$$GRP_{g,i,t} = \frac{1}{k_g} \sum_{j=1}^{k_g} s_j \cdot z_{j,i,t}, \quad s_j \in \{-1, +1\}, \quad (5)$$

där $z_{j,i,t}$ är det tvärsnittligt z-standardiserade värdet av faktor j enligt ekvation (3).

Variabeln s_j säkerställer att alla faktorer inom en grupp pekar i samma ekonomiska riktning innan medelvärdesbildningen. Faktorer inom samma område kan ha motsatt förtecken i förhållande till förväntad avkastning. Inom riskgruppen är exempelvis hög volatilitet och hög skuldsättning förknippade med lägre riskjusterad avkastning, medan hög soliditet signalerar finansiell stabilitet. Genom att vända tecknet på faktorer som är negativt relaterade till den önskade tolkningen ($s_j = -1$) blir alla bidrag inom gruppen jämförbara. Utan denna justering kan motverkande faktorer ta ut varandra, vilket försvagar gruppens signal.

2.3.5 Interaktionsgrupper

Faktorgrupperna beskriver hur en aktie skiljer sig från andra aktier vid samma tidpunkt, men inte det makroekonomiska sammanhanget eller rådande marknadssentiment som aktien befinner sig i. Sambandet mellan en faktor och framtida avkastning kan dock variera med marknadsläget. Värdeaktier kan presterar olika i perioder av hög respektive låg volatilitet, och momentumfaktorer kan reagera olika på förändringar i räntor eller kreditspreddar.

Att inkludera interaktionstermer mellan företagsegenskaper och makrovariabler är ett etablerat sätt att fånga tillståndsberoende effekter i linjär regression [22]. Den prediktiva effekten av en aktiespecifik faktor får då bero på det makroekonomiska läget och marknadssentiment, vilket ger icke-linjäritet i variablerna men behåller den linjära parameterstrukturen. Nackdelen är att antalet prediktorer ökar snabbt, vilket ökar risken för överanpassning.

En interaktionsgrupp definieras som produkten av en tidsstandardiserad makro- eller sentimentfaktor och en faktorgrupp:

$$x_{m \times g, i, t} = z_{m, t} \cdot GRP_{g, i, t}, \quad (6)$$

där $z_{m, t}$ är det tidsstandardiserade värdet av makro- eller sentimentfaktor m vid tidpunkt t enligt ekvation (4), och $GRP_{g, i, t}$ är värdet av faktorgrupp g för aktie i vid samma tidpunkt. När en makro- eller sentimentfaktor ligger nära sitt historiska medelvärde är $z_{m, t} \approx 0$, vilket dämpar interaktionstermens bidrag. När faktorn däremot avviker kraftigt från sitt historiska genomsnitt förstärks bidraget. Regressionen kan därmed skilja på faktorernas effekt i olika marknadsregimer.

Enligt den hierarkiska principen bör en regressionsmodell med interaktionstermer i regel även inkludera tillhörande huvudeffekter [23]. Om en modell exempelvis innehåller interaktionen $X_1 X_2$, bör även X_1 och X_2 ingå separat. I en interaktion mellan en aktiespecifik faktor och en makro- eller sentimentfaktor innebär detta att båda inkluderas separat. I tvärsnittliga aktieavkastningsmodeller kan makro- och sentimentfaktorer dock behandlas annorlunda, eftersom de är gemensamma för samtliga aktier vid en given tidpunkt och därför främst fångar variation över tid snarare än mellan aktier. Ett liknande upplägg används av Gu, Kelly och Xiu [22], som i sin modell inkluderar aktiespecifika faktorer som huvudeffekter men låter makroekonomiska tillståndsvariabler ingå endast genom interaktioner med dessa faktorer. Modellen innehåller därmed inga huvudeffekter från makrovariablerna själva. På motsvarande sätt bör faktorgruppernas huvudeffekter inkluderas, medan makro- och sentimentfaktorernas separata huvudeffekter exkluderas. Makro- och sentimentfaktorerna bör därmed användas främst som tillståndsvariabler som modifierar sambandet mellan faktorgrupper och framtida avkastning.

2.4 Linjära regressionsmetoder

Inom finansiell prediktion används multipel linjär regression för att analysera hur olika faktorer relaterar till framtida avkastning. Den multipla linjära regressionsmodellen kan skrivas som

$$R_{i,t+d} = \beta_0 + \sum_{j=1}^k \beta_j x_{i,j,t} + \epsilon_{i,t} \quad (7)$$

där $R_{i,t+d}$ representerar framtida avkastning för aktie i , $x_{i,j,t}$ beskriver faktor j för aktie i vid tidpunkt t , β_j är modellens koefficienter och $\epsilon_{i,t}$ representerar modellens felterm [20].

2.4.1 Minsta kvadratmetoden och dess begränsningar

För att skatta modellens koefficienter i ekvation (7) används den klassiska skattningsmetoden minsta kvadratmetoden (Ordinary least squares, OLS) [20]. För enkel notation betecknas det observerade värdet $R_{i,t+d}$ som y_i , medan modellens predikterade värde betecknas $\hat{y}_i$. OLS skattar koefficienter genom att minimera summan av de kvadrerade residualerna,

där varje residual är skillnaden mellan det observerade värdet y_i och modellens predikterade värde,

$$\min_{\beta} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (8)$$

Trots sin enkelhet har OLS flera begränsningar, särskilt vid analys av finansiella data. En viktig begränsning är multikollinearitet som uppstår när variabler är starkt korrelerade [20]. Detta kan leda till instabila skattningar av modellens koefficienter, ökar risken för överanpassning och försämrar modellens prediktionsförmåga.

2.4.2 Regularisering och regulariserade regressionsmetoder

För att hantera problem med multikollinearitet används regularisering för att minska modellens komplexitet och förbättra stabiliteten i regressionskattningar. Genom att lägga till en straffterm som begränsar hur stora koefficienterna tillåts bli minskar modellens tendens att anpassa sig till brus i träningsdata [17].

Vanliga regulariserade regressionsmetoder är Ridge regression, Lasso regression och Elastic net. Ridge regression tillför en kvadratisk straffterm som krymper koefficienterna mot noll utan att eliminera dem, vilket stabiliserar skattningarna vid hög korrelation mellan prediktorer

$$\min_{\beta} \sum (y_i - \hat{y}_i)^2 + \lambda \sum \beta_j^2. \quad (9)$$

Lasso regression använder istället en absolut straffterm

$$\min_{\beta} \sum (y_i - \hat{y}_i)^2 + \lambda \sum |\beta_j|, \quad (10)$$

vilket kan reducera vissa koefficienter till exakt noll och därmed ge möjlighet till variabelselektion. Elastic net kombinerar de två strafftermerna från Ridge och Lasso genom att införa en viktad summa av båda regulariseringarna

$$\min_{\beta} \sum (y_i - \hat{y}_i)^2 + \lambda \left(\alpha \sum |\beta_j| + (1 - \alpha) \sum \beta_j^2 \right), \quad (11)$$

där $\alpha \in [0, 1]$ styr avvägningen mellan de två strafftermerna. Metoden kombinerar Lassos förmåga till variabelselektion med Ridges stabilitet vid korrelerade prediktorer, vilket gör den lämplig när flera faktorer är korrelerade [20].

2.5 Effektivitetsmått

I detta delavsnitt presenteras teori och ekvationer kring effektivitetsmått i form av korrelationsmått samt portföljmått och prediktiva mått. Måtten används för analysering av resultat och modeller.

2.5.1 Korrelationsmått

I en prediktiv modell behöver träffsäkerheten i förutsägelseerna alltid utvärderas för att den ska kunna tilldelas en nivå av trovärdighet. Även en totalt slumpmässig modell kommer någon gång att gissa rätt, vilket innebär att pålitlighet måste utvärderas mot en ansevärd mängd mätningar. Ett vanligt första steg i dessa utvärderingar är att söka efter en stark korrelation (ρ) [24]. Det beskriver huruvida två variabler tenderar att följa samma mönster enligt ekvation 12, där σ betecknar standardavvikelsen inom en fördelning.

$$\rho = \frac{\text{Cov}(\hat{y}, y)}{\sigma_{\hat{y}} \sigma_y} \quad (12)$$

Genom att ta hänsyn till antalet mätpunkter som används i valideringen, kan också säkerheten i själva korrelationen mellan en förutsägelse och korrekt utveckling mätas. Detta görs vanligtvis med ett *Z-score*, som normerar korrelationen och tar hänsyn till standardfelet $SE = N^{-1/2}$ enligt:

$$Z = \frac{1}{2} \frac{\ln(1 + \rho)}{\ln(1 - \rho)} N^{1/2} \quad (13)$$

Z kan i ekvation 13 tolkas som ett antal standardavvikelser som korrelationen ligger ifrån väntevärdet i en normalfördelning. Ju större detta är, desto säkrare är korrelationen, och en tumregel brukar vara att då $Z > 1.96$ bedöms korrelationen ej bero på slumpen [25]. En modell med stark prediktiv förmåga kommer således få ett högt Z -värde, och hög korrelation.

2.5.2 Portföljmått

För att utvärdera den ekonomiska relevansen av en prediktiv modell, kan en portfölj som använder sig av modellens prediktioner simuleras. Detta möjliggör flera ekonomiska mått, vars konstruktioner redogörs nedan.

Portföljens volatilitet mäts i form av standardavvikelsen i avkastningarna för varje period, annualiserad enligt

$$\sigma_{\text{ann}} = \sigma_{\text{period}} \sqrt{\frac{12}{n}}, \quad (14)$$

där σ_{period} är standardavvikelsen för serien $\{r_{t,t+n}^{LS}\}$, avkastningen mellan tid t och $t + n$ månader. Ett centralt portföljmått som väger in risk och avkastning för att mäta portföljprestanda är Sharpekvoten och den definieras som

$$\text{Sharpe} = \frac{\bar{r}_{\text{period}}}{\sigma_{\text{period}}} \sqrt{\frac{12}{n}} \quad (15)$$

där $\bar{r}_{\text{period}}$ är periodens avkastning minus periodens riskfria ränta och σ_{period} är portföljens standardavvikelse [26].

Ett kompletterande mått är hit rate, som anger andelen perioder med positiv avkastning för en long/short-portfölj, definierad i avsnitt 2.6.1, och är centralt för att mäta hur konsekvent en modell identifierar under-/övertvärdering. Hit Rate definieras som

$$\text{Hit Rate} = \frac{1}{T} \sum_{i=1}^T \mathbf{1}(r_{i,t+n}^{LS} > 0), \quad (16)$$

där $\mathbf{1}(\cdot)$ är en indikatorfunktion som antar värdet 1 om villkoret är uppfyllt och 0 annars, $\{r_{i,t+n}^{LS}\}$ är definierat likt ovan och T är antalet perioder.

Turnover beräknas som den procentuella andelen aktier i portföljen som byts ut mellan två rebalansstillfällen [27]. Måttet används för att definiera handelsintensiteten och är tillsammans med antalet rebalanseringsperioder central för portföljens transaktionskostnader [27].

Informationskoefficienten (IC) är ett mått på hur ofta en portföljs prediktion stämmer överens med faktiskt utfall, förslagsvis korrekt förutspådd riktning på utvecklingen [28]. IC definieras som

$$\text{IC} = 2 \cdot \text{Andel korrekta prediktioner} - 1 \quad (17)$$

och är ett mått som kan anta värden från -1 som betyder ingen prediktiv framgång, till $+1$ som betyder perfekt prediktiv framgång [28].

Informationskoefficientens informativa ratio (IC IR) är kvoten mellan genomsnittlig IC och dess standardavvikelse över tid, och definieras som

$$\text{IC IR} = \frac{\overline{\text{IC}}}{\sigma_{\text{IC}}}, \quad (18)$$

där $\overline{\text{IC}}$ är genomsnittlig IC över tid t , och σ_{IC} standardavvikelsen för IC över samma tid [29]. IC IR kan användas för att mäta prediktionsstyrkan, inte bara i absoluta mått, utan också om modellens prediktioner är konsekventa över tid [29].

2.6 Portföljkonstruktioner

I detta teoriavsnitt presenteras fyra portföljkonstruktioner och hur innehaven viktas. Hur innehav i en portfölj viktas är centralt för portföljens prestanda [30]. Först presenteras den huvudsakliga portföljkonstruktionen, en likviktad long/short-portfölj baserad på de 10 procent högst respektive lägst rankade aktierna baserat på predikterad avkastning [31]. Därefter presenteras en sigmoidbaserad portfölj, en rankingbaserad och en linjär portföljkonstruktion. Den rankingbaserade och den linjära portföljkonstruktionen är egenkonstruerade modeller. Alla portföljer är long/short-portföljer där de tio procent aktier med högst predikterad avkastning köps och de tio procent aktier med lägst predikterad avkastning blankas [32]. Skillnaden mellan portföljkonstruktionerna är hur vikterna fördelas inom long- respektive short-benet. I samtliga fall normaliseras long-benet till en total vikt om $+1$ och short-benet till en total vikt om -1 vilket betyder att long- och short-benen är likviktade. Portföljavkastningen beräknas därför som skillnaden mellan den viktade avkastningen i long-benet och den viktade avkastningen i short-benet. Portföljkonstruktionerna redovisas i resultatet och diskuteras i diskussionen för att motivera valet av huvudsaklig portföljkonstruktion.

2.6.1 Long/short tio procent likviktad

Den huvudsakliga portföljkonstruktionen är en likviktad long/short-portfölj [31]. Vid varje rekonstruktionstillfälle, som inträffar efter prediktionshorisonten löpt ut, sorteras aktierna efter predikterad avkastning. De tio procent aktier med högst predikterad avkastning inkluderas i long-benet och de tio procent aktier med lägst predikterad avkastning inkluderas i short-benet. Inom respektive ben ges varje aktie lika vikt. Om N_L betecknar antalet aktier i long-benet och N_S antalet

aktier i short-benet ges portföljens avkastning av

$$R_p = \sum_{i \in L} \frac{1}{N_L} R_i - \sum_{j \in S} \frac{1}{N_S} R_j. \quad (19)$$

där R_i respektive R_j är den realiserade avkastningen för aktie i respektive j under prediktionshorisonten. Den likviktade konstruktionen innebär att modellen endast används för att avgöra vilka aktier som ska ingå i portföljen och dessa aktier handlas sedan likvikttat.

2.6.2 Sigmoidfunktion

För den sigmoidbaserade portföljkonstruktionen bestäms vikterna av styrkan i modellens prediktioner [33]. Först standardiseras de predikterade avkastningarna inom varje rekonstruktionsmånad enligt

$$z_i = \frac{\hat{R}_i - \bar{\hat{R}}}{\sigma_{\hat{R}}}. \quad (20)$$

där $\hat{R}_i$ är den predikterade avkastningen för aktie i , $\bar{\hat{R}}$ är den genomsnittliga predikterade avkastningen under en rekonstruktionsperiod och $\sigma_{\hat{R}}$ är standardavvikelsen för de predikterade avkastningarna.

Därefter transformeras de standardiserade förväntade avkastningarna med tangens hyperbolicus enligt

$$s_i = \tanh(kz_i). \quad (21)$$

där s_i är den transformerade signalen för aktie i och k ett känslighetsmått som styr hur stor vikt en aktie får i portföljen baserat på standardiserad förväntad avkastning. Konstruktionen gör att större predikterade avkastningar får större betydelse, samtidigt som tangens hyperbolicus-transformeringen begränsar effekten av mycket stora signalvärden, till följd av att den är monoton och begränsad till värden i intervallet $(-1, 1)$ [34].

2.6.3 Rankingbaserad

Den egenkonstruerade rankingbaserade portföljkonstruktionen baseras på aktiernas inbördes rangordning snarare än på en viktning utifrån faktisk storlek på aktiens förväntade avkastning. Inom long-benet får den högst rankade aktien störst vikt, den näst högst rankade näst störst vikt och så vidare. Om long-benet innehåller N_L aktier kan rankingpoängen för aktie i skrivas som

$$s_{i,L} = N_L - r_i + 1. \quad (22)$$

där r_i är aktiens rank inom long-benet, med $r_i = 1$ för den högst rankade aktien. Vikten ges därefter av

$$w_{i,L} = \frac{s_{i,L}}{\sum_{j \in L} s_{j,L}}. \quad (23)$$

På motsvarande sätt ges störst absolut vikt i short-benet till den aktie som har lägst predikterad avkastning. Den rankingbaserade konstruktionen tar därmed hänsyn till aktiernas relativa ordning, men är mindre känslig för faktisk storlek på de predikterade avkastningarna. Avkastningen R_p beräknas som

$$R_p = \sum_{i \in L} w_{i,L} R_i - \sum_{j \in S} w_{j,S} R_j. \quad (24)$$

med komponenter definierade enligt ovan.

2.6.4 Linjär funktion

Den egenkonstruerade linjära portföljkonstruktionen använder standardiserade prediktioner för att vikta aktierna proportionellt mot signalstyrkan. Precis som för den sigmoidbaserade portföljen standardiseras de predikterade avkastningarna inom varje rekonstruktionsperiod enligt ekvation 20.

Inom long-benet viktas aktier proportionellt mot dess predikterade avkastning. För att säkerställa genomgående positiva vikter i long-benet används den aktie med lägst predikterad avkastning som referensnivå i form av

$$s_{i,L} = z_i - \min_{j \in L} (z_j) + \epsilon. \quad (25)$$

där ϵ är ett litet positivt tal. Vikterna ges sedan av

$$w_{i,L} = \frac{s_{i,L}}{\sum_{j \in L} s_{j,L}}. \quad (26)$$

Även i short-benet viktas aktier proportionellt mot predikterad avkastning, men i detta ben ges störst negativ vikt till den aktie med störst predikterad förlust. Uttryckt blir det

$$s_{i,S} = \max_{j \in S} (z_j) - z_i + \epsilon. \quad (27)$$

Det betyder att den linjära konstruktionen därmed gör aktiernas vikt direkt beroende av den predikterade avkastningens storlek. Till skillnad från den rankingbaserade metoden påverkas vikterna inte enbart av aktiernas rangordning, utan även skillnaden mellan aktiernas predikterade avkastning.

2.7 Modellval i högdimensionella faktormodeller

Faktorlitteraturen har vuxit kraftigt under de senaste decennierna. Cochrane [35] beskriver utvecklingen som ett *factor zoo*, där ett stort antal publicerade faktorer föreslås kunna förklara eller prediktera aktieavkastning. Harvey, Liu och Zhu [36] dokumenterar hundratals sådana faktorer och visar att en betydande andel inte håller för replikationsstudier eller standardkorrigeringar för multipel testning. Hou, Xue och Zhang [37] fann i en omfattande replikationsstudie att mer än hälften av de undersökta anomalierna förlorade statistisk signifikans efter korrigering för testmängd och förbättrad metodologi. En faktorbaserad regressionsansats står därför inför två problem, att identifiera faktorer med verklig prediktiv förmåga och att hantera hög dimensionalitet.

Fama-MacBeth-ansatsen skattar en separat tvärsnittlig regression vid varje tidpunkt [13]. När antalet faktorer är begränsat och faktorerna är svagt korrelerade fungerar den väl. Med fler prediktorer blir dock tvärsnitten högdimensionella, faktorerna ofta starkt korrelerade och skattningarna instabila med hög varians. Ett alternativ är panelregression över ett sammanhängande tidsfönster, där observationer från flera aktier och tidpunkter kombineras. Panelansatsen ökar antalet observationer per regression och ger stabilare koefficientskattningar när sambanden mellan faktorer och avkastning är förhållandevis stabila inom fönstret [22]. Den förutsätter dock stabilitet både över aktier och över tid inom fönstret, vilket bör hanteras genom rullande estimering.

En central referens är Gu, Kelly och Xiu [22] som utvärderade olika skattningsmetoder i en högdimensionell faktormodell med panelregressionsansats. Deras uppställning består av 94 aktiespecifika faktorer som huvudeffekter, interaktioner mellan dessa och 8 makroekonomiska tillståndsvariabler, samt branschdummies baserade på SIC-koder. De visar att OLS presterar sämre när antalet prediktorer är stort och delvis korrelerade, medan regulariserade metoder ger stabilare skattningar. Samtidigt finner de att mer flexibla icke-linjära metoder ofta presterar bäst, eftersom de fångar interaktioner och icke-linjära samband.

Modern empirisk tillgångsprissättning använder flera principer för att hantera dessa utmaningar. Ett strukturerat urval av faktorer och skattningsmetoder baserat på etablerad litteratur med dokumenterad replikerbarhet minskar risken för överanpassning [36], [37]. Att samla ekonomiskt besläktade faktorer i större faktorgrupper minskar antalet prediktorer och dämpar bruset från enskilda korrelerade faktorer [21]. Regulariserade regressionsmetoder hanterar kvarvarande kollinearitet och minskar instabilitet i koefficientskattningarna [22]. Interaktionstermer fångar tillståndsberoende effekter och låter en faktors betydelse variera mellan marknadslägen [22]. Branschspecifik modellering fångar slutligen att sambanden mellan faktorer och avkastning skiljer sig mellan branscher, något en samlad modell över hela aktieuniversumet jämnar ut [22].

3 Metod

I detta arbete användes linjära regressionsmodeller för att prediktera framtida aktieavkastning för aktier som ingått i aktieindexet S&P 500 de senaste 20 åren, baserat på finansiella och makroekonomiska variabler. Målet var att med hjälp av en faktorkombination av faktorer vid en tidpunkt t , kunna prediktera den framtida avkastningen vid tidpunkt $t + dt$. Syftet med arbetet var att undersöka hur en viss faktorkombination, olika typer av regressionsmetoder samt prediktionshorisonter och tidsfönster (träningsperioder) kunde användas för att förutsäga framtida avkastning. Samtliga steg i utvecklingen av modeller implementerades i Python. För att skapa en modell som predikterar framtida aktieavkastning delades arbetet upp i fyra större områden. Dessa områden bestod av datahantering, modellkonstruktion, parameterval, samt modellutvärdering.

3.1 Datahantering

På grund av tillgång, processorkraft och lagringsminne finns det en del praktiska avgränsningar kring hur mycket och vilken data som kan användas. Det finns även teoretiska faktorer som kan försämra modellprestandan såsom bias, brus och onormerad data. Detta måste alltid tas i beaktande vid träning inom prediktionsmetoder. Hur dessa begränsningar har hanterats, samt tillvägagångssättet för hur data samlats in, behandlats och använts, beskrivs i denna sektion.

3.1.1 Datainsamling

Företagsdatan hämtades från hemsidan Wharton Research Data Services där aktiedata (CRSP), kvartalsdata (Compustat). CRSP och Compustat är två databaser som innehåller historisk marknadsdata för aktier, såsom aktiepriser och handelsvolymer respektive företagens finansiella kvartalsdata såsom balans- och resultaträkningar. Makrodatan fick däremot hämtas från FRED (Federal Reserve Economic Data), som tillhandahålls av Federal Reserve Bank of St. Louis. Datan hämtades löpande under arbetet, där den första modellen använde data från 50 företag, medan den slutliga modellen använde data från samtliga företag som funnits i aktieindexet S&P 500 mellan åren 2004 och 2024. För att undvika en systematisk träning mot enbart företag som är stora idag och på så sätt vuxit historiskt, har även avlistade företag sparats och använts. Den dagliga prisnivån för VIX och VVIX hämtades från Yahoo Finance, med VIX mellan åren 2004 och 2024, och VVIX mellan 2007 och 2024.

Filerna sammanfogades genom att sammankoppla CRSP och Compustat månadsvis för varje bolag, genom att mappa värdepappersidentifieraren CUSIP, en unik kod som identifierar finansiella instrument, i CRSP mot samma kod i Compustat. Från CRSP användes datan för den sista dagen varje månad. Då Compustat är kvartalsdata, som bara släpps var tredje månad och kan komma att redigeras eller bli tillgänglig för investerare i efterhand, försköts den tillgängliga Compustat-datan tre månader och upprepades sedan i tre månader tills nästa mängd med kvartalsdata blev tillgänglig. Makrodata, VIX och VVIX är identiska för varje företag, och kopplades också månadsvis till varje datamängd.

Tidigt i projektet sparades datan i en JSON-fil som en Python dictionary. När antalet företag ökade och därmed mängden data, uppmärksammades att denna typ av datahantering inte längre var lämplig eftersom filerna blev för stora. Av denna anledning flyttades samtliga datapunkter istället till formatet dataframe, och sparades i en parquet-fil.

3.1.2 Databehandling

Efter sammanslagningen av datakällorna erhöles ett antal grundvariabler från CRSP och Compustat, vilka användes för att konstruera finansiella faktorer. De grundvariabler som användes i arbetet presenteras i tabell 14, medan de konstruerade finansiella faktorerna och deras beräkningar presenteras i tabell 15 i Appendix A.

De finansiella faktorerna winsoriserades mellan första och nittionionde percentilen för att minska påverkan från extrema observationer. En mer aggressiv winsorisering riskerar att dämpa ekonomiskt relevant information. Därefter z-standardiserades faktorerna tvärsnittligt enligt ekvation (3). Makro- och sentimentfaktorerna winsoriserades inte då extrema observationer ofta innehåller ekonomiskt relevant information snarare än att utgöra brus eller mätfel. Dessa variabler z-standardiserades istället över tid enligt ekvation (4).

För att underlätta vidare analys och modellträning sparades den behandlade datan i en separat parquet-fil. Den standardiserade datamängden användes därefter som indata till modellerna.

3.2 Modellkonstruktion

I detta avsnitt beskrivs hur modellen är uppbyggd, där syftet var att konstruera en modell som kan förutsäga framtida aktieavkastning baserat på observerade finansiella faktorer vid en given tidpunkt. Avsnittet är uppdelat i tre delar. I det första avsnittet beskrivs hur matriser konstrueras från datan. Därefter presenteras de linjära regressionsmetoder som har använts vid modellträning. Slutligen behandlas hur en modellprediktion görs med hjälp av de tränade modellerna.

3.2.1 Matriskonstruktion

Modellen är uppbyggd genom att valda parametrar i ett givet tidsintervall användes för konstruktion av matriser, där varje rad innehöll en specifik aktie vid en viss tidpunkt, medan kolumnerna innehöll de valda faktorkombinationerna. I detta steg filterades ogiltiga rader bort, och endast observationer med ett framtida pris och genomgående väldefinierade aktiefaktorer behölls. Därefter användes den konstruerade matrisen som indata till någon av de tillgängliga regressionsmetoderna.

3.2.2 Linjära regressionsmetoder

I modellen konstruerades fyra olika regressionsmetoder bestående av linjär regression (OLS), Ridge-regression, Lasso-regression och Elastic. OLS användes som en basmodell eftersom det är den mest grundläggande linjära regressionsme-

toden. För samtliga regressionsmetoder användes pythonbiblioteket Scikit-learn för enkel implementation av metoderna.

För modellerna som använde sig av regularisering, det vill säga Ridge, Lasso och Elastic Net, bestämdes regulariseringsparametern α med hjälp av 5-faldig korsvalidering. Detta gjordes med hjälp av inbyggda funktioner i Scikit-learn som valde de parametrar som minimerade prediktionsfelet. Därefter tränades modellen med den α -parameter som hade tagits fram. Den tränade modellen användes sedan för att prediktera framtida aktieavkastning för alla observationer i testdatamängden.

3.2.3 Modellprediktion

För prediktion av framtida aktieavkastning användes en prediktionsfunktion. Denna funktion tog emot testdata, alltså en mängd data inom ett givet tidsintervall som inte hade använts vid modellträningen, och konstruerade matriser på samma sätt som i avsnitt 3.2.1. Därefter användes den konstruerade testmatrisen som indata i den tränade modellen för att generera prediktioner av den framtida avkastningen. Avkastningen uttrycks relativt den genomsnittliga avkastningen för samtliga aktier i aktieurvalet vid samma tidpunkt, det vill säga som antalet procentenheter över eller under urvalets genomsnittliga avkastning under perioden. Slutligen utvärderades modellen för att undersöka hur väl den tränade modellen predikterade framtida aktieavkastning baserat på de val som gjorts.

3.3 Parameterväl

En viktig del i arbetet har varit vilken information och vilken träning som har använts i modellträningen. De valda parametrarna utgör både den indata som används i modellträningen och under vilka förutsättningar den används. Därför har en stor del av arbetet utgjorts av att testa olika kombinationer av indata för att på så sätt hitta den kombination av information som har gett störst prediktiv styrka. De parametrar som har testats under arbetet är vilka faktorkombinationer som har använts under träningen, tidsperiod som datan är hämtad ifrån, vilken regressionsmetod som har använts vid modellträning, vilken prediktionshorisont som har använts, samt branschindelning.

3.3.1 Faktorkombinationer

Faktorkombinationerna som har använts i modellträningen har varit uppbyggda av 22 stycken z-standardiserade finansiella faktorer, där hela och delmängder av dessa faktorer har använts i träningen. Gruppen där alla 22 faktorer har använts kallas härnäst för *z-gruppen*, och förkortas ZG. Mer information om dessa kan läsas i tabell 15 i Appendix A.

Faktorerna har även delats upp i åtta faktorgrupper där z-standardiserade finansiella faktorer som tillhört samma område har adderats och medelvärdesbildats med hjälp av ekvation (5). Dessa faktorgrupper är kategoriserade inom värde, momentum, kvalitet, storlek, tillväxt, omslag, likviditet och risk, och presenteras i tabell 16 i Appendix A. Gruppen som består av samtliga åtta faktorgrupper kallas härnäst för *faktorgruppsuppsättning*, och förkortas till FGU. Motivering och validering av FGU redovisas i Appendix B.

Dessa faktorgrupper har också multiplicerats med nio stycken makro- och sentimentfaktorer, med hjälp av ekvation (6), vilket resulterade i en grupp som kallas *interaktionsgruppen* eller IG, som innehåller dessa 72 interaktionstermer plus de åtta ursprungliga faktorgrupperna. Samtliga makro- och sentimentfaktorer presenteras i tabell 17 i Appendix A. Motivering och validering av IG redovisas i Appendix C.

3.3.2 Hyperparametrar

Utöver regressionsmetod och faktorkombination finns det fler parametrar som påverkar resultaten i en prediktionsmodell. Dessa styr hur modellen extraherar och hanterar mätdata, och kommer i slutändan att påverka modellens förutsägelser. Regressionsmetod kommer härnäst hänvisas till som en hyperparameter, och de andra hyperparametrarna som varierades var prediktionshorisont, tidsfönster och branschval. Branschvalen utvecklas mer i delavsnitt 3.3.3.

Prediktionshorisonten dt påverkar direkt målvariabeln Y , som används som korrekt avkastning för aktien under dt antal månader in i framtiden. Om $dt = 1$ så tränas modellen på att förutspå aktiens utveckling under kommande månad. Om $dt = 12$ tränas den mot utvecklingen under kommande år. Detta kan jämföras med långsiktig och kortsiktig utveckling. För att undersöka hur den prediktiva styrkan förändras mot utvecklingens prediktionshorisont så itererades testerna över $dt = 1, 3, 6, 9, 12$. Målvariabeln Y normaliseras efter medelutveckling inom aktieuniversumet för att inte låta olika lönsamma år påverka träningen, vilket kan jämföras med att utvecklingen mäts utöver en portfölj med jämn fördelning.

Tidsfönstret beskriver hur lång period träningsdatan är inhämtad ifrån, samt vilka specifika år. Då börsen följt olika mönster historiskt är det rimligt att göra en avvägning mellan relevans i närtid och robusthet i långsiktigt mätdata, vilket ledde till att testperioder om 2, 5 och 10 år testades för varje parameterkombination. Eftersom dessa tidsfönster kan testas flera gånger under det 20-årsspann som datamängden utgjorde, kunde flera i övrigt identiska tester jämföras med oberoende datapunkter.

3.3.3 Branschindelning

För de branschspecifika testerna delades bolagen in i breda branschgrupper baserat på respektive bolags SIC2-kod. Syftet med indelningen var att undersöka om modeller tränade på data från mer homogena aktieurval kunde identifiera andra eller starkare prediktiva samband än modeller tränade på hela det valda aktieuniverset. Branschindelningen applicerades efter att den framtida avkastningen och den marknadsrelativa överavkastningen hade konstruerats, vilket innebär att avkastningsmålet även i branschtesterna definieras relativt hela urvalets genomsnittliga avkastning vid respektive tidpunkt.

Efter indelningen varierade antalet tillgängliga bolag tydligt mellan branscherna. I genomsnitt per månad innehöll grupperna cirka 108 bolag för teknik, 89 för konsumentvaror och tjänster, 89 för finans och 68 för hälsovård. Därefter följde industri med cirka 41 bolag, övrigt med 34, olja och gas med 33, energi med 24 och material med omkring 5 bolag per månad. Detta visar att branschindelningen inte utgör en helt jämnt fördelad uppdelning av det ursprungliga universumet, som totalt omfattar knappt 800 bolag. Skillnaden kan bero på att vissa bolag saknar tillräcklig branschklassificering, har kortare datahistorik eller faller bort i samband med datakonstruktionen. Vidare analys gjordes enbart på teknik, konsumentvaror och tjänster, finans och hälsovård. För få bolag i ett urval innebär att ett fåtal bolag uteslutande driver portföljens utveckling och modellens prediktiva mått vilket gör att ett större urval krävdes för representativa, försvarbara och rättvisa resultat. Varje kombination av bransch, faktorkombination, prediktionshorisont, regressionsmodell och tidsfönster körs 8 gånger med testperiod för att finna de kombinationer som genomgående är mest stabila och minst utsatta för enbart slump och enskilda bra körningar.

3.4 Modellutvärdering

För att kunna utvärdera den tränade modellen har flera typer av valideringsfunktioner använts för att undersöka hur väl modellen har predikerat framtida aktieavkastning. Dessa valideringsfunktioner har använts vid analys av samtliga modeller, och presenteras nedan.

För att hitta en optimal modell utifrån förutsättningarna tränades klassmetoden mot samtliga kombinationer av regressionsmetoder, faktorkombinationer, prediktionshorisont (dt) och tidsfönster, vilka bildade 180 unika kombinationer. Dessa kombinationer utvärderades emot korrelationsmått som beskrivs i avsnitt 2.5.1 och emot portföljmått som beskrivs i avsnitt 2.5.2, för att utvärdera den prediktiva och ekonomiska relevansen av de prediktiva modellerna. Den konstruerade portföljen varifrån måtten hämtades var en så kallad long/short-portfölj, där tillgångar med hög förväntad avkastning kombinerades med korta positioner i tillgångar med låg förväntad avkastning. För mer information om hur portföljen var uppbyggd, se avsnitt 2.6.1. Samtliga resultat dokumenterades med modulen MLflow, som lagrar tester och förenklar gruppering och jämförelse.

Eftersom den totala datamängden täcker ett tjugofårigt tidsspänn kunde varje tidsfönster på 2, 5 och 10 år genomföras mot olika sammanhängande år. Varje kombination av parametrar testades totalt 8 gånger under olika tidsperioder, och på så sätt kunde robustheten av en kombination utvärderas. Om en kombination genererade hög avkastning kontinuerligt, stärkte detta trovärdigheten i även framtida prediktioner. Om den genererade sämre avkastning för tidiga år, men bättre avkastning för senare år kunde även detta vara ett tecken på relevans i samtiden.

Utav måtten som användes fästes extra vikt vid annualiserad avkastning och korrelation, då ett av arbetets mål är att hitta undervärderade aktier som genererar hög avkastning. Hög korrelation mellan prediktion och korrekt utveckling tyder på att modellen hittat ett användbart mönster som används i prediktionen.

Parameterkombinationer som gav starkt varierande resultat betraktades ej som robusta, och hög avkastning betraktades som en anomali om det följdes av låg avkastning för närliggande tidsperioder. Pålitligheten för en modell karaktäriseras av kontinuitet i resultaten, vilket prioriterades högt i utvärderingen. På detta vis kunde parameterkombinationer med hög potential urskiljas.

Även modellernas genomsnittliga prestation mellan olika branscher jämfördes. Syftet med detta steg var att identifiera inom vilka branscher modellerna uppvisat störst potential. Efter den övergripande branschjämförelsen valdes de mest lovande branscherna ut för en mer detaljerad analys. I detta steg delades resultaten upp efter prediktionshorisont, vilket möjliggjorde undersökning om modellens förklarings- och rangordningsförmåga varierat beroende på hur långt fram i tiden aktieavkastningen har predikerats. För varje bransch och prediktionshorisont analyserades samma uppsättning mått som i den övergripande jämförelsen. Detta gjorde att en bedömning av en branschs goda genomsnittliga resultat var stabilt över flera horisonter eller om det främst drevs av en specifik prediktionshorisont. De framstående kombinationerna analyserades vidare på faktorkombinations-, regressions-, och tidsfönsternivå.

Slutligen isolerades unika parameterkombinationer inom branscherna, och jämfördes. Den slutliga modellstrategin valdes inte enbart utifrån högst portföljvinst, utan utifrån en samlad bedömning av portföljmått och prediktiva mått. En

modellkombination betraktades som mer attraktiv om den samtidigt uppvisat positiv annualiserad portföljavkastning, positiv Sharpe-kvot, hög hit rate samt positiva korrelations- och Z-score-mått. Genom att kombinera dessa mått kunde modeller särskiljas som antingen gav starka portföljresultat i enskilda fall eller uppvisade en mer robust prediktiv relation mellan faktorvariabler och framtida relativ avkastning.

Denna stegvisa utvärderingsmetod innebar att analysen gick från ett brett urval till en allt mer specifik modellstrategi. På så sätt valdes den slutliga strategin utifrån både ekonomisk användbarhet och statistisk/prediktiv evidens, snarare än utifrån en isolerad toppnotering i ett enskilt mått.

4 Resultat

Under arbetets gång har tester utvärderats kontinuerligt för att styra utvecklingen, och för att hitta problem eller anomalier som tyder på brister i koden. Resultaten som redovisas nedan är hämtade från den slutgiltiga versionen av koden, och presenteras ur olika aspekter. Resultaten i detta avsnitt ska ses som preliminära och används främst för att identifiera mönster mellan faktorkombinationer, prediktionshorisonter, regressionsmetoder och portföljutfall. Eftersom ett stort antal modellkombinationer har utvärderats bör enskilda toppresultat tolkas med försiktighet. Fokus ligger därför inte enbart på högst observerad avkastning, utan på kombinationer där portföljmått och prediktiva mått samverkar.

4.1 Parameteranalys

För att undersöka hur olika hyperparametrar påverkar modellens prediktions- och korrelationsförmåga, har dessa hyperparametrar isolerats och utvärderats. Först undersöktes de isolerade hyperparametrarna faktorkombination, träningsfönster och prediktionshorisont. Därefter grupperades testerna i olika kombinationer av hyperparametrar för att slutligen undersöka hur valet av regressionsmetod påverkade den prediktiva styrkan hos modellerna.

Först undersöktes resultaten då tre olika faktorkombinationer, som beskrivs under avsnitt 3.3.1, tillsammans med olika kombinationer av hyperparametrar användes under modellträningen. Faktorkombinationerna benämns som interaktionsgrupp (IG), Z-grupp (ZG) och faktorgruppsuppsättning (FGU). I tabell 2 presenteras medelresultaten för testerna av faktorkombinationerna, där dessa har körts mot varje kombination av hyperparametrar samma antal gånger. Det går att urskilja att IG har en högre korrelation än ZG och FGU, men i övrigt är resultaten lika. Observera att varje medelvärde innehåller resultaten av 400 körningar, och att faktorkombinationerna kan ha mycket olika resultat i kombination med olika hyperparametrar. För en noggrannare undersökning krävs ytterligare specificering, vilket följer efter en utvärdering av hyperparametrarna.

Tabell 2: Resultat av modellträningen presenteras, där olika faktorkombinationer har utvärderats.

Faktorkombination	Ann. avkastning	Z-score	Hit rate	Korrelation
IG	-2%	0,52	0,50	0,00
ZG	-2%	-0,50	0,49	-0,02
FGU	-2%	-0,87	0,51	-0,02

Därefter grupperas testerna utefter hyperparametern tidsfönster, och utvärderas mot korrelation, Z-score, annualiserad avkastning och hit rate. I tabell 3 finns positiva värden på motsvarande punkter då modellerna tränas mot ett medellångt tidsfönster på fem år. Observera att även här är värdena medelvärden över flera tester, men fungerar vägledande för tidsfönstrets robusthet.

Tabell 3: Resultatet av modellträningen presenteras, där olika tidsfönster har utvärderats.

Antal tränade år	annualiserad avkastn.	Z-score	Hit rate	Korrelation
10 år	-1%	0,42	0,50	0,00
5 år	+1%	0,69	0,58	0,01
2 år	-5%	-1,77	0,44	-0,04

På samma sätt grupperas testerna efter prediktionshorisont (dt) i tabell 4 och regressionsmetod i tabell 5. I tabell 4 avläses att $dt = 9$ genererat högst avkastning, medan $dt = 12$ genererat högst Z-score. Då regressionsmetoderna i tabell 5 producerar resultat med mindre variation, bedöms prediktionsstyrkan vara mer beroende av val av tidsfönster, faktorgrupp och prediktionshorisont.

Vid djupare analys av parameterresultaten grupperades testerna initialt i kombinationer av faktorkombination och prediktionshorisont. Dessa bildar 20 grupper, där de 5 högsta i Z-score och annualiserad avkastning presenteras i tabell 6. I dessa deltabeller framgår ett mönster, IG tenderar att skapa hög korrelation i modellen och $dt = 9$ har genererat hög avkastning. Som konsekvens är kombinationen IG och $dt = 9$ med i båda tabellerna.

Tabell 4: Resultaten för modellträningen presenteras, där olika prediktionshorisonter, dt , har utvärderats.

dt	annualiserad avkastn.	Z-score	Hit rate	Korrelation
12	-1%	0,94	0,52	0,00
9	+2%	-0,66	0,56	-0,03
6	-3%	-0,24	0,49	-0,01
3	-5%	-0,73	0,43	-0,01
1	-4%	-0,71	0,50	-0,01

Tabell 5: Resultaten för modellträningen presenteras, där fyra olika regressionsmetoder har utvärderats. OLS är förkortningen för Ordinary Least Squares och EN är förkortningen för Elastic Net.

Regressionsmetod	annualiserad avkastn.	Z-score	Hit rate	Korrelation
OLS	-2%	-0,16	0,51	-0,01
Lasso	-2%	-0,36	0,50	-0,01
Ridge	-2%	-0,27	0,50	-0,01
EN	-2%	-0,34	0,48	-0,01

Tabell 6: Resultat för modellträningen presenteras, där olika kombinationer av prediktionshorisonter, dt , och faktorkombinationer har utvärderats.

(a) Högst annualiserad avkastning

Faktorkomb.	dt	Ann. avkast.	Z-score	Hit rate
FGU	9	+3%	-1,62	0,58
IG	9	+3%	0,74	0,52
ZG	9	+1%	-1,10	0,58
IG	12	-1%	2,24	0,51
FGU	12	-1%	0,21	0,57

(b) Högst Z-score

Faktorkomb.	dt	Ann. avkast.	Z-score	Hit rate
IG	12	-1%	2,25	0,57
IG	9	+3%	0,74	0,52
IG	6	-3%	0,69	0,49
ZG	12	-2%	0,41	0,47
FGU	12	-1%	0,21	0,57

Hyperparametern tidsfönster lades till som gruppvariabel, och presenteras i tabell 7. Mätvärdet standardavvikelse (σ) får nu signifikans, eftersom prediktionshorisonter och tidsfönster är separerade. Övre halvan av tabell 7 består av högpresterande kombinationer inom korrelationsmått, och den undre halvan består av de kombinationer som genererade högst avkastning. Där urskiljs ytterligare ett mönster, långa tidsfönster genererar högt Z-score medan medellånga tidsfönster genererar hög avkastning. Faktorkombination IG dominerar fortfarande bland korrelationsmått och $dt = 9$ dominerar fortsatt inom hög avkastning. Två grupper finns med i båda topplistorna, IG med $dt = 9$ och tidsfönster 10 år samt IG med $dt = 12$ och tidsfönster 5 år. Både ZG och FGU presterar kontinuerligt lågt i båda kategorierna, och avvikelser är ovanliga även om de förekommer.

Tabell 7: Resultaten presenteras från modellträningen där högpresterande kombinationer av faktorkombination, prediktionshorisont, dt , och tidsfönster har utvärderats. Den övre tabelldelen presenterar högpresterande kombinationer sett från korrelation, och den undre tabelldelen presenterar högpresterande kombinationer sett från högst avkastning.

Faktorkomb.	dt	Tidsfönster	Ann. avkast.	Z-score	Hit rate	Korrelation	σ
IG	9	10 år	+4%	4,13	0,62	0,03	0,07
IG	12	10 år	-5%	4,03	0,49	0,04	0,10
IG	6	10 år	+1%	3,27	0,46	0,03	0,04
IG	12	5 år	+6%	3,05	0,63	0,05	0,21
FGU	12	5 år	+1%	2,69	0,80	0,04	0,04
IG	9	5 år	+8%	0,37	0,65	0,01	0,10
FGU	9	5 år	+8%	0,07	0,67	0,00	0,03
IG	12	5 år	+6%	3,05	0,63	0,05	0,21
ZG	9	5 år	+6%	1,21	0,69	0,02	0,04
IG	9	10 år	+4%	4,13	0,62	0,03	0,07

Slutligen användes även val av regressionsmetod till gruppering, och grupperna som bildades representerar således enskilda modeller. Till denna analys användes endast modeller som presterade högt inom både korrelation och avkastning. Varje parameterkombination har körts på åtta olika tidsperioder då tidsfönstret kunde användas rullande på den totala 20-årsperioden, och värdena som visas är medelvärderade inom det spannet. Dessa presenteras i tabell 8 utan inbördes ordning tillsammans med en uppsättning ekonomiska och prediktiva mått. I tabell 8 har också robustheten tagits hänsyn till utöver medelvärdet. Robustheten syftar på kontinuiteten i modellens prestanda, vilket innebär att modeller med samma parameteruppsättning, men med kraftigt skilda resultat på olika tidsperioder, inte visas. I denna tabell uteblir faktorkombinationen FGU helt då modeller som använde FGU utkonkurrerades av övriga faktorkombinationer på samtliga mått. Det gäller även prediktionshorisonten $dt = 1, 3$ och tidsfönstret 2 år, som överträffades av alternativa parametrar.

Sammantaget skildrar tabell 8 ett urval av relevanta modeller som presterar olika bra inom olika användningsområden,

Tabell 8: Medelresultat presenteras vid modellträning av specifika modeller över 8 tester.

Faktorkomb.	dt	Tidsfönster	Reg.	Z-score	Ann. avk.	Hit rate	Sharpe	Korrelation	σ
IG	9	10 år	Lasso	4,48	+4%	0,68	0,72	0,04	0,06
			E.N.	4,47	+3%	0,61	0,61	0,04	0,06
			Ridge	4,37	+4%	0,67	0,63	0,04	0,07
	12	5 år	E.N.	2,22	+5%	0,50	0,64	0,05	0,18
ZG	9	5 år	OLS	0,82	+7%	0,75	0,82	0,01	0,05
	12	10 år	OLS	2,55	+4%	0,61	0,47	0,02	0,09
	6	5 år	Lasso	2,89	+4%	0,65	0,75	0,04	0,02

men där IG presterar konsekvent högst inom prediktiva mått. I nästa avsnitt kommer modellernas ekonomiska prestanda inom olika branscher presenteras mer ingående.

4.2 Branschspecifik analys

För att undersöka om modellens prediktiva förmåga påverkas av hur homogent ett aktieuniversum är, tränas även modellerna på branschindelad data. Utvärderingen är baserad på metoden som lyfts i avsnitt 3.4. Först jämförs resultaten på branschnivå, därefter bryts de mest intressanta branscherna ned efter faktorkombination, sedan prediktionshorisont, därefter utifrån regressionsmodell och slutligen efter tidsfönster. Slutligen resulterar det i ett fåtal kombinationer av bransch, faktorkombination, prediktionshorisont, regressionsmodell och träningsfönster som genomgående anses mest välpresterande. De fullständiga tabellerna för respektive steg återfinns i Appendix D, medan resultatdelen endast redovisar de urval som ligger till grund för den fortsatta analysen. Fyra stycken branscher har analyserats, konsumentvaror och tjänster, finans, hälsovård och teknik. Övriga branscher har färre bolag än vad som krävs för att ge meningsfulla resultat.

Tabell 9 visar de kombinationer av bransch och faktorkombination som valdes ut för vidare analys. Urvalet av branscher baserades först på att branschen ska ha tillräckligt många bolag för att ha givande resultat. Urvalet av kombinationer med faktorkombinationer gjordes sedan baserat på portföljmått och prediktiv styrka, där detta gäller för hela analyskedjan.

Tabell 9: Utvalda kombinationer av bransch och faktorkombination för vidare analys.

Bransch	faktorkombination	Portföljmått			Prediktiv styrka					Antal körningar
		Ann. avk.	Sharpe	Hit rate	Mean IC	IC IR	Positiv IC	Korr.	Z-score	
Konsumentvaror och tjänster	IG	2,52%	1,0537	50,28%	0,0251	0,1386	55,34%	0,0065	0,3318	437
Konsumentvaror och tjänster	ZG	-2,55%	0,9763	48,81%	0,0020	0,0411	50,65%	-0,0071	0,6808	440
Finans	IG	-13,77%	-0,5049	41,66%	-0,0287	-0,1400	45,54%	-0,0406	-0,7848	437
Hälsovård	FGU	-1,57%	0,1496	46,62%	0,0151	0,1425	52,69%	0,0040	0,5939	440
Hälsovård	ZG	-0,84%	0,2473	47,99%	0,0020	0,0329	50,37%	0,0030	0,6473	440
Teknik	IG	-1,07%	-0,3221	48,13%	0,0054	0,0196	50,97%	0,0022	0,2084	437

Resultaten i tabell 9 visar de kombinationer av bransch och faktorkombination som valdes ut för vidare analys. Konsumentvaror och tjänster med IG framstår som den generellt mest konsekventa kombinationen av positiv portföljprestation och prediktiv styrka. Branschen har positiv annualiserad portföljavgkastning, positiv Sharpe-kvot och positiva prediktiva mått. Konsumentvaror och tjänster med ZG har negativ avkastning men hög Sharpe och delvis positiv prediktiv styrka. Kombinationerna ZG och FGU inom hälsovård behålls för vidare analys då de uppvisar positiv prediktiv styrka, trots negativ annualiserad avkastning. Finans med IG visar generellt på svaga portföljmått och prediktiv styrka men hade enskilda kombinationer som drev resultatet positivt och behålls för vidare analys. Kombinationerna innehållande Teknik visar sämre resultat och valdes inte ut för vidare analys.

Efter det första urvalet bryts resultaten ned utifrån ovan presenterade kombinationer tillsammans med framstående prediktionshorisonter. Syftet är att undersöka om de aggregerade branschresultaten är stabila över flera horisonter eller om de främst drivs av en specifik prediktionshorisont. Tabell 10 presenterar de kombinationer av bransch och prediktionshorisont som valdes ut för vidare analys på regressionsnivå.

Tabell 10: Utvalda kombinationer av bransch, faktorkombination och prediktionshorisont för vidare analys på regressionsnivå.

Bransch	faktorkombination	dt	Portföljmått			Prediktiv styrka					Antal körningar
			Ann. avk.	Sharpe	Hit rate	Mean IC	IC IR	Positiv IC	Korr.	Z-score	
Finans	IG	1	9,24%	0,3215	53,90%	0,0442	0,1533	55,69%	0,0231	0,2861	88
Konsumentvaror och tjänster	IG	1	6,39%	0,2714	53,95%	0,0075	0,0459	50,92%	0,0153	0,6487	88
Konsumentvaror och tjänster	IG	3	3,28%	0,3276	51,85%	0,0294	0,2101	55,57%	0,0161	0,6325	88
Konsumentvaror och tjänster	ZG	12	-2,13%	-0,2988	45,83%	0,0111	0,5529	50,91%	0,0049	1,5215	88
Hälsovård	FGU	6	1,54%	0,4372	48,66%	0,0252	0,2080	54,59%	0,0190	1,0041	88
Hälsovård	ZG	6	1,34%	1,2240	52,93%	0,0091	0,0202	52,94%	0,0219	1,2201	88

Tabell 10 visar att flera av resultaten drivs av specifika prediktionshorisonter. Finans med IG och en månads prediktionshorisont visar här det starkaste portföljresultatet. Konsumentvaror och tjänster med IG och en respektive tre månaders prediktionshorisont framstår som balanserade alternativ med positiva portföljmått och positiv prediktiv styrka. Konsumentvaror och tjänster med ZG och 12 månaders prediktionshorisont har negativa portföljmått men inkluderas till följd av tydlig prediktiv evidens. Hälsovård uppvisar sina mest intressanta resultat för FGU och ZG vid sex månaders prediktionshorisont med positiva portföljmått, trots lägre än ovan nämnda kombinationer, samt prediktiv styrka.

I nästkommande steg bryts de utvalda kombinationerna ned efter regressionsmodell. Syftet är att identifiera om resultaten drivs av en specifik modelltyp och därmed kunna välja en mer konkret investeringsstrategi och starka prediktiva modeller. Tabell 11 visar de huvudsakliga slutkandidaterna efter denna nedbrytning.

Tabell 11: Huvudsakliga kandidater efter nedbrytning på bransch, faktorkombination, prediktionshorisont och regressionsmodell.

Bransch	faktorkombination	dt	Regression	Portföljmått			Prediktiv styrka					Antal körningar
				Ann. avk.	Sharpe	Hit rate	Mean IC	IC IR	Positiv IC	Korr.	Z-score	
Finans	IG	1	Elastic Net	17,61%	0,5589	55,45%	0,0730	0,2521	58,52%	0,0578	0,8513	22
Finans	IG	1	Lasso	11,79%	0,4003	53,67%	0,0633	0,2198	55,76%	0,0521	0,7078	22
Konsumentvaror och tjänster	IG	3	OLS	10,34%	0,7805	55,26%	0,0372	0,2685	56,81%	0,0240	0,7906	22
Konsumentvaror och tjänster	IG	1	Ridge	10,24%	0,4212	55,52%	0,0123	0,0751	53,31%	0,0165	0,6856	22
Konsumentvaror och tjänster	ZG	12	OLS	1,52%	0,6738	55,68%	0,0362	0,7269	59,42%	0,0306	2,5173	22
Hälsovård	FGU	6	Ridge	3,86%	0,1670	51,76%	0,0154	0,1574	55,27%	0,0201	0,9625	22
Hälsovård	ZG	6	OLS	3,29%	1,9134	60,14%	0,0078	-0,0073	54,28%	0,0264	1,3994	22

Tabell 11 visar de huvudsakliga kandidaterna efter analys på regressionsmodell. Finans med IG, en månads prediktionshorisont och Elastic Net-regression ger det starkaste portföljutfallet, med högst annualiserad avkastning bland de utvalda kombinationerna. Kombinationen har även positiva prediktiva mått, men Z-score är måttligt, vilket gör att resultatet bör tolkas som främst portföljdrivet. Konsumentvaror och tjänster med IG, tre månaders prediktionshorisont och OLS-regression framstår som en mer balanserad kombination, eftersom den kombinerar hög positiv portföljavkastning med prediktiv styrka. Konsumentvaror och tjänster med ZG, tolv månaders prediktionshorisont och OLS-regression har betydligt lägre portföljavkastning, men uppvisar starkast prediktiv evidens genom hög IC IR och högst Z-score bland kandidaterna.

Tabell 12 presenterar tre intressanta slutkandidater i form av färdiga modellstrukturer som levererat både starka portföljmått och hög prediktiv styrka.

Tabell 12: Utvalda slutkandidater efter nedbrytning på bransch, faktorkombination, prediktionshorisont, regressionsmodell och tidsfönster.

Bransch	faktorkombination	dt	Regression	Tidsfönster	Portföljmått			Prediktiv styrka					Antal körningar
					Ann. avk.	Sharpe	Hit rate	Mean IC	IC IR	Positiv IC	Korr.	Z-score	
Finans	IG	1	Elastic Net	2 år	35,10%	0,9687	60,42%	0,0970	0,3484	59,72%	0,1183	1,7794	8
Konsumentvaror och tjänster	IG	3	OLS	2 år	26,03%	1,9290	65,63%	0,0523	0,4008	60,00%	0,0533	1,4905	8
Konsumentvaror och tjänster	ZG	12	OLS	10 år	4,98%	0,6573	71,88%	0,0984	0,7767	76,31%	0,1141	6,0794	8

I tabell 12 presenteras två kombinationer som främst är portföljdrivna och en kombination främst driven av stark prediktiv evidens. Finans med IG, en månads prediktionshorisont, Elastic Net och två års tidsfönster levererar högst annualiserad överavkastning kombinerat med medelgod sharpekvot, hit rate och genomgående positiv prediktiv styrka. Konsumentvaror och tjänster med IG, tre månaders prediktionshorisont, OLS och två års prediktionshorisont genererar hög annualiserad avkastning, hög sharpekvot, god hit rate och genomgående positiv prediktiv styrka men något lägre prediktiv evidens än föregående kombination. Konsumentvaror och tjänster med ZG, tolv månaders prediktionshorisont, OLS och tio års tidsfönster ger markant lägre annualiserad avkastning än de två föregående kombinationerna. Med det sagt är portföljmåtten ändå positiva, kombinerat med en prediktivt stark modell där främst Z-score och den procentuellt positiva IC sticker ut positivt i förhållande till de två föregående kombinationerna. Det är den enda av de tre slutkandidaterna som överstiger ett Z-score på 1,96. För en visuell jämförelse av de tre slutkandidaternas portföljprestation och prediktiva styrka, se figur 5 i Appendix D.

4.3 Jämförelse av portföljkonstruktioner

För att jämföra olika typer av portföljkonstruktioner har fyra olika vikttningsstrategier undersökts i syfte att finna den bäst lämpade för arbetets prediktionsmodeller. Enbart portföljmått jämförs eftersom portföljkonstruktionen enbart påverkar hur aktier handlas, inte hur väl modellen faktiska prediktioner. Tabell 13 visar genomsnittlig avkastning för fyra olika portföljkonstruktionerna baserat på resultaten av de tre kombinationer av bransch, prediktionshorisont och regressionsmodell som presenterades i tabell 11.

Tabell 13: Övergripande jämförelse av portföljkonstruktioner över samtliga 24 körningar.

Portföljvariant	Medel ann. avk.	Median ann. avk.	Positiva körningar	Medel Sharpe	Medel hit rate
Likviktad top/bottom 10%	1,16%	3,04%	14/24	0,205	55,7%
Rankviktad top/bottom 10%	-1,61%	-1,86%	11/24	0,099	51,8%
Linjärt signalviktad top/bottom 10%	-5,51%	-7,33%	8/24	-0,003	48,9%
Sigmoidviktad top/bottom 10%	-2,76%	-5,51%	9/24	0,072	51,7%

I tabellen framgår att den likviktade top/bottom-portföljen har högst genomsnittlig annualiserad avkastning, högst medianavkastning, flest positiva körningar, högst genomsnittlig Sharpe-kvot och högst genomsnittlig hit rate. Rankviktningen ger näst högst Sharpe-kvot och hit rate, medan både linjär signalviktning och sigmoidviktning uppvisar lägre genomsnittlig annualiserad avkastning. Den linjära signalviktningen har lägst värden i samtliga redovisade avkastnings- och riskjusterade mått.

5 Diskussion

I detta avsnitt diskuteras först svårigheten med prediktiva modeller till följd av brusiga signaler, för att därefter behandla riskerna med portföljer konstruerade av ett lågt antal bolag. Därefter analyseras testresultaten och de korresponderande modellerna de resulterade i, både för breda och branschspecifika modeller. Slutligen jämförs modeller baserade på ett brett urval av aktier med branschspecifika modeller ur ett investeringsperspektiv, följt av en diskussion om transaktionskostnader och valet av portföljkonstruktion baserat på resultaten som presenterades i avsnitt 4.3.

5.1 Signalsökning

Att hitta under-/övervärderade värdepapper via linjär regression kan liknas vid att hitta en svag signal dold i brus. Framgången som olika modeller hade med denna uppgift varierade, och ledde som regel till tre olika typer av resultat som dokumenterats under projektets gång, där modellen hittade antingen en svag signal, en falsk signal eller en fungerande signal.

Om modellen inte fann någon prediktiv signal mellan faktorkombinationen och målvariabeln så pressades koefficienterna mot 0 av de linjära regressionsmetoderna. Detta innebär att den säkraste förutsägelsen för modellen blir medelvärdet av utvecklingen - vilket i beräkningen av målvariabeln alltid sätts till 0. Detta kunde identifieras via måttet standardavvikelse.

Modellen kunde också hitta en stark, men falsk signal. Detta kan ske vid överanpassning eller då rörelser som egentligen inte kan förklaras av faktorkombinationen dykt upp på ett sätt så att det förefaller ligga prediktiv styrka i dem. Dessa identifierades genom svag korrelation, trots eventuell hög avkastning som ändå vid enstaka tillfällen kan uppstå.

Återstående är då modellerna som lyckats finna en fungerande prediktiv signal i faktorkombinationerna. Ju större korrelationsmått, desto större del av förändringarna i rörelserna har modellen hittat en förklaring till. En intressant observation kring detta är att det vid tillfällen uppstår en negativ korrelation. Detta ska inte misstas för en rent falsk signal, eftersom det är amplituden på korrelationen som avgör prediktionsstyrkan i modellen. Sannolikt sker detta också på grund av överanpassning och brus, men rent matematiskt har modellen en förutsäggande egenskap. Däremot så har modellen misslyckats med sitt syfte, och dessa modeller räknas som dåliga eftersom de under testperioden i regel genererar låg avkastning.

Flertalet mått har använts för att kunna identifiera och skilja fungerande positiva signaler från övriga, men då den korrekta signalen är sänkt i brus kan även valideringstesterna komma att bli missvisande. Målet har då varit att eftersöka parameterkombinationer som kontinuerligt har robusta resultat, men med hänsyn till att antalet unika parameterkombinationer som testats är 180 och att de enbart testats åtta gånger vardera, kan det inte uteslutas att även falska signaler skulle kunna generera goda medelresultat vid enskilda tillfällen på ett missvisande sätt.

5.2 Risker med lågt antal bolag i en portfölj

En begränsning med branschspecifika modeller, likt i detta arbete, är att de kan bestå av ett mindre urval aktier. Eftersom portföljkonstruktionen bygger på att likviktat köpa de 10 procent högst rankade aktierna och blanka de 10 procent lägst rankade aktierna, utifrån predikterad avkastning, innebär det att portföljen består av ett färre antal aktier. I sådana fall kan individuella aktier få stort genomslag på den uppmätta avkastningen, vilket gör det svårare att bedöma om utvecklingen beror på modellens prediktiva förmåga eller ett fåtal extrema observationer.

Detta är en viktig anledning till att analysen fokuserade på teknik, konsumentvaror och tjänster, hälsovård och finans. Övriga branscher löper större risk att portföljers avkastning uteslutande beror på en eller ett par aktiers extrema rörelser, och därmed är utsatt för slump i större utsträckning. Modeller skapade baserat på data från de fyra nyss nämnda bran-

scherna är däremot mer stabila som investerings- och prediktionsunderlag till följd av att de innehåller tillräckligt många bolag för att ge meningsfullt analysunderlag.

5.3 Tolkning av resultat för parametrar

Då faktorkombinationerna som har undersökts i modellträningen endast utgör en liten del av faktorerna som styr värdesättningen av aktier över tid, måste resultaten tolkas med försiktighet. Faktorerna som modellen ej har tillgång till skapar ett informationsglapp, framför allt då prediktionshorisonten är högre än $dt = 3$. I dessa fall har ny data och nya kvartalsrapporter publicerats för allmänheten, som ligger till grund för den aktuella prissättningen. Det innebär i teorin att modellen kan hitta goda tecken för under- eller övervärdering vid mättillfället, men även om denna brist i marknadseffektiviteten jämnar ut sig enligt modellens prediktioner kan ny information leda till en motsatt förändring. Det kan därför konstateras att det stora brus som existerar i mätdata också existerar i valideringsdata, och att bruset ökar i takt med ökad prediktionshorisont.

På grund av detta brus i resultaten eftersöks inte endast goda resultat för en specifik parameterkombination, utan även tecken på att parametrarna som används har god prediktionsstyrka även i andra modeller. Se exempelvis tabell 7 där faktorkombinationen FGU genererat högst avkastning, men då samma faktorkombination visat sig kontinuerligt svag i andra parameterkombinationer (se tabell 2) kan den höga avkastningen antas vara en anomali.

Att parameterkombinationer med högre prediktionshorisonter, såsom $dt = 9$ och $dt = 12$ genererat högst prediktiv förmåga och avkastning (se tabell 8) trots det ökande bruset är anmärkningsvärt. En förklaringsmodell skulle kunna vara att modellen har lättare att hitta tecken på långsiktig utveckling, vilket egentligen också är en typ av under-/övervärdering om denna långsiktiga utveckling förbises vid värderingstillfället. Kortsiktiga svängningar, som kan bero på mediala händelser, desinformation eller annat utanför modellens mätdata, har också fler perioder att jämna ut sig över.

Att $dt = 9$ genererar högre avkastning än $dt = 12$ är också en intressant observation. Detta skulle kunna tillskrivas symmetrin i $dt = 12$, då portföljen köper och säljer aktier samma månad varje år. På grund av svaga årliga mönster som börserna uppvisat historiskt skulle detta kunna vara till portföljens nackdel. Däremot så tyder den starka prediktionsstyrkan på att portföljen skulle kunna generera bättre resultat ifall den använde sig av en annan metod, eller köpte in sig under en annan månad.

Vid närmare observation av tidsfönstrets betydelse i tabell 3, framgår att det kortaste tidsfönstret genererat lägst resultat. I dessa modeller kan bruset, eller mycket kortvariga rörelsemönster, ha givits för stor vikt inför framtida prediktioner vilket brukar kallas överanpassning. Om mer data använts vid träningen hade detta eventuellt kunnat undvikas. I tabell 7 saknas det korta tidsfönstret helt, och endast det medellånga och långa tidsfönstret återfinns. Ur samma tabell går det också att utläsa en skillnad i σ för modeller som endast skiljer sig på punkten tidsfönster. Då faktorkombinationen IG och prediktionshorisonten $dt = 9$ tränas mot ett medellångt tidsfönster genereras högre standardavvikelse, jämfört med det långa tidsfönstret. Detta är logiskt då modellen under den medellånga träningsperioden har färre mätpunkter att ta hänsyn till, och således lättare att hitta samtida mönster. Korrelationsförändringen, som är högre för det medellånga tidsfönstret, talar emot att det skulle vara en överanpassning, men tillförlitligheten i korrelationen (Z-score) går ner då modellen valideras mot en mindre mängd data. Det medellånga och långa tidsfönstret kan alltså båda anses vara fördelaktiga, beroende på hur stor risk en eventuell investerare är villig att ta.

Slutligen tolkas regressionsmetodernas olika påverkan på modellprestandan. Vid första anblick i tabell 5 ser alla ut att prestera på liknande vis. När specifika modeller senare analyseras i tabell 8, framgår dock ett annat mönster. Faktorkombinationen IG genererar goda resultat mot regressionsmetoder som inte är OLS. Däremot verkar ZG tillsammans med OLS generera bättre resultat än med andra regressionsmetoder. Dessa två listade OLS-modeller bör dock tolkas med varsamhet, då den ena har ett lågt Z-score och den andra låg portföljkvalité (Sharpe) vilket kan komma från mycket pendlade resultat. Däremot tyder resultaten på att även OLS kan generera en prediktiv förmåga, men att mer brusreducerande regressioner såsom Lasso, Elastic Net och Ridge, kan generera mer konsekventa resultat i kombination med rätt parametrar.

5.4 Tolkning av resultat för branschindelning

Resultaten från den branschspecifika analysen visar att valet av strategi inte enbart bör baseras på högst observerad portföljavgkastning. Den stegvisa utvärderingsprocessen syftade därför till att identifiera modellkombinationer som inte bara genererade överavkastning, utan som även uppvisade prediktiv styrka och en tydligare relation mellan modellens signaler och framtida relativ avkastning. Analysen inleddes med att kombinationerna jämfördes efter bransch och faktorkombination, därefter efter prediktionshorisont, sedan efter regressionsmodell och slutligen tidsfönster. Efter denna analyskedja identifierades främst tre kombinationer som slutkandidater, (i) Finans med IG, en månads prediktionshorisont, Elastic Net-regression och två års tidsfönster, (ii) Konsumentvaror och tjänster med IG, tre månaders prediktionshorisont, OLS-regression och två års tidsfönster, samt (iii) Konsumentvaror och tjänster med ZG, tolv månaders prediktionshori-

sont, OLS-regression och tio års tidsfönster.

Finans med IG, en månads prediktionshorisont, Elastic Net-regression och två års tidsfönster uppvisade det starkaste portföljutfallet bland slutkandidaterna. Med en annualiserad överavkastning på 35,10%, Sharpe-kvot på 0,9687 och hit rate på 60,42%. Kombinationen uppvisade även positiva prediktiva mått, med Mean IC på 0,0970, IC IR på 0,3484 och positiv korrelation samt starkt positivt Z-score på 1,7794 (se tabell 12). Detta gör kombinationen intressant ur ett investeringsperspektiv, särskilt eftersom den visar att interaktionsgruppen, där faktorgrupper kombineras med makro- och sentimentvariabler, kan ge stark portföljprestation inom finans. Samtidigt bör resultatet tolkas med viss försiktighet. En annualiserad överavkastning på dryga 35 % är sannolikt inte reproducerbart och drevs troligtvis av en ovanligt stark period för finansbranschen i sin helhet. Z-score uppgår till 1,7794, vilket kombinerat med fler starka prediktiva mått tyder på att förklaringsgrad finns, och modellen är intressant ur ett investeringsperspektiv. Däremot överstiger den inte ett Z-score på 1,96 som används som en gräns för bekräftad statistisk evidens. Den korta prediktionshorisonten leder till fler rekonstruktionsperioder årligen och därmed ökade transaktionskostnader. Effekterna av transaktionskostnader diskuteras mer djupgående i avsnitt 5.7.

Konsumentvaror och tjänster med IG, tre månaders prediktionshorisont, OLS-regression och två års tidsfönster ger ytterligare en stark portföljkandidat. En annualiserad överavkastning på 26,03%, Sharpe-kvot på 1,9290 och en hit rate på 65,63% visar på starka portföljmått. Den höga överavkastningen kombinerat med en remarkabelt hög Sharpe visar på starka portföljkvaliteter drivet av en låg standardavvikelse. Även dessa resultat bör tolkas försiktigt eftersom reproducerbarhet är svåruppnått, men resultaten är intressanta ur analysperspektivet. Samtidigt är de prediktiva måtten genomgående positiva, med Mean IC på 0,0523, IC IR på 0,4008, positiv IC-andel på 60,00%, positiv korrelation och högt positivt Z-score på 1,4905 (se tabell 12). Trots lägre Z-score än de andra kombinationerna visar kombinationen att portföljresultatet inte enbart drivs av avkastning, utan även stöds av positiv rangordningsförmåga. Detta gör Konsumentvaror och tjänster med IG, tre månaders prediktionshorisont, OLS-regression och två års tidsfönster sammantaget till en av de mest intressanta strategierna. Den kombinerar relativt hög överavkastning med konsekvent prediktiv information. Inte heller här överstiger Z-score 1,96 men den prediktiva evidensen trendar positivt. Transaktionskostnaderna kommer för denna kombination att bli lägre än för Finans med 1 månads prediktionshorisont men högre än för nästa kandidat.

Konsumentvaror och tjänster med ZG, 12 månaders prediktionshorisont, OLS-regression och tio års tidsfönster ger en lägre annualiserad avkastning än de två föregående kombinationerna men en högre prediktiv styrka. Kombinationen har en annualiserad överavkastning på 4,98%, Sharpe-kvot på 0,6573 och hit rate på 71,88%. Den prediktiva styrkan syns i form av mean IC på 0,0984, IC IR på 0,7767, 76,31% positiv IC, positiv korrelation och positivt Z-score på 6,0794 som är avsevärt högre än de två ovan presenterade kombinationerna, från tabell 11. Detta tyder på att modellen i denna kombination fångar en mer stabil relation mellan z-standardiserade faktorvariabler och framtida relativ avkastning, även om signalen inte omsätts i lika stark portföljavkastning. Resultatet visar därmed att god prediktionsförmåga inte nödvändigtvis leder till den mest framgångsrika long/short-portföljen. Kombinationen är därför mer intressant ur en prediktionssynpunkt snarare än som investeringsunderlag. Notera att prediktionshorisonten är tolv månader. Eftersom portföljen inte handlas under prediktionshorisonten kan innehavet inte anpassas utifrån oförutsedda händelser, vilket gör långa prediktionshorisonten mer osäkra för icke-predikterbara händelser. Det diskuteras djupare i avsnitt 5.6. Den längre prediktionshorisonten om tolv månader bidrar å andra sidan till att begränsa transaktionskostnaderna.

Sammantaget visar resultaten att olika modellkombinationer fyller olika roller. Finans med IG, en månads horisont, Elastic Net-regression och två års tidsfönster är den mest avkastningsstarka kombinationen och är därför intressant ur ett portföljperspektiv. Kombinationen visar även stark prediktiv evidens. Konsumentvaror och tjänster med IG, en månads prediktionshorisont och två års tidsfönster är sammantaget också en stark portföljkandidat med hög annualiserad överavkastning och hög Sharpekvot, men också intressant ur ett prediktivt perspektiv. Däremot har båda kombinationerna Z-score som inte når 1,96 men generell prediktiv evidens finns, kombinerat med Z-score som trendar åt rätt håll. En förklaring kan vara att modeller med kortare prediktionshorisonten inte innehåller nog med information för att med hög säkerhet fastslå om prediktioner och verklighet har statistiskt bekräftad korrelation, trots att det resultat tyder på det. Konsumentvaror och tjänster med ZG, 12 månaders prediktionshorisont och tio års tidsfönster är inte lika intressant ur ett portföljperspektiv men kombinationen uppvisar den starkaste prediktiva förmågan. Intressant är att till skillnad från modeller baserat på det breda aktieurvalet så påträffas de starkaste portföljerna för korta prediktionshorisonten och korta tidsfönster. Sannolikt eftersom modeller tränade på en datamängd från mer homogena aktier är bättre på att identifiera utvecklingar baserat på kortsiktiga branschdrivna fluktuationer och sentiment.

5.5 Branschindelning kontra brett urval ur investeringssynpunkt

Efter analysering av resultaten för det breda testet och branschtesterna kan en jämförelse ur investeringssynpunkt göras. Se figur 6 i Appendix D för en visuell jämförelse av portföljprestation och prediktiv styrka hos slutkandidaterna för de breda modellerna och branschmodellerna. Det som sticker ut är att det för branschmodellerna finns specifika kombinationer med genomgående bättre portföljmått tillsammans med starkare prediktiv evidens än för det breda urvalet. Å andra sidan visar kombinationerna i det bredare testet en högre generell förklaringsförmåga, i form av högt medel- och medi-

anvärde på både Z-score och korrelation. Det tyder på att det precis som i branschtesterna finns prediktiv evidens bakom resultaten. Prediktionshorisonterna för de specifika resultaten i tabell 8 är längre än för de bäst presterande portföljerna i branschtesterna, tabell 11. Att längre prediktionshorisonter generellt ger lägre annualiserad överavkastning bör beaktas när direkta jämförelser mellan portföljers avkastning görs. Det eftersom många oförutsägbara händelser kan inträffa under en lång prediktionshorisont.

Att döma av resultaten, är branschmodellerna bättre på att förutspå framtida avkastningar för korta prediktionshorisonter och tidsfönster än vad en mer marknadsgenerell modell är. Vid längre prediktionshorisonter och tidsfönster är portföljprestandan likvärdig för branschmodeller och mer marknadsgenerella modeller. Därtill är positionerna i branschportföljer mer korrelerade och rörelser är starkt beroende av branschens generella rörelse. En marknadsgenerell modell kan till skillnad från en branschspecifik modell lägga en grund för en generell marknadsindikation.

En praktisk investeringsstrategi kan därför bygga på en kombination av breda och branschspecifika modeller. Den breda modellen kan fungera som en basmodell som indikerar en övergripande marknadssignal, medan branschspecifika modeller med fördel kan användas vid perioder där marknadssentimentet för specifika branscher är tydligt identifierbart. I perioder där en bransch är svårtolkad och oförklarligt volatil bör branschspecifika modeller undvikas till förmån för en bredare, mer marknadsövergripande modell. Sammantaget kan en väl presterande modell kombinera breda med branschspecifika modeller för att åstadkomma bättre avkastning med ökad stabilitet.

5.6 Olika portföljkonstruktioner

En viktig begränsning i portföljkonstruktionen är att innehaven hålls under hela prediktionshorisonten *dt*. Portföljen rekonstrueras först efter att horisonten löpt ut, vilket innebär att positionerna inte justeras om en aktie börjar underprestera under innehavsperioden eller om ny information signalerar att ett bolag eller en bransch oväntat har försämrade framtidsutsikter. Detta gör resultaten användbara som en indikation på modellernas förmåga att identifiera relativ över- och undervärdering över en given tidshorisont, snarare än som en dynamisk investeringsstrategi. Begränsningen blir särskilt relevant för längre prediktionshorisonter, där sannolikheten för oförutsedda bolags-, bransch- eller marknadshändelser ökar. En mer aktiv portföljstrategi med tätare rebalansering trots längre prediktionshorisont, eller stop-loss-liknande regler, skulle därför kunna ge bättre resultat. Däremot hade det samtidigt gjort det svårare att isolera modellens prediktionsförmåga för den specifika horisont som testas.

Resultaten från jämförelsen av portföljkonstruktioner, presenterat i tabell 13, visar att den likviktade long/short-portföljen är den starkaste av de testade alternativen. Detta tyder på att modellens främsta styrka inte ligger i att exakt bestämma hur mycket varje enskild aktie bör viktas, utan snarare i att identifiera aktiers över-/undervärdering. När vikterna i stället görs beroende av de predikterade avkastningarnas storlek, genom linjär viktning, rankingbaserad viktning eller sigmoidviktning, försämrats resultaten. En möjlig tolkning är därför att prediktionerna innehåller tillräckligt med information för att särskilja attraktiva och oattraktiva aktier på gruppnivå, men att den inbördes signalstyrkan inom dessa grupper är för brusig för att användas direkt som portföljvikt.

5.7 Transaktionskostnader

En begränsning i arbetet är att resultaten som presenterats ej är justerade för transaktionskostnader. Resultaten bör därför ses som bruttoresultat före courtage, eventuella kostnader för blankning och andra avgifter i samband med handel och ägande. Ha därför i åtanke att modeller med kortare prediktionshorisont kommer att vara känsligare för transaktionsavgifterna till följd av en högre omsättning av aktier.

Detta påverkar exempelvis kombinationer som Finans med IG, en månads prediktionshorisont, Elastic Net-regression och två års tidsfönster. Trots den höga annualiserade bruttoavkastningen bör resultatet tolkas med försiktighet.

Eftersom transaktionskostnader beror på faktorer som orderstorlek, aktiemäklare och möjlighet till blankning, blir det svårt att redovisa ett rättvist nettoutfall inom ramen för studien. Resultaten bör därför tolkas som en indikation på modellernas portföljmässiga och prediktiva potential. En naturlig vidareutveckling av arbetet hade varit att undersöka hur känsliga olika modeller är för transaktionskostnader, speciellt de med korta prediktionshorisonter.

6 Samhälleliga och etiska aspekter

I detta arbete används prediktionsmodeller för att förutsäga framtida avkastningar för aktier. Eftersom modellen fungerar som ett verktyg för investeringsbeslut, kan de indirekt påverka hur kapital fördelas på marknaden. Användningen av finansiella modeller är därmed inte enbart en teknisk fråga, utan väcker även viktiga samhälleliga och etiska aspekter.

Prediktionsmodeller kan bidra till snabbare och mer effektiva investeringsbeslut. Samtidigt kan tekniken skapa skillnader mellan olika aktörer på marknaden, då större institutioner ofta har bättre tillgång till data, datorkraft och avancerade

modeller än mindre investerare. Detta kan ge större aktörer ett informationsövertag och bidra till asymmetrier i kapitalfördelningen [38]. När många aktörer dessutom använder likartade modeller, kan de fatta liknande investeringsbeslut vid samma tidpunkt, vilket kan skapa ett flockbeteende som kan förstärka prISRörelser och bidra till ökad volatilitet [38]. Eftersom finansmarknaden är nära kopplad till individers ekonomi genom pensioner och sparande, samtidigt som företag är beroende av stabila marknadsförhållanden för investeringar och tillväxt, kan en sådan instabilitet få konsekvenser som sträcker sig utanför själva finansmarknaden.

Utöver de samhällseliga aspekterna väcker prediktionsmodeller flera etiska frågor kring hur investeringsbeslut fattas och vilka konsekvenser besluten kan få. När modeller används för att fatta ekonomiska beslut kan det vara svårt att avgöra vem som bär ansvar om modellen leder till felaktiga beslut eller ekonomiska förluster, särskilt när beslutsprocessen automatiseras och människans roll i beslutsfattandet minskar [38]. Eftersom modeller bygger på historisk data finns det dessutom en risk att tidigare marknadsmönster och skevheter på marknaden reproduceras, vilket kan påverka hur kapital fördelas mellan företag och sektorer. Därmed uppstår etiska frågor kring kapitalallokering och vilka typer av företag som prioriteras genom investering, särskilt inom kontroversiella branscher såsom spel, tobak eller försvar. Samtidigt finns det olika uppfattningar om vad som definieras som en etisk investering eftersom investerare har olika värderingar och prioriteringar. Etiska aspekter behöver dock inte stå i konflikt med ekonomiska mål. En studie av företag som rankats som särskilt etiska av Ethisphere Institute visar att dessa företag ofta är undervärderade av analytiker men ger bättre riskjusterad avkastning [39]. Detta visar att etiska aspekter inte enbart handlar om värderingar utan även kan ha ekonomisk betydelse.

Sammanfattningsvis representerar den data som används i finansiella modeller verkliga ekonomiska händelser och människors livssituationer. Förändringar i aktieavkastning och marknadsutveckling kan framstå som ren statistik men speglar i verkligheten företags utveckling, arbetstillfällen och individers privatekonomi. Därför bör finansiella prediktionsmodeller inte enbart utvärderas utifrån kvantitativa mått som träffsäkerhet eller avkastning utan även utifrån deras påverkan på marknaden och samhället.

7 Slutsats

Sammantaget visar resultaten att breda och branschspecifika modeller kan fylla olika roller i en faktorbaserad investeringsstrategi. I det breda aktieuniversumet gav IG- och ZG-baserade modeller med långa och medellånga prediktionshorisonter de genomgående mest positiva resultaten. Längre träningsfönster kombinerat med IG gav konsekvent de högsta prediktiva styrkorna och avkastningen är nästintill likgiltig, mellan 3% och 7% för alla de specifika kombinationerna i tabell 8.

I den branschspecifika analysen framstod finans med IG, en månads prediktionshorisont, Elastic Net-regression och två års tidsfönster som den mest intressanta portföljkombinationen med högst annualiserad överavkastning. Däremot med lägre prediktiv förmåga än konsumentvaror och tjänster med ZG, tolv månaders prediktionshorisont, OLS-regression och tio års tidsfönster. Den kombinationen sticker ut med den högst uppmätta prediktiva styrkan. Däremot visade den kombinationen en sämre omsättning i portföljstyrka med en lägre annualiserad överavkastning och lägre portföljmått. Även konsumentvaror och tjänster med IG, tre månaders prediktionshorisont, OLS-regression och två års tidsfönster är intressant ur ett portföljperspektiv med hög annualiserad överavkastning och hög Sharpe-kvot, och samtidigt relativt god prediktionsförmåga med genomgående positiva mått. Det tyder på att längre prediktionshorisonter och tidsfönster är prediktivt starkare. Se tabell 12 för kombinationernas exakta mått.

Slutligen föreslås en investeringsstrategi som bygger på en kombination av breda, mer marknadsgenerella modeller, och branschspecifika modeller. Det för att i perioder av tydliga branschrörelser kunna dra nytta av branschspecifika prediktioner, samtidigt som breda marknadsgenerella modeller kan vara mer stabila när en bransch är i en osäker och oförklarligt volatil period. Därtill kan breda modeller användas som bas för indikation kring övergripande marknadsläge.

Sammantaget har arbetet resulterat i modeller som visar god förklaringsgrad för avkastningen de predikterar, både på en marknadsgenerell och branschspecifik nivå. För långa prediktionshorisonter och tidsfönster har branschspecifika och marknadsgenerella modeller liknande robusthet. Däremot uppvisar branschspecifika modeller högre portföljprestation och prediktiv styrka än vad marknadsgenerella modeller gör på korta prediktionshorisonter och tidsfönster. Det kan bero på faktorer som att en modell tränad på en mer homogen datamängd lättare plockar upp kortsiktiga strukturerade fluktuationer och sentiment. En förklaring till att kortare prediktionshorisonter har lägre Z-score kan vara att de inte innehåller nog med information för att med hög säkerhet fastslå om prediktioner och verklighet har statistiskt bekräftad korrelation, trots att resultaten tyder på det.

Referenser

- [1] W. F. Sharpe, "Capital asset prices: A theory of market equilibrium under conditions of risk," *The Journal of Finance*, årg. 19, nr 3, s. 425–442, 1964. doi: 10.1111/j.1540-6261.1964.tb02865.x.
- [2] E. F. Fama, "Efficient capital markets: A review of theory and empirical work," *The Journal of Finance*, årg. 25, nr 2, s. 383–417, 1970. doi: 10.1111/j.1540-6261.1970.tb00518.x.
- [3] B. G. Malkiel, *A Random Walk Down Wall Street*. New York: W. W. Norton & Company, 1973.
- [4] S. Basu, "Investment performance of common stocks in relation to their price-earnings ratios: A test of the efficient market hypothesis," *The Journal of Finance*, årg. 32, nr 3, s. 663–682, 1977. doi: 10.1111/j.1540-6261.1977.tb01979.x.
- [5] R. W. Banz, "The relationship between return and market value of common stocks," *Journal of Financial Economics*, årg. 9, nr 1, s. 3–18, 1981. doi: 10.1016/0304-405X(81)90018-0.
- [6] W. F. M. De Bondt och R. Thaler, "Does the stock market overreact?" *The Journal of Finance*, årg. 40, nr 3, s. 793–805, 1985. doi: 10.1111/j.1540-6261.1985.tb05004.x.
- [7] E. F. Fama och K. R. French, "Common risk factors in the returns on stocks and bonds," *Journal of Financial Economics*, årg. 33, nr 1, s. 3–56, 1993. doi: 10.1016/0304-405X(93)90023-5.
- [8] N. Jegadeesh och S. Titman, "Returns to buying winners and selling losers: Implications for stock market efficiency," *The Journal of Finance*, årg. 48, nr 1, s. 65–91, 1993. doi: 10.1111/j.1540-6261.1993.tb04702.x.
- [9] M. M. Carhart, "On persistence in mutual fund performance," *The Journal of Finance*, årg. 52, nr 1, s. 57–82, 1997. doi: 10.1111/j.1540-6261.1997.tb03808.x.
- [10] E. F. Fama och K. R. French, "A five-factor asset pricing model," *Journal of Financial Economics*, årg. 116, nr 1, s. 1–22, 2015. doi: 10.1016/j.jfineco.2014.10.010.
- [11] E. F. Fama och K. R. French, "Choosing factors," *Journal of Financial Economics*, årg. 128, nr 2, s. 234–252, 2018. doi: 10.1016/j.jfineco.2018.02.012.
- [12] G. W. Schwert, "Anomalies and market efficiency," *Handbook of the Economics of Finance*, vol. 1, s. 939–974, 2003. doi: 10.1016/S1574-0102(03)01024-0.
- [13] E. F. Fama och J. D. MacBeth, "Risk, return, and equilibrium: Empirical tests," *Journal of Political Economy*, årg. 81, nr 3, s. 607–636, 1973. doi: 10.1086/260061.
- [14] R. C. Grinold och R. N. Kahn, *Active Portfolio Management: A Quantitative Approach for Producing Superior Returns and Controlling Risk*, 2:a uppl. New York: McGraw-Hill, 2000.
- [15] N.-F. Chen, R. Roll och S. A. Ross, "Economic forces and the stock market," *The Journal of Business*, årg. 59, nr 3, s. 383–403, 1986. doi: 10.1086/296344.
- [16] R. E. Whaley, "The investor fear gauge," *The Journal of Portfolio Management*, årg. 26, nr 3, s. 12–17, 2000. doi: 10.3905/jpm.2000.319728.
- [17] G. James, D. Witten, T. Hastie, och R. Tibshirani, *An Introduction to Statistical Learning: with Applications in R*. New York, NY: Springer, 2013. doi: 10.1007/978-1-4614-7138-7.
- [18] F. Zubedi, B. Sartono och K. A. Notodiputro, "Implementation of winsorizing and random oversampling on data containing outliers and unbalanced data with the random forest classification method," *Jurnal Natural*, vol. 22, nr 2, 2022. doi: 10.24815/jn.v22i2.25499.
- [19] F. T. Lima och V. M. A. Souza, "A Large Comparison of Normalization Methods on Time Series", *Big Data Research*, vol. 34, 2023, art. 100407. doi: 10.1016/j.bdr.2023.100407.
- [20] T. Hastie, R. Tibshirani och J. Friedman, *The Elements of Statistical Learning*. New York: Springer, 2009.
- [21] C. S. Asness, T. J. Moskowitz och L. H. Pedersen, "Value and Momentum Everywhere," *The Journal of Finance*, årg. 68, nr 3, s. 929–985, 2013. doi: 10.1111/jofi.12021.
- [22] S. Gu, B. Kelly och D. Xiu, "Empirical Asset Pricing via Machine Learning," *The Review of Financial Studies*, årg. 33, nr 5, s. 2223–2273, 2020. doi: 10.1093/rfs/hhaa009.

- [23] J. A. Nelder, "A Reformulation of Linear Models," *Journal of the Royal Statistical Society. Series A (General)*, årg. 140, nr 1, s. 48–77, 1977. doi: 10.2307/2344517.
- [24] N. Dasari, "The Pearson Correlation Coefficient, Explained Simply," *Towards Data Science*, 1 nov. 2025. [Online]. Tillgänglig: <https://towardsdatascience.com/pearson-correlation-coefficient-explained-simply/>. [Hämtad: 13 maj 2026].
- [25] A. Baines, "Statistical Significance in 1000 Words: Why 1.96 Rules Research," *Medium*, 4 aug. 2025. [Online]. Tillgänglig: <https://medium.com/@alfie.baines/statistical-significance-in-1000-words-why-1-96-rules-research-c11d515b17e7>. [Hämtad: 13 maj 2026].
- [26] J. Fernando, "Sharpe Ratio: Definition, Formula, and Examples", *Investopedia*, uppdaterad 2025-12-23, <https://www.investopedia.com/terms/s/sharperatio.asp>.
- [27] J. Chen, "Understanding Portfolio Turnover: Formula, Impact, and Tax Implications," *Investopedia*, uppdaterad 2025-09-08, <https://www.investopedia.com/terms/p/turnover.asp>.
- [28] A. Hayes, "Understanding the Information Coefficient (IC): Definition, Formula, and Example", *Investopedia*, uppdaterad 2025-09-24, <https://www.investopedia.com/terms/i/information-coefficient.asp>.
- [29] P. Gratton, "Information Ratio (IR): Definition, Formula, vs. Sharpe Ratio", *Investopedia*, uppdaterad 2025-06-18, <https://www.investopedia.com/terms/i/informationratio.asp>.
- [30] J. Chen, "Portfolio Weights Explained: Calculations & Diversity", *Investopedia*, uppdaterad 2025-09-20, <https://www.investopedia.com/terms/p/weights.asp>.
- [31] T. Tamplin, "Equal-Weighted Portfolio," *Finance Strategists*, uppdaterad 2025-07-10, <https://www.financestrategists.com/wealth-management/risk-profile/diversification/equal-weighted-portfolio/>.
- [32] Avanza, "Vad är blankning och hur fungerar det?" *Avanza Akademin*, <https://www.avanza.se/lar-dig-mer/avanza-akademin/aktier/vad-ar-blankning-hur-fungerar-det.html>.
- [33] L. S. Baugh, "Sigmoid function," *Encyclopaedia Britannica*, hämtad: 2026-05-12, <https://www.britannica.com/science/sigmoid-function>.
- [34] Wolfram Alpha LLC, "tanh(x)," *WolframAlpha*, hämtad: 2026-05-12, <https://www.wolframalpha.com/input?i=tanh%28x%29>.
- [35] J. H. Cochrane, "Presidential Address: Discount Rates," *The Journal of Finance*, årg. 66, nr 4, s. 1047–1108, 2011. doi: 10.1111/j.1540-6261.2011.01671.x.
- [36] C. R. Harvey, Y. Liu och H. Zhu, "... and the Cross-Section of Expected Returns," *The Review of Financial Studies*, årg. 29, nr 1, s. 5–68, 2016. doi: 10.1093/rfs/hhv059.
- [37] K. Hou, C. Xue och L. Zhang, "Replicating Anomalies," *The Review of Financial Studies*, årg. 33, nr 5, s. 2019–2133, 2020. doi: 10.1093/rfs/hhy131.
- [38] W. A. Addy, A. O. Ajayi-Nifise, B. G. Bello, S. T. Tula, O. Odeyemi och T. Falaiye, "Machine learning in financial markets: A critical review of algorithmic trading and risk management", *International Journal of Science and Research Archive*, årg. 11, nr 1, s. 1853–1862, 2024. doi: 10.30574/ijrsra.2024.11.1.0292.
- [39] B. Yu, S. Wu och M. J. Lenard, "Do Ethical Companies Have High Stock Prices or High Returns?" *Journal of Risk and Financial Management*, årg. 15, nr 2, s. 81, 2022. doi: 10.3390/jrfm15020081.

AI-användande

AI-verktyg användes främst som ett stöd för lärande och förståelse under projektets gång. Inom programmeringsdelen användes AI som hjälp för att kunna förstå och använda olika Python-paket, bibliotek, funktioner och vid felsökning av kod.

AI-verktygen användes även för strukturerande av idéer, förbättring av rapportens upplägg och optimering av LaTeX-formatering, exempelvis vid skapande av komplexa tabeller och layout i rapporten. Verktygen användes också för namngivning av faktorer för ökad tydlighet.

Allt AI-genererat material och alla förslag har kritiskt granskats och verifierats innan de användes i vårt arbete. Vi är ansvariga för projektets implementation och vetenskapliga innehåll.

A Variabler och faktorkonstruktion

Detta appendix redovisar de variabler och faktorer som används i projektet. Först presenteras de grundvariabler från CRSP och Compustat som används för att konstruera finansiella faktorer. Därefter redovisas de finansiella, makroekonomiska, sentimentbaserade faktorer, faktorgrupper samt de faktoruppsättningar som används i regressionerna.

A.1 Grundvariabler till finansiella faktorer

Tabell 14: Grundvariabler från CRSP och Compustat som används vid konstruktionen av finansiella faktorer.

Variabel	Datakälla	Beskrivning
PRC	CRSP	Aktiepris
SHROUT	CRSP	Antal utestående aktier
VOL	CRSP	Handelsvolym
RET	CRSP	Månadsavkastning
atq	Compustat	Totala tillgångar
seqq	Compustat	Eget kapital
dlcq	Compustat	Kortfristiga skulder
dlttq	Compustat	Långfristiga skulder
oiadpq	Compustat	Rörelseresultat efter avskrivningar (EBIT)
piq	Compustat	Vinst före skatt
revtq	Compustat	Intäkter
saleq	Compustat	Försäljning
cogsq	Compustat	Kostnad för sålda varor
xsgaq	Compustat	Försäljnings- och administrationskostnader
oancfy	Compustat	Operativt kassaflöde

A.2 Finansiella faktorer

Tabell 15: Tabellen redovisar de finansiella faktorer som har använts under projektet. För varje faktor anges dess dimension samt hur faktorn beräknas. Beräkningarna baseras på finansiella nyckeltal.

Aktiefaktor	Dimension	Beräkning
BM	Värde	Bokfört eget kapital / börsvärde
EP	Värde	Vinst före skatt / börsvärde
CFP	Värde	Operativt kassaflöde / börsvärde
MOM12_1	Momentum	Kumulativ avkastning 12 mån, senaste mån exkluderad
MOM6_1	Momentum	Kumulativ avkastning 6 mån, senaste mån exkluderad
ROA	Kvalitet	EBIT / totala tillgångar
ROE	Kvalitet	Vinst före skatt / eget kapital
OP	Kvalitet	(Intäkter - kostnad sålda varor - försäljningskostnader) / eget kapital
GP	Kvalitet	(Intäkter - kostnad sålda varor) / totala tillgångar
MARGIN	Kvalitet	EBIT / intäkter
LOG_MCAP	Storlek	Naturlig logaritm av börsvärde
ASSET_GROWTH	Tillväxt	Tillgångstillväxt år-över-år
SALES_GROWTH	Tillväxt	Intäkstillväxt år-över-år
GROWTH	Tillväxt	EBIT-tillväxt år-över-år
CAPALOC	Tillväxt	Förändring i utestående aktier år-över-år
REV1	Reversal	Föregående månads avkastning
TURNOVER	Likviditet	Handelsvolym / antal utestående aktier
LEVERAGE	Risk	(Kortfristiga + långfristiga skulder) / eget kapital
SOLIDITY	Risk	Eget kapital / totala tillgångar
VOL12	Risk	Standardavvikelse av månadsavkastning, 12 mån
MARKNADSRISK	Risk	CAPM-beta, 24-mån rullande regression mot S&P 500
FÖRETAGSRISK	Risk	Standardavvikelse av residualer från CAPM-regressionen

Börsvärde hämtas inte direkt från Compustat utan beräknas som absolutvärdet av aktiepriset multiplicerat med antal utestående aktier, $|PRC| \cdot SHROUT$.

A.3 Faktorgrupper

Tabell 16: Tabellen visar en av faktorkombinationerna som använts i studien, bestående av åtta faktorgrupper och totalt 22 finansiella faktorer. Den första kolumnen anger gruppnamnet för respektive faktorgrupp. I den andra och tredje kolumnen redovisas antalet ingående finansiella faktorer samt vilka dessa är. Den sista kolumnen indikerar huruvida en teckenvändning har använts eller inte.

Grupp	k	Komponenter	Teckenvändningar
VALUE	3	BM, EP, CFP	Inga
MOMENTUM	2	MOM12_1, MOM6_1	Inga
QUALITY	5	ROA, ROE, OP, GP, MARGIN	Inga
SIZE	1	LOG_MCAP	LOG_MCAP vänd ($s = -1$)
GROWTH	4	ASSET_GROWTH, SALES_GROWTH, GROWTH, CAPALLOC	CAPALLOC vänd ($s = -1$)
REVERSAL	1	REV1	Ingen
LIQUIDITY	1	TURNOVER	Ingen
RISK	5	LEVERAGE, SOLIDITY, VOL12, MARKNADS-RISK, FÖRETAGSRISK	LEVERAGE, VOL12, MARKNADSRISK och FÖRETAGSRISK vända ($s = -1$); SOLIDITY oförändrad

A.4 Makro- och sentimentfaktorer

Tabell 17: Tabellen redovisar de makro- och sentimentfaktorer som används under projektet. För varje faktor anges dess dimension och beskrivning

Faktor	Dimension	Beskrivning
VIX	Sentiment	Implicit volatilitet, S&P 500-optioner (30 dagar)
VVIX	Sentiment	Volatilitet av VIX (osäkerhet om osäkerhet)
VVIX/VIX	Sentiment	Regimin stabilitet
Kreditspread	Makro	BAA – AAA företagsobligationsränta
Terminspread	Makro	10-årig – 2-årig statsränta
Inflation	Makro	Konsumentprisinflation, år-över-år
Ränteförändring	Makro	Förändring i federal funds rate
Industriproduktion	Makro	Tillväxt i industriproduktion, år-över-år
Arbetslöshet	Makro	Förändring i arbetslösheten

CNN:s Fear and Greed Index inkluderades initialt som en sentimentfaktor, men exkluderades ur den slutliga analysen på grund av bristande datatäckning. Serien finns endast tillgänglig från 2011.

A.5 Faktoruppsättningar

Tabell 18: Tabellen visar de tre faktorkombinationer som har använts i modellträningen. I den första kolumnen visas den förkortning som använts för varje faktorkombination, i den andra kolumnen presenteras namnet på faktorkombinationen, och i den tredje kolumnen visas de variabler som ingår i varje faktorkombination.

Kod	Namn	Beståndsdelar	Antal
ZG	Z-grupp	z_BM, z_EP, z_CFP, z_MOM12_1, z_MOM6_1, z_ROA, z_ROE, z_OP, z_GP, z_MARGIN, z_LOG_MCAP, z_ASSET_GROWTH, z_SALES_GROWTH_YOY, z_GROWTH, z_CAPALLOC, z_REV1, z_TURNOVER, z_LEVERAGE, z_SOLIDITY, z_VOL12, z_MARKNADSRISK, z_FORETAGSRISK	22
FGU	Faktorgruppsuppsättning	SIZE: -z_LOG_MCAP REVERSAL: z_REV1 LIQUIDITY: z_TURNOVER VALUE: z_BM, z_EP, z_CFP MOMENTUM: z_MOM12_1, z_MOM6_1 QUALITY: z_ROA, z_ROE, z_OP, z_GP, z_MARGIN GROWTH: z_ASSET_GROWTH, z_SALES_GROWTH_YOY, z_GROWTH, -z_CAPALLOC RISK: -z_LEVERAGE, z_SOLIDITY, -z_VOL12, -z_MARKNADSRISK, -z_FÖRETAGSRISK	8
IG	Interaktionsgrupp	Faktorgrupper: SIZE, REVERSAL, LIQUIDITY, VALUE, MOMENTUM, QUALITY, GROWTH, RISK Makro-/sentimentvariabler: z_inflation_yoy, z_rate_change, z_term_spread, z_credit_spread, z_ip_growth_yoy, z_unemployment_change, z_VIX, z_VVIX, z_VVIX_VIX	80

B Empirisk motivation och validering av FGU

Detta appendix redovisar den fullständiga motiveringen för faktorgruppsuppsättningen FGU samt den korrelationsanalys som validerar grupperingen ur ett regressionsperspektiv. Materialet skiljs från (**Avsnitt A**), som beskriver de underliggande faktorerna och faktorkonstruktionerna. Analyserna i detta appendix motiverar grupperingen ur ett strukturellt regressionsperspektiv. De garanterar inte att FGU presterar bättre än ZG i den empiriska utvärderingen, vilket avgörs separat i resultatdelen (**Avsnitt 4**).

B.1 Motivation


Vi konstruerar FGU i prioriterad ordning enligt tre steg:

Steg 1 (Ekonomisk teori): Primärt bestäms gruppindelningen efter faktorernas ekonomiska mening, vilket inte kräver någon statistisk analys. BM, EP och CFP mäter alla värdering relativt fundamentala mått och tillhör därför VALUE. ROA, ROE, OP, GP och MARGIN mäter lönsamhet och tillhör QUALITY. MOM12_1 och MOM6_1 fångar trender över olika tidshorisonter och bildar MOMENTUM. LOG_MCAP utgör i sig själv ett mått på företagsstorlek och definierar SIZE, den ingår med negativt tecken eftersom storlekspremien avser småbolags exponering. TURNOVER mäter handelsaktivitet och bildar LIQUIDITY, REV1 fångar kortsiktiga prisreverseringar och bildar REVERSAL.


Steg 2 (Beräkningsmässig logik): För teoretiskt ambigüosa faktorer delas grupperna efter gemensam matematisk struktur. ASSET-GROWTH, SALES-GROWTH och GROWTH beräknas som år-över-år-förändringar i tillgångar, intäkter respektive EBIT och bildar GROWTH gruppen. CAPALLOC mäter förändring i utestående aktier och fångar kapitalallokeringsbeslut, en närliggande dimension av tillväxtprofilen. Den ingår med negativt tecken i GROWTH gruppen eftersom utspädning typiskt signalerar svagare värdeskapande, så att gruppen pekar i riktningen starkare tillväxt kvalitet. LEVERAGE, SOLIDITY, VOL12, MARKNADSRISK och FORETAGSRISK bygger på olika konstruktioner, från balansräkningsnyckeltal till statistisk volatilitet och CAPM-regression, men mäter samtliga finansiell eller marknadsmässig risk och bildar RISK. Fyra av dem är riskhöjande och ingår med negativt tecken (LEVERAGE, VOL12, MARKNADSRISK, FORETAGSRISK) medan SOLIDITY mäter finansiell stabilitet och ingår positivt, så att gruppen efter vändning pekar i riktningen lägre risk.

Steg 3 (Korrelationsanalys): Till sist görs en korrelationsanalys på finansiella faktorerna för att hitta linjära samband. Detta valdes som den sista metoden av anledningen att de finansiella faktorerna som uppenbarligen ska vara i samma grupp kan visa sig ha låg linjär korrelation. Exempelvis korrelerar BM och EP bara 0,05, trots att båda mäter värdering. Den låga korrelationen beror på att de använder olika fundamentala mått i täljaren. Till exempel kan ett teknikbolag med lite bokfört kapital men hög vinst ha lågt BM och högt EP. Att de korrelerar lågt är inte ett argument mot att gruppera dem. Det är tvärtom ett argument för att ha med dem i samma grupp, just för att de mäter samma sak från olika vinklar och därmed minskar mätbruset i kompositen.

Korrelationer mellan de 22 råa z-faktorerna



Figur 1: Tids-medelvärderade tvärsnittskorrelationer för de 22 råa z-faktorerna, ordnade efter faktorgrupp. Svarta linjer markerar gruppgränser.



Figur 2: Tids-medelvärderade tvärsnittskorrelationer mellan de 8 sammansatta faktorgrupperna.

B.2 Validering

För att verifiera att grupperingen från ZG till FGU förbättrar regressionens egenskaper jämfördes tre mått på multikollinearitet, beräknade på tids-medelvärderade tvärsnittskorrelationer (Tabell 19).


Tabell 19: Regressionsegenskaper för ZG och FGU.

Mått	ZG (22 faktorer)	FGU (8 kompositer)
Genomsnittlig $ \rho $	0.119	0.087
Konditionstal	30.2	2.9
Max VIF	4.83	1.27

Genomsnittlig $|\rho|$ är den genomsnittliga absoluta korrelationen mellan alla par av variabler. Konditionstalet är förhållandet mellan korrelationsmatrisens största och minsta egenvärde. Värdet under 30 klassificeras som låg multikollinearitet, över 100 som problematisk. Max VIF (Variance Inflation Factor) anger hur mycket koefficientvariansen för den värst drabbade featuren inflateras av kollinearitet, där $VIF > 10$ traditionellt anses problematisk.

FGU har lägre multikollinearitet än ZG på samtliga tre mått, framför allt konditionstalet som faller från 30,2 till 2,9. Grupperingen ger därmed stabilare koefficientskattningar. För IG gäller andra överväganden eftersom syftet där är att fånga tillståndsberoende effekter, inte att minska multikollinearitet. (**Avsnitt 2.3.5**)

Regressionsegenskaper: 22 råa vs 8 grupperade features



Figur 3: Jämförelse av regressionsegenskaper för ZG och FGU. Genomsnittlig $|\rho|$, konditionstal och Max VIF är samtliga lägre för FGU, vilket indikerar lägre multikollinearitet och därmed stabilare regressionskoefficienter.

C Empirisk motivation och validering av IG

För att motivera utvidgningen från FGU till IG empiriskt undersöker vi om faktorgruppernas avkastning varierar med makroekonomiska och sentimentbaserade regimer. Om så är fallet kan interaktionstermerna bära information som de rena huvudeffekterna inte fångar. Att regimberoendet existerar i historiska data är en nödvändig men inte tillräcklig förutsättning för att IG ska prestera bättre än FGU. Den frågan avgörs av modelltesterna i resultatdelen (**Avsnitt 4**).

C.1 Metod

Analysen är beskrivande snarare än prediktiv. Den karakteriserar regimberoendet i historiska data utan att skatta någon modell, utan tidsuppdelning och utan korsvalidering, till skillnad från metoden för huvudanalysen (**Avsnitt 3**). Metoden består av fyra steg.

Steg 1 (Konstruktion av long/short-portföljer): För var och en av de åtta faktorgrupperna konstrueras en månadsvis long/short-portfölj. Varje månad sorteras aktierna efter faktorgruppens värde. En lika viktad portfölj bildas av de 10 % högst rankade aktierna (long) och en av de 10 % lägst rankade aktierna (short). Skillnaden mellan den långa och korta portföljens avkastning under nästkommande månad ger faktorgruppens månadsvisa long/short-avkastning.


Steg 2 (Uppdelning av månader i två regimer): För varje makro- eller sentimentfaktor delas de cirka 250 månaderna i datasettet i två grupper baserat på faktorns medianvärde. Medianen delar fördelningen i två lika stora halvor, vilket innebär att hälften av månaderna hamnar i hög-regim (faktorn över medianen) och hälften i låg-regim (faktorn under medianen). Detta ger en enkel och symmetrisk uppdelning utan antaganden om fördelningens form.

Steg 3 (Beräkning av regimskillnad): Inom varje regim beräknas medelvärdet av long/short-avkastningen över alla månader. Skillnaden $\Delta = r_{\text{hög}} - r_{\text{låg}}$ visar hur mycket bättre eller sämre faktorn presterar i hög-regim jämfört med låg-regim. Ett värde nära noll innebär att faktorns avkastning är oberoende av regimen. Stora absolutvärden innebär att faktorns avkastning systematiskt skiljer sig mellan regimerna, ett mönster som IG:s interaktionstermer kan utnyttja men inte FGU:s rena huvudeffekter.

Steg 4 (Permutationstest för statistisk signifikans): Eftersom enskilda regimskillnader kan uppstå av slump kontrolleras varje par av faktorgrupp och makro- eller sentimentfaktor med ett permutationstest. Testet undersöker om de observerade regimskillnaderna är större än vad som kan förväntas om regimetiketter vore oinformativa. Regimetiketter (hög/låg) slumpas om bland månaderna 1000 gånger, och för varje slumpning beräknas en ny regimskillnad. p -värdet är andelen slumpade skillnader vars absolutbelopp är minst lika stort som det faktiskt observerade. Ett p -värde under 0.05 innebär att den observerade skillnaden uppstår i färre än 5 % av slumpade utfall och tolkas som statistiskt signifikant.

C.2 Resultat

Resultatet visas i Figur 4 och sammanfattas i Tabell 20. Den fullständiga listan över alla 72 par med tillhörande p -värden visas i Tabell 21.



Figur 4: Skillnad i månadsvis long/short-avkastning mellan hög- och låg-regim för samtliga par av faktorgrupp och makro-/sentimentfaktor. Värdet anger differensen i procent per månad.

Tabell 20: Sammanfattning av regimberoende över 72 par av faktorgrupp och makro-/sentimentfaktor.

Mått	Värde
Antal par (faktorgrupp $\times$ makro/sentiment)	72
Genomsnittlig $ \Delta $	0.83 % per månad
Maximalt $ \Delta $	2.50 % per månad
Par med $ \Delta > 0.5$ %	47 av 72
Par där faktorn byter tecken mellan regimer	30 av 72
Par med $p < 0.05$ (permutationstest)	9 av 72
Par med $p < 0.01$ (permutationstest)	3 av 72
Förväntat antal under H_0 vid $p < 0.05$	3.6
Förväntat antal under H_0 vid $p < 0.01$	0.7
Starkaste regimberoende	RISK $\times$ inflation (+2.50 %)

Av de 72 paren har 47 en absolut regimskillnad över 0.5 % per månad. Den genomsnittliga absoluta skillnaden är 0.83 % per månad. För 30 av 72 par byter faktorns avkastning tecken mellan regimerna, vilket innebär att faktorn ger positiv avkastning i den ena regimen och negativ i den andra.

Permutationstestet visar att 9 av 72 par är statistiskt signifikanta på 5 %-nivå och 3 på 1 %-nivå, vilket är 2.5 respektive 4 gånger fler än de 3.6 respektive 0.7 par som förväntas under nollhypotesen att makrofaktorerna är oinformativa.

Tabell 21: Fullständigt permutationstest för alla 72 par av faktorgrupp och makro-/sentimentfaktor. Δ anger skillnaden i månadsvis long/short-avkastning mellan hög- och låg-regim. p -värdet är andelen av 1000 permutationer som ger lika stor eller större absolut skillnad. Fetstil markerar par med $p < 0.05$.

Faktor	Makro-/sentimentfaktor	Δ [%]	p -värde
SIZE	VIX	+0.42	0.498
SIZE	VVIX	−1.26	0.075
SIZE	VVIX_VIX	+1.74	0.075
SIZE	credit_spread	−0.05	0.937
SIZE	term_spread	+1.33	0.057
SIZE	inflation_yoy	−1.17	0.094
SIZE	rate_change	+2.44	0.001
SIZE	ip_growth_yoy	+0.66	0.345
SIZE	unemployment_change	−1.01	0.137
REVERSAL	VIX	−0.53	0.241
REVERSAL	VVIX	+0.60	0.262
REVERSAL	VVIX_VIX	+0.38	0.392
REVERSAL	credit_spread	−0.72	0.111
REVERSAL	term_spread	−0.70	0.116
REVERSAL	inflation_yoy	+0.90	0.044
REVERSAL	rate_change	−0.19	0.658
REVERSAL	ip_growth_yoy	+0.69	0.121
REVERSAL	unemployment_change	−0.71	0.111
LIQUIDITY	VIX	−0.07	0.921
LIQUIDITY	VVIX	−1.24	0.123
LIQUIDITY	VVIX_VIX	+1.24	0.158
LIQUIDITY	credit_spread	−0.30	0.642
LIQUIDITY	term_spread	+0.37	0.581
LIQUIDITY	inflation_yoy	−1.08	0.094
LIQUIDITY	rate_change	+2.20	0.007
LIQUIDITY	ip_growth_yoy	+0.54	0.408
LIQUIDITY	unemployment_change	−1.20	0.075
VALUE	VIX	−0.15	0.722
VALUE	VVIX	−0.34	0.495
VALUE	VVIX_VIX	−0.68	0.172
VALUE	credit_spread	−0.49	0.244
VALUE	term_spread	−0.52	0.197
VALUE	inflation_yoy	+0.16	0.702
VALUE	rate_change	+0.11	0.785
VALUE	ip_growth_yoy	−0.33	0.412
VALUE	unemployment_change	−0.05	0.910
MOMENTUM	VIX	−0.54	0.347
MOMENTUM	VVIX	−0.06	0.918
MOMENTUM	VVIX_VIX	−0.80	0.230
MOMENTUM	credit_spread	+0.19	0.737
MOMENTUM	term_spread	−0.58	0.302
MOMENTUM	inflation_yoy	+0.33	0.572
MOMENTUM	rate_change	−0.91	0.114
MOMENTUM	ip_growth_yoy	−0.84	0.144
MOMENTUM	unemployment_change	+1.25	0.041
QUALITY	VIX	+0.30	0.605
QUALITY	VVIX	+0.80	0.186
QUALITY	VVIX_VIX	−2.20	0.038
QUALITY	credit_spread	+0.18	0.748
QUALITY	term_spread	−0.06	0.913
QUALITY	inflation_yoy	+1.69	0.023
QUALITY	rate_change	−1.74	0.015
QUALITY	ip_growth_yoy	−0.40	0.526
QUALITY	unemployment_change	+0.94	0.123
GROWTH	VIX	−0.75	0.166
GROWTH	VVIX	+1.21	0.075
GROWTH	VVIX_VIX	−1.78	0.055
GROWTH	credit_spread	+0.29	0.587
GROWTH	term_spread	−0.59	0.279
GROWTH	inflation_yoy	+0.43	0.434
GROWTH	rate_change	−2.03	0.000
GROWTH	ip_growth_yoy	+0.22	0.692
GROWTH	unemployment_change	+0.64	0.221
RISK	VIX	−0.54	0.358
RISK	VVIX	+0.83	0.227
RISK	VVIX_VIX	−1.34	0.082
RISK	credit_spread	+0.33	0.564
RISK	term_spread ^x	−0.98	0.092
RISK	inflation_yoy	+2.50	0.014
RISK	rate_change	−2.32	0.020
RISK	ip_growth_yoy	−1.19	0.057
RISK	unemployment_change	+1.72	0.057

C.3 Diskussion

Den deskriptiva analysen visar stora skillnader i månadsvis avkastning mellan regimer för många par. Permutationstestet visar dock att majoriteten av dessa skillnader inte kan särskiljas från slumpvariation. Av de 30 teckenbytena motsvarar bara en mindre del verkliga regimeffekter.

De signifikanta paren koncentreras till vissa makro- och sentimentfaktorer. Fem av de nio involverar ränteförändringar (`rate_change`), fördelade över `SIZE`, `LIQUIDITY`, `QUALITY`, `GROWTH` och `RISK`. Inflation, arbetslöshetsförändring och `VVIX/VIX`-ratio står för resten. Resterande makro- och sentimentfaktorer ger inga signifikanta par, vilket kan innebära att deras interaktioner i IG bidrar litet till modellen.

Trots detta inkluderas interaktionstermer för samtliga nio makro- och sentimentfaktorer i IG. Regulariseringen i Ridge, Lasso och Elastic Net straffar oinformativa koefficienter, vilket gör att brusiga interaktioner får liten vikt automatiskt. En modell med enbart huvudeffekter (FGU) kan inte fånga regimskiften även när de finns. IG väljer alltså högre dimensionalitet för att kunna modellera tillståndsberoende.

D Branschtester

Tabell 22 presenterar resultaten för alla kombinationer av bransch och faktorkombination. Se tabell 9 för de kombinationer som valdes ut för vidare analys.

Tabell 22: Fullständig sammanställning av samtliga kombinationer av bransch och faktorkombination. Tabellen visar medelvärden över samtliga körningar inom respektive kombination.

Bransch	faktorkombination	Portföljmått			Prediktiv styrka					Antal körningar
		Ann. avk.	Sharpe	Hit rate	Mean IC	IC IR	Positiv IC	Korr.	Z-score	
Konsumentvaror och tjänster	FGU	-4,37%	0,0634	46,93%	-0,0104	-0,0110	47,89%	-0,0223	-0,4450	440
Konsumentvaror och tjänster	IG	2,52%	1,0537	50,28%	0,0251	0,1386	55,34%	0,0065	0,3318	437
Konsumentvaror och tjänster	ZG	-2,55%	0,9763	48,81%	0,0020	0,0411	50,65%	-0,0071	0,6808	440
Finans	FGU	-12,42%	-0,3527	45,26%	-0,0376	-0,1646	44,73%	-0,0525	-0,9540	440
Finans	IG	-13,77%	-0,5049	41,66%	-0,0287	-0,1400	45,54%	-0,0406	-0,7848	437
Finans	ZG	-9,09%	-0,1412	45,65%	-0,0304	-0,1395	46,34%	-0,0434	-0,4012	440
Hälsovård	FGU	-1,57%	0,1496	46,62%	0,0151	0,1425	52,69%	0,0040	0,5939	440
Hälsovård	IG	-3,63%	-0,3152	43,78%	-0,0196	-0,0802	44,36%	-0,0231	-0,0896	437
Hälsovård	ZG	-0,84%	0,2473	47,99%	0,0020	0,0329	50,37%	0,0030	0,6473	440
Teknik	FGU	-0,76%	-2,0683	52,58%	-0,0027	-0,0684	48,53%	-0,0113	-0,3706	440
Teknik	IG	-1,07%	-0,3221	48,13%	0,0054	0,0196	50,97%	0,0022	0,2084	437
Teknik	ZG	-1,20%	-0,0329	49,43%	-0,0097	-0,1868	47,63%	-0,0159	-0,2558	440

Tabell 23 presenterar resultaten för alla kombinationer av de utvalda kombinationerna av bransch och faktorkombination med samtliga dt. Se tabell 10 för de kombinationer som valdes ut för vidare analys.

Tabell 23: Fullständig sammanställning av samtliga prediktionshorisonter för de utvalda kombinationerna av bransch och faktorkombination. Tabellen visar medelvärden över samtliga körningar inom respektive kombination.

Bransch	faktorkombination	dt	Portföljmått			Prediktiv styrka					Antal körningar
			Ann. avk.	Sharpe	Hit rate	Mean IC	IC IR	Positiv IC	Korr.	Z-score	
Konsumentvaror och tjänster	IG	1	6,39%	0,2714	53,95%	0,0075	0,0459	50,92%	0,0153	0,6487	88
Konsumentvaror och tjänster	IG	3	3,28%	0,3276	51,85%	0,0294	0,2101	55,57%	0,0161	0,6325	88
Konsumentvaror och tjänster	IG	6	0,41%	0,6518	56,48%	0,0235	0,1135	52,60%	-0,0021	0,1346	87
Konsumentvaror och tjänster	IG	9	3,12%	2,3998	43,30%	0,0278	0,1023	55,92%	-0,0110	-0,0587	87
Konsumentvaror och tjänster	IG	12	-0,66%	2,9770	45,79%	0,0378	0,2602	61,87%	0,0133	0,2747	87
Konsumentvaror och tjänster	ZG	1	-3,55%	-0,1156	49,44%	-0,0028	-0,0050	51,29%	-0,0015	0,0622	88
Konsumentvaror och tjänster	ZG	3	-2,19%	0,0250	51,87%	0,0065	0,0771	50,99%	-0,0087	0,2189	88
Konsumentvaror och tjänster	ZG	6	-5,36%	3,4819	46,70%	0,0012	-0,0395	50,89%	-0,0097	0,9060	88
Konsumentvaror och tjänster	ZG	9	0,48%	1,3430	50,19%	-0,0063	-0,1915	49,20%	-0,0199	0,7046	88
Konsumentvaror och tjänster	ZG	12	-2,13%	-0,2988	45,83%	0,0111	0,5529	50,91%	0,0049	1,5215	88
Finans	IG	1	9,24%	0,3215	53,90%	0,0442	0,1533	55,69%	0,0231	0,2861	88
Finans	IG	3	-7,60%	-0,1499	46,26%	-0,0081	-0,0427	49,60%	-0,0050	-0,0131	88
Finans	IG	6	-25,08%	-0,8943	37,99%	-0,0572	-0,2748	40,73%	-0,0747	-1,5804	87
Finans	IG	9	-19,39%	-1,1021	39,04%	-0,0845	-0,3986	37,16%	-0,0804	-1,4497	87
Finans	IG	12	-26,34%	-1,2679	30,94%	-0,0470	-0,1896	43,34%	-0,0736	-1,2906	87
Hälsovård	FGU	1	-0,80%	0,0331	51,05%	0,0009	0,0117	51,17%	-0,0073	-0,1934	88
Hälsovård	FGU	3	-1,56%	-0,0264	50,58%	0,0169	0,1089	53,27%	0,0117	0,5885	88
Hälsovård	FGU	6	1,54%	0,4372	48,66%	0,0252	0,2080	54,59%	0,0190	1,0041	88
Hälsovård	FGU	9	-4,08%	0,1448	39,36%	0,0155	0,2276	50,80%	0,0151	0,9510	88
Hälsovård	FGU	12	-2,95%	0,1641	43,47%	0,0165	0,1488	53,62%	-0,0181	0,5623	88
Hälsovård	ZG	1	-0,13%	0,0163	49,13%	0,0059	0,0324	50,79%	0,0069	0,3974	88
Hälsovård	ZG	3	-1,40%	-0,0960	46,36%	0,0074	0,0554	51,84%	0,0150	0,9677	88
Hälsovård	ZG	6	1,34%	1,2240	52,93%	0,0091	0,0202	52,94%	0,0219	1,2201	88
Hälsovård	ZG	9	-3,12%	0,1232	44,56%	-0,0049	0,0302	48,88%	-0,0023	0,5138	88
Hälsovård	ZG	12	-0,90%	-0,3457	46,97%	-0,0086	0,0221	47,03%	-0,0257	0,1378	88

Tabell 24 presenterar resultaten för alla kombinationer av de utvalda kombinationerna av bransch, faktorkombination och dt med samtliga regressioner. Se tabell 11 för de kombinationer som valdes ut för vidare analys.

Tabell 24: Fullständig sammanställning av samtliga regressionsmodeller för de utvalda kombinationerna av bransch, faktorkombination och prediktionshorisont. Tabellen visar medelvärden över samtliga körningar inom respektive kombination.


Bransch	faktorkombination	dt	Regression	Portföljmått			Prediktiv styrka					Antal körningar
				Ann. avk.	Sharpe	Hit rate	Mean IC	IC IR	Positiv IC	Korr.	Z-score	
Finans	IG	1	Elastic Net	17,61%	0,5589	55,45%	0,0730	0,2521	58,52%	0,0578	0,8513	22
Finans	IG	1	Lasso	11,79%	0,4003	53,67%	0,0633	0,2198	55,76%	0,0521	0,7078	22
Finans	IG	1	OLS	-1,99%	-0,0184	50,21%	0,0209	0,0644	54,86%	0,0030	0,0748	22
Finans	IG	1	Ridge	9,54%	0,3451	56,28%	0,0349	0,1294	54,55%	-0,0032	-0,2205	22
Konsumentvaror och tjänster	IG	1	Elastic Net	5,75%	0,2476	54,10%	0,0059	0,0332	50,09%	0,0196	0,8318	22
Konsumentvaror och tjänster	IG	1	Lasso	6,05%	0,2765	54,33%	0,0062	0,0329	50,69%	0,0183	0,7855	22
Konsumentvaror och tjänster	IG	1	OLS	3,52%	0,1404	51,85%	0,0055	0,0411	49,54%	0,0070	0,3063	22
Konsumentvaror och tjänster	IG	1	Ridge	10,24%	0,4212	55,52%	0,0123	0,0751	53,31%	0,0165	0,6856	22
Konsumentvaror och tjänster	IG	3	Elastic Net	3,33%	0,2784	54,35%	0,0318	0,1992	54,74%	0,0143	0,6284	22
Konsumentvaror och tjänster	IG	3	Lasso	1,97%	0,1492	50,45%	0,0280	0,1750	54,22%	0,0114	0,5497	22
Konsumentvaror och tjänster	IG	3	OLS	10,34%	0,7805	55,26%	0,0372	0,2685	56,81%	0,0240	0,7906	22
Konsumentvaror och tjänster	IG	3	Ridge	-2,51%	0,1022	47,34%	0,0205	0,1977	56,50%	0,0149	0,5613	22
Konsumentvaror och tjänster	ZG	12	Elastic Net	-4,08%	-0,1504	43,56%	0,0011	0,5182	49,61%	-0,0109	0,8192	22
Konsumentvaror och tjänster	ZG	12	Lasso	-3,89%	-0,1658	42,80%	0,0048	0,5161	50,40%	-0,0091	0,7998	22
Konsumentvaror och tjänster	ZG	12	OLS	1,52%	0,6738	55,68%	0,0362	0,7269	59,42%	0,0306	2,5173	22
Konsumentvaror och tjänster	ZG	12	Ridge	-2,08%	-1,5529	41,29%	-0,0002	0,4402	43,94%	0,0050	1,7553	22
Hälsovård	FGU	6	Elastic Net	1,28%	0,3084	48,24%	0,0301	0,2706	53,26%	0,0169	0,9663	22
Hälsovård	FGU	6	Lasso	1,36%	-0,0103	45,97%	0,0380	0,2230	53,33%	0,0142	1,0225	22
Hälsovård	FGU	6	OLS	-0,36%	1,2837	48,66%	0,0228	0,1978	55,80%	0,0231	1,0745	22
Hälsovård	FGU	6	Ridge	3,86%	0,1670	51,76%	0,0154	0,1574	55,27%	0,0201	0,9625	22
Hälsovård	ZG	6	Elastic Net	-0,06%	0,4167	51,24%	0,0185	0,0678	54,94%	0,0246	1,3043	22
Hälsovård	ZG	6	Lasso	-0,40%	0,5050	48,08%	0,0136	0,0151	51,56%	0,0196	1,2580	22
Hälsovård	ZG	6	OLS	3,29%	1,9134	60,14%	0,0078	-0,0073	54,28%	0,0264	1,3994	22
Hälsovård	ZG	6	Ridge	2,53%	2,0610	52,25%	-0,0010	0,0130	51,08%	0,0170	0,9352	22

Tabell 25 presenterar resultaten för alla kombinationer av de utvalda kombinationerna av bransch, faktorkombination, dt och regression med samtliga träningsfönster. Se tabell 12 för de utvalda slutkandidaterna.


Tabell 25: Fullständig sammanställning av samtliga tidsfönster för de utvalda slutkandidaterna. Tabellen visar medelvärden över samtliga körningar inom respektive kombination.

Bransch	faktorkombination	dt	Regression	Tidsfönster	Portföljmått			Prediktiv styrka					Antal körningar
					Ann. avk.	Sharpe	Hit rate	Mean IC	IC IR	Positiv IC	Korr.	Z-score	
Finans	IG	1	Elastic Net	2 år	35,10%	0,9687	60,42%	0,0970	0,3484	59,72%	0,1183	1,7794	8
Finans	IG	1	Elastic Net	5 år	19,33%	0,7183	58,60%	0,0805	0,2659	60,47%	0,0257	0,4809	6
Finans	IG	1	Elastic Net	10 år	-1,17%	0,0297	48,12%	0,0102	0,0319	52,21%	-0,0190	-0,5732	8
Konsumentvaror och tjänster	IG	3	OLS	2 år	26,03%	1,9290	65,62%	0,0523	0,4008	60,00%	0,0533	1,4905	8
Konsumentvaror och tjänster	IG	3	OLS	5 år	-0,34%	0,0097	49,70%	0,0277	0,2350	55,97%	0,0246	1,0845	6
Konsumentvaror och tjänster	IG	3	OLS	10 år	2,66%	0,2102	49,06%	0,0292	0,1612	54,24%	-0,0058	-0,1298	8
Konsumentvaror och tjänster	ZG	12	OLS	2 år	-4,95%	–	37,50%	-0,0421	–	37,50%	-0,0780	-0,6857	8
Konsumentvaror och tjänster	ZG	12	OLS	5 år	5,54%	0,7066	58,33%	0,0578	0,6605	66,13%	0,0643	2,0383	6
Konsumentvaror och tjänster	ZG	12	OLS	10 år	4,98%	0,6573	71,88%	0,0984	0,7767	76,31%	0,1141	6,0794	8

I tabellerna nedan presenteras visualiseringar av resultaten för branschmodellernas slutkandidater samt en jämförelse med de breda modellerna.



Figur 5: Figuren visar portföljprestation och prediktiv styrka hos slutkandidaterna för branschmodellerna



Figur 6: Figuren visar en jämförelse av portföljprestation och prediktiv styrka mellan slutkandidaterna för de breda modellerna och för branschmodellerna. Både genom medelvärden och enskilda toppresultat.